

ZAGADNIENIA PODSTAWOWE

ZAKRES I ZASTOSOWANIE WIEDZY PRZEKAZANEJ W RAMACH PRZEDMIOTU

Przedmiot „Wstęp do metod numerycznych” zajmuje się zagadnieniami z pogranicza teorii matematycznej i aplikacji w systemach komputerowych metod obliczeniowych. W szczególności przedstawione zagadnienia dotyczą: metod rozwiązywania bardziej skomplikowanych problemów przez aplikacje na komputerach i systemach cyfrowych zależności wynikających z różnych działów techniki np. teorii sterowania i regulacji, teorii przetwarzania sygnałów, teorii fizycznych (np. fizyki ciała stałego itp.) i innych. Znaczna część zagadnień jest też obecna w metodach analizy danych liczbowych stosowanych w różnych dziedzinach wiedzy np. analizy danych statystycznych w biologii, chemii czy ekonomii.

Kurs jest przeznaczony dla studentów kierunku „Elektronika”, więc nacisk będzie położony na techniczne aspekty zastosowania tej wiedzy. Wiedza dotycząca metod numerycznych przydaje się wszędzie tam, gdzie mamy do czynienia z tzw. maszyną numeryczną¹, która najczęściej jest komputerem, oraz danymi liczbowymi przedstawiającymi dane niebezpośrednie. Tzn. wtedy, kiedy nasze dane liczbowe którymi dysponujemy nie reprezentują dokładnie informacji, która nas interesuje, a jedynie informacje powiązane. W takim przypadku musimy interesujące nas wielkości z takich danych wydobyć stosując modele matematyczne właściwe dla danego zagadnienia wykorzystując do tego celu właśnie metody numeryczne. Typowe zastosowanie to a) ekstrakcja wartości użytecznej z danych pomiarowych, kiedy interesująca nas informacja lub parametr nie są bezpośrednio mierzalne, b) odtworzenie parametrów modelu matematycznego, kształtu zależności albo trendu z danych silnie zaburzonych, zawierających interesujące nas informacje, ale zaburzone szumem, błędami wynikającymi z niedoskonałości aparatury pomiarowej lub będącymi wynikiem statystycznej/losowej natury procesów które analizujemy, c) wykonanie symulacji rzeczywistych warunków działania opracowań, projektów konstrukcji.

Przykład a1:

Pomiar rezystancji wewnętrznej źródła (np. akumulatora) na podstawie pomiaru prądu i (napięcia), dla różnych wartości rezystancji obciążenia.

Przykład a2:

W obwodach elektrycznych ilość energii zgromadzona np. w systemie podtrzymywania awaryjnego zasilania w baterii superkondensatorów jest zależna od pojemności i napięcia wg wzoru:

$$W = \int_0^Q \frac{q}{C} dq \quad (1)$$

Kluczowym parametrem jest tutaj pojemność baterii kondensatorów. Z powodów technologicznych i użytkowych wraz z czasem i warunkami pracy pojemność superkondensatorów maleje. Naszym zadaniem jest zapewnienie systemu monitoringu tego parametru w celu sygnalizacji wymiany lub dania regulatorowi ładowania informacji do skompensowania tego efektu, tak aby nasz system podtrzymania działał z założonymi parametrami. Kontroler i system pomiarowy jest wbudowany w sterownik urządzenia i ma postać mikroprocesora lub mikrokontrolera – z punktu widzenia metod numerycznych jest to maszyna numeryczna. W trakcie studiów poznałeś lub poznasz pewne uproszczenia takiego problemu np. uproszczenie przytoczonego wzoru wynikające z założenia, że kondensator ładuje się stałym prądem.

W praktyce jednak często ze względów użytkowych lub technologicznych zaimplementowanie takich uproszczeń jest niemożliwe – wtedy pozostaje zastosowanie definicji. Wymaga ona zebrania przez określony odcinek czasu pomiarów prądu i napięcia, a następnie numerycznego scałkowania wg przytoczonego wzoru. Zastosowanie będą tutaj miały metody numerycznego całkowania, o których będziemy mówili w dalszej części wykładu.

Przykład a3:

Bardzo podobny problem znajduje się w teorii mocy. W obwodach prądu przemiennego podstawowa teoria mocy mówi o mocy czynnej i mocy biernej, o której uczyłeś się lub uczysz w trakcie teorii obwodów. Teoria ta jest jednak zaledwie przybliżeniem realnych zjawisk fizycznych dobrym,

¹Maszyną numeryczną jest każde urządzenie obliczeniowe, które ma ograniczony zestaw instrukcji arytmetycznych oraz posługuje się zapisem liczb o skończonej precyzji.

o ile spełnione jest założenie, że wszystkie przebiegi mają charakter sinusoidalny. W większości przypadków rzeczywistych tak nie jest – współczesny rozwój elektroniki i energoelektroniki powoduje, że przebiegi napięć i prądów pobieranych np. przez pomieszczenia w budynku nie przypominają w ogóle sinusoidy (szczególnie jeżeli chodzi o prądy). Powstaje zatem problem jak szacować moc pobieraną przez danego odbiorcę w celu obciążenia płatnością lub prognozowania zużycia i produkcji. Jedyną skuteczną metodą jest zatem obliczenie zużytej energii z definicji:

$$W = \int_{t_0}^{t_1} i(t)u(t)dt \quad (2)$$

Pomiar polega zatem na próbkowaniu przebiegów i napięć przez określony okres, a następnie ich numerycznemu całkowaniu.

Przykład b1:

Zmierzono charakterystykę prądowo-napięciową diody w kierunku zaporowym w celu wyznaczenia jej parametrów. Mierzone prądy są na tyle niskie, że nie można pominąć szumu termicznego szeregowych rezystancji (wynikających w głównej mierze z układu pomiarowego). Wyznaczone parametry mogą znacznie odbiegać od rzeczywistości. Jeżeli poprawa dokładności pomiaru nie jest możliwa przez rekonfigurację stanowiska pomiarowego/zastosowanie lepszego miernika, można „odszumić” dane numerycznie, np. poprzez zastosowanie średniej, mediany, transformaty falkowej itp. Wykorzystanie przetworzonej charakterystyki do wyznaczenia parametrów powinno skutkować wynikami znacznie bliższymi rzeczywistości. O niektórych metodach odszumiania danych będzie mowa w dalszej części wykładu.

Przykład b2:

Energję aktywacji domieszki w półprzewodniku można wyznaczyć na podstawie nachylenia krzywej Arrheniusa, tj. wykresu koncentracji nośników w funkcji odwrotności temperatury. Koncentrację nośników w funkcji temperatury można wyznaczyć np. poprzez pomiar efektu Halla, przy czym pomiar taki może być obciążony dużym szumem. W takim przypadku można zastosować aproksymację danych funkcją liniową (regresję liniową), a energję aktywacji należy wyznaczyć z nachylenia funkcji aproksymującej. Metody przybliżania danych wejściowych za pomocą funkcji oraz odtwarzania przebiegu funkcji na podstawie wybranych punktów charakterystyki również będzie przedmiotem wykładu.

Przykład c1:

Z teorii pola i elektromagnetyzmu wiemy, że charakterystyka kierunkowa anteny (np. anteny Bluetooth) odpowiada teoretycznej charakterystyce w wolnej przestrzeni m.in. wtedy, kiedy w tzw. polu bliskim anteny² nie ma elementów o dużej przewodności. Niestety ze względów konstrukcyjnych (np. antena jest zintegrowana w telefonie komórkowym), takich elementów nie można wyeliminować. Musimy sprawdzić i ewentualnie dobrać takie położenie i konstrukcję anteny, aby w jak największym stopniu spełnić założenia projektowe. Skomplikowana rzeczywista geometria nie pozwala na zastosowanie metod analitycznych, realistyczne wyniki uzyskamy wyłącznie w przypadku zastosowania symulatora CAD (*ang. Computer Aided Design*). Symulatory takie rozwiązują w przestrzeni podstawowe równania, w tym wypadku równania Maxwella, w rzeczywistej geometrii wg zadanych wytycznych. Działanie tych symulatorów opiera się na metodach numerycznych rozwiązywania równań różniczkowych cząstkowych. W ramach wykładu prawdopodobnie nie uda się nam omówić całkowicie tego zagadnienia, jednak przerobiony materiał powinien wyposażać absolwenta przedmiotu w umiejętności pozwalające skutecznie (czyli nie bezmyślnie) korzystać z tego typu symulatorów.

Przykład c2:

Analogiczny przykład dotyczy wszelkich problemów termicznych w konstrukcji urządzeń i przyrządów. Przypuśćmy, że mamy do czynienia z urządzeniem lub systemem energoelektronicznym o określonej mocy dysponowanej. Każdy element tego systemu ma określone parametry i potrafimy oszacować lub obliczyć moc traconą w takim elemencie w trakcie różnych warunków pracy. Chcemy sprawdzić czy nie zostaną przekroczone wytrzymałościowe parametry graniczne w naszym rozwiązaniu we wszystkich przewidywanych warunkach pracy. Ponownie skomplikowana geometria i wielość elementów, przez które przepływa ciepło, a także zróżnicowanie mechanizmów tego przepływu

²Tzn. w określonym obszarze dookoła anteny.

sprawiają, że nie da się z dostateczną dokładnością problemu tego rozwiązać analitycznie. Pozostają nam tylko kosztowne pod względem czasu i pieniędzy eksperymenty, albo właśnie symulacje numeryczne. Tym razem rozwiązywać będziemy równania cząstkowe innego typu – równania dyfuzji, ponieważ transport ciepła jest opisany takimi właśnie równaniami.

Przykład c3:

Projektujemy układ elektroniczny (w zasadzie dowolny, przyjmijmy, że jest to przetwornica zasilająca), który pracuje w zakresie warunków mogących być analizowanymi za pomocą teorii obwodów. Stosując wiedzę z zakresu np. energoelektroniki jesteśmy w stanie określić podstawowe parametry układu np. indukcyjność cewki pracującej w przetwornicy. Musimy jednak dobrać teraz takie wartości parametrów drugorzędnych (np. prądu maksymalnego cewki), aby układ działał w warunkach, w jakich metody projektowe, których użyliśmy, działają. Często krytyczne warunki pracy występują w stanach nieustalonych układu, w tym przypadku np. w trakcie startu przetwornicy szczytowe wartości prądu w cewce mogą przekraczać kilkukrotnie wartości w stanie ustalonym. Ponieważ nie chcemy przewymiarować znacząco rozwiązania (brak miejsca, nieakceptowalny wzrost kosztów lub generacja innych problemów np. termicznych) musimy wiarygodnie oszacować parametry pracy elementów. Posłużymy się w tym celu symulatorem obwodowym typu SPICE. W zależności od wykonywanej symulacji będzie on rozwiązywał albo układy równań liniowych lub równań różniczkowych zwyczajnych opisujących nasz przypadek. Metody numeryczne dotyczące tych zagadnień również zostaną omówione w trakcie wykładu.

Przytoczone powyżej przykłady nie wyczerpują stosowalności wiedzy z metod numerycznych. Zjawiska, o których będziemy mówili mają charakter podstawowy i manifestują się w różnych miejscach.

W rzeczywistości (w zawodowej praktyce inżynierskiej) rzadko zajdzie potrzeba, aby samodzielnie implementować bezpośrednio którąś z przedstawianych na wykładzie metod numerycznych. Mimo to dużą część zajęć przeznaczymy na omówienie konkretnych z nich, co więcej w trakcie laboratoriów czasem wymagać będziemy zaimplementowania konkretnej z nich. Wydaje nam się, że jest to jedyny sposób, aby skutecznie zaprezentować pewne zjawiska numeryczne o charakterze ogólnym. To właśnie zrozumienie tych zjawisk jest kluczowe dla świadomego korzystania z metod numerycznych w zagadnieniach inżynierskich. Najczęściej bowiem praktycznie użyteczne metody są implementowane w skomplikowany sposób (np. są połączeniem różnych metod rozwiązania danego problemu) ze względu na konieczność obsłużenia różnych efektów numerycznych, o których będziemy mówili w trakcie wykładu.

W praktyce inżynierskiej:

- Korzystamy z gotowych bibliotek i implementacji bądź specjalistycznego oprogramowania mającego takie biblioteki wbudowane – nasze laboratorium będziemy prowadzić na oprogramowaniu MATLAB, które jest tego typu pakietem. Przykładem mogą być też liczne biblioteki „open source” do typowych języków programowania np. pythona, C++ itd. W przeważającej liczbie problemów implementacje tam zakodowane są znacznie bardziej wydajne, stabilne i przemyślane niż to, co moglibyśmy stworzyć samemu.
- W przypadku symulatorów, o ile nie pracujemy w firmie zajmującej się rozwojem tego typu oprogramowania lub nie zajmujemy się tego typu rozwiązaniami z naukowego punktu widzenia, raczej będziemy korzystać z oprogramowania i zaimplementowanych metod sterując tylko ich parametrami albo wybierając do danego przypadku odpowiednią metodę spośród tych, które zostały zaimplementowane w symulatorze.
- Często metody numeryczne są zaimplementowane przez producentów układów scalonych (co zazwyczaj ma miejsce w układach takich jak np. w przykładach a2 i a3) i pracę tę wykonuje wąska grupa specjalistów. Jednak znacznie większe grono absolwentów naszego wydziału musi umieć poprawnie skonfigurować i posłużyć się takim chipem jako programiści systemów wbudowanych (*ang. embedded*).

Dlatego znacznie ważniejszą wiedzą niż to, jak działają same metody jest to, jakie są problemy numeryczne z jakimi spotykamy się w konkretnych zagadnieniach numerycznych, analiza zjawisk z jakimi mamy do czynienia, ich przyczyn, parametrów jakich używamy do ich klasyfikacji i opisu. Pozwala to bowiem sprawnie posługiwać się każdą metodą numeryczną, pozwala wybrać odpowiednią metodę do swojego problemu, a następnie systematycznie i krytycznie analizować wyniki.

Proszę zwrócić uwagę, że natura numerycznych rozwiązań jest taka, że zawsze zwracają one jakąś liczbę jako wynik swojego

OGÓLNY SPOSÓB ROZUMOWANIA METOD NUMERYCZNYCH, DEFINICJE

Na najwyższym stopniu ogólności w metodach numerycznych posługujemy się pojęciem „maszyny numerycznej”. W większości rzeczywistych przypadków należy rozumieć pod tym pojęciem komputer. Niemniej

maszyna numeryczna jest pojęciem szerszym. Maszyną numeryczną jest każde urządzenie obliczeniowe, które ma ograniczony zestaw instrukcji arytmetycznych oraz posługuje się zapisem liczb o skończonej precyzji. W rzeczywistości na co dzień używamy wielu typów maszyn numerycznych np.:

- Komputery, a w zasadzie procesory – istnieje wiele różnych konstrukcji procesorów o różnych właściwościach (innym zestawie instrukcji, budowie pamięci itd.) np. procesory ogólnego stosowania (w tej grupie różne architektury i podgrupy np. 32-i 64 bitowe), procesory graficzne (różniące się od poprzednich dostępnym zestawem instrukcji), koprocesory np. kryptograficzne itd.
- Mikroprocesory i mikrokontrolery – także o różnych architekturach, różniące się od poprzedniej grupy uproszczoną budową, ale także większą energooszczędnością i innymi cechami użytkowymi.
- Procesory sygnałowe. Dedykowane przetwarzaniu sygnałów, odpowiadają na potrzebę np. szybkiego obliczania transformaty Fouriera itp.
- Maszyną numeryczną może być nawet programowalny układ typu FPGA, CPLD, albo nawet kombinacyjny system złożony z elementów dyskretnych, bramek itd. – konstrukcje takie były popularne w latach 80-90 ubiegłego wieku. Wszystkie te systemy jako całość wykonują obliczenia, mają skończoną długość słowa w pamięci i ograniczony zestaw instrukcji – są więc maszynami numerycznymi.

Wszystko to są urządzenia o różnych długościach słowa i różnych zestawach instrukcji – różne maszyny numeryczne. Pojęcie maszyny numerycznej jest jeszcze szersze, nie ogranicza się bowiem do urządzeń wykonujących obliczenia w systemie dwójkowym. Nie ma jakościowo dla naszej analizy żadnego znaczenia jak zapisywane są liczby w pamięci – maszyną numeryczną będzie też zeszyt i ołówek jeżeli tylko będziemy zawsze zapisywać liczby np. z dokładnością do drugiego miejsca po przecinku (skończona dokładność) i wykonywali tylko skończony zestaw instrukcji. Taka maszyna numeryczna będzie maszyną działającą w systemie dziesiętnym.

Drugim podstawowym aspektem metod numerycznych jest pojęcie modelu matematycznego. Przez model rozumiemy matematyczny opis obserwowanych zjawisk/zależności. Jest on konieczny, żeby wyciągać wnioski natury ilościowej na temat zależności między różnymi wielkościami fizycznymi (w szczególności, żeby obliczyć wartość jednej wielkości fizycznej na podstawie znajomości innych). Np. do wyznaczenia wykonanej pracy (energii) można posłużyć się modelem całki z mocy chwilowej, w skali makroskopowej jest to wzór działający w każdych warunkach:

$$W = \int_{t_0}^{t_1} i(t)u(t)dt \quad (3)$$

W pewnych przypadkach można zastosować bardziej szczegółowy model np. właściwy dla prądu stałego:

$$W = tUI \quad (4)$$

To jest inny model opisujący ten sam problem. Różni się on od poprzedniego tym, że nie wymaga całkowania – jest więc prostszy, a co za tym idzie łatwiejszy do rozwiązania (wymaga mniej zasobów), i wiąże się z nim inny zestaw problemów numerycznych – zamiast całkowania wystarczy wykonać mnożenie. Należy jednak mieć na uwadze, że w przypadku niespełnienia warunków stosowania modelu, prowadzić on będzie do całkowicie błędnych wyników. Najczęściej proste modele mają ograniczone zastosowanie i zmuszeni jesteśmy korzystać z modeli bardziej zaawansowanych. Jest to bezpośrednią przyczyną rozwoju metod numerycznych.

Często w celu rozwiązania zagadnienia należy przeprowadzić kaskadę operacji numerycznych. Przykładowo:

Znamy wartości jakiejś wielkości (np. pola) w określonych punktach w przestrzeni, na podstawie tej wiedzy chcemy obliczyć wartość pochodną (rozwiązując równania różniczkowe opisujące ten problem), następnie wyznaczyć przybliżone wartości wyniku naszych obliczeń w punktach, które nie są naszymi punktami rozwiązania (pomiędzy nimi – interpolacja, aproksymacja), a na koniec na tej podstawie podać jakąś interesującą nas wielkość zależną – np. całkę z przekroju obiektu w wyznaczonych punktach, która jest proporcjonalna do np. ciepła.

Takie zagadnienie jest złożone. Zamiast zatem wymyślać specjalistyczne metody numeryczne tylko do tego stosujemy podejście modułowe. **Skupiamy się na opracowaniu jak najlepszych metod rozwiązywania pewnych często spotykanych zagadnień nazywanych przez nas problemami numerycznymi.** Bardziej złożone zagadnienia staramy się wyrazić za pomocą takiego modelu, żeby był on sekwencją tych typowych problemów numerycznych, które będą rozwiązywane w typowy, ustandaryzowany sposób.

W trakcie naszego wykładu zapoznamy się z podstawowymi problemami numerycznymi, którymi są:

- Rozwiązywanie układów równań liniowych

- Rozwiązywanie układów równań nieliniowych
- Interpolacja, aproksymacja, transformata Fouriera
- Metody numerycznego całkowania i różniczkowania
- Metody rozwiązywania układów równań różniczkowych zwyczajnych

Problemów numerycznych jest znacznie więcej. Podane powyżej są problemami podstawowymi i najprostszymi. Warty wspomnienia problemami numerycznymi, o których nie będziemy mówić to problem regresji, problem rozwiązywania układów równań różniczkowych cząstkowych, problem optymalizacji lokalnej i inne.

Przedmiotem analizy w metodach numerycznych są dwa podstawowe aspekty ich działania:

- Koszt jaki musimy ponieść żeby uzyskać wynik – z tym wiąże się pojęcie **złożoności obliczeniowej i złożoności pamięciowej** (na WNUM co do zasady nie będziemy zajmować się złożonością pamięciową)
- Dokładność rozwiązania – z tym wiąże się pojęcie **dokładności lub inaczej błędu rozwiązania**

W większości wypadków (choć nie zawsze!) złożoność można wymienić na dokładność – wykonując więcej obliczeń można otrzymać dokładniejszy wynik.

Złożoność i błąd w każdej metodzie będą zależeć od rozmiaru problemu. W każdym problemie numerycznym pojęcie rozmiaru może oznaczać coś innego, ale zawsze jest to parametr, wraz z którym rosną koszty obliczeniowe/maleje dokładność rozwiązania. Przykładowo: w przypadku układów równań rozmiarem problemu jest liczba równań w układzie, a w przypadku interpolacji, aproksymacji, całkowaniu i różniczkowaniu jest to liczba punktów w danych wejściowych.

NAJWAŻNIEJSZE PODSTAWOWE ZAŁOŻENIA MATEMATYCZNE

Maszyny numeryczne korzystają oczywiście z matematyki i mają charakter matematyczny. Niektóre zagadnienia z zakresu algebry i analizy matematycznej mają szczególnie szerokie zastosowanie w metodach numerycznych. W niektórych przypadkach wykorzystują elementarną naturę matematycznych koncepcji, co pozwala nam spojrzeć na teoretycznie poznane zagadnienia od innej strony. Często dopiero w zastosowaniu zdajemy sobie sprawę jak pięknymi są te koncepcje, które poznaliśmy w programie studiów w formie nieatrakcyjnych wzorów. Dla przypomnienia podamy kilka klasycznych definicji pojęć matematycznych wykorzystywanych w metodach numerycznych oraz postaramy się pokazać sens ich stosowania.

WEKTORY I MACIERZE

Macierz to wg matematycznej definicji zestaw liczb zapisanych razem w postaci prostokątnej tablicy. Przykładowo:

$$\mathbf{A} = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 2 & 3 \\ 3 & 7 & 8 \end{bmatrix}, \mathbf{w} = [1 \quad 2 \quad 3], \text{ oraz } \mathbf{v} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$$

są macierzami.

Można spotkać się z różnymi definicjami wektora. Można myśleć o wektorach jako o długości wraz z kierunkiem (w polskiej nomenklaturze kierunek jest określany przez kierunek i zwrot) – jest to wygodna intuicja do ilustracji wielkości fizycznych, które charakteryzują się określoną orientacją przestrzenną. Można myśleć o wektorze jako o ciągu liczb (w szczególności odpowiadających poszczególnym składowym przestrzennym kartezjańskiego układu odniesienia punktu lub wielkości skierowanej), albo szerzej ciągu zmiennych – z takim rozumieniem wektora mamy do czynienia, kiedy wektorem nazywamy tablicę zmiennych przechowywaną w pamięci komputera. Można wreszcie potraktować wektor ściśle wg definicji matematycznej, czyli jako element przestrzeni liniowej, czyli jako obiekt abstrakcyjny charakteryzujący się tym, że może być dodawany do innych wektorów oraz mnożony przez liczbę rzeczywistą (ograniczając definicję do wektorów nad ciałem liczb rzeczywistych). Najczęściej wektory zapisujemy w postaci macierzowej:

$$\mathbf{v} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \quad (5)$$

Przy czym w algebrze macierzowej należy wektory zapisywać w formie pionowej (np. macierz 3x1 dla wektora opisującego położenie punktu w przestrzeni trójwymiarowej) – poniżej zostanie wyjaśnione dlaczego.

Przy tym należy zaznaczyć, że ze względów łatwości zapisu w tekście często spotyka się zapis wektora w formie poziomej, albo używa się tych notacji wymiennie, co może być mylące – będziemy starali się trzymać zapisu wektorów w formie pionowej, ale należy zachować czujność. W ramach niniejszego wykładu macierze i wektory oznaczać będziemy symbolami pogrubionymi. Przykładowo:

A, **w** oznacza macierz i wektor, podczas, gdy *A*, *w* oznaczają wartości skalarne.

Warto zaznaczyć, że **jeżeli zapisujemy coś w notacji macierzowej/wektorowej to chcemy podkreślić, że należy te liczby traktować jako spójną całość i należy je zawsze traktować razem jako system, a nie osobno.**

Zmienia to zasadniczo podejście do obiektów opisanych za pomocą takiej notacji.

PRZYKŁAD 1

W przestrzeni 3D pojedyncza współrzędna wyrażona jest liczbą. Ale punkt w tej przestrzeni wyrażony jest wektorem:

$$\mathbf{p} = \begin{bmatrix} x \\ y \\ z \end{bmatrix} \quad (6)$$

jeżeli będziemy wykonywać jakieś operacje na punkcie, to matematyczny opis takiej operacji będzie działał na cały wektor, a nie na pojedynczą współrzędną (oczywiście działanie na wektor będzie implikowało działanie na współrzędnych, ale chodzi o hierarchię skomplikowania opisu, czyli właściwy opis matematyczny systemu).

PRZYKŁAD 2

Napięcie na pojedynczym elemencie systemu elektronicznego opisane jest za pomocą wartości skalarnej U_1 . Jednak cały system opisany jest za pomocą wektora napięć, ponieważ oddziałują one na siebie i muszą być traktowane łącznie jako system, a nie osobno:

$$\mathbf{U} = \begin{bmatrix} U_1 \\ U_2 \\ \vdots \\ U_N \end{bmatrix} \quad (7)$$

System elektroniczny musi być traktowany łącznie, więc operacje wykonywane na tym systemie będziemy opisywać działaniami matematycznymi działającymi na wektor napięć, a nie pojedyncze napięcie.

W interpretacji geometrycznej algebry liniowej wektor opisuje punkt przestrzeni. W zastosowaniach praktycznych wektory najczęściej opisują stan systemu, a dokładniej stan parametrów jakimi nasz system opisujemy.

W interpretacji geometrycznej algebry liniowej macierz kwadratowa odpowiada transformacji liniowej przestrzeni (kolejne kolumny macierzy mówią jak zostaną przetransformowane poszczególne składowe przestrzenne wektora, na który działa macierz – z tego wynika, że aby wektor pomnożyć przez macierz musi ona mieć tyle kolumn ile wektor ma wierszy). W wyniku mnożenia wektora przez macierz otrzymujemy wektor, który będzie miał tyle wymiarów, ile wierszy miała macierz na niego oddziałująca. Macierz prostokątna będzie zatem odpowiadała przekształceniu zmieniającemu liczbę wymiarów wektora (przykładowo macierz 1x3 może zmienić wektor trójwymiarowy w liczbę). Właśnie dlatego macierz 3x1 traktujemy jako wektor (punkt przestrzeni lub wektor stanów), a macierz 1x3 jako macierz (przekształcenie). Zapisu tego należy pilnować w trakcie implementacji kodu MatLab'owego.

Sens ma również mnożenie macierzy przez siebie. W wyniku otrzymamy macierz, która odpowiada przekształceniu będącego złożeniem dwóch przekształceń składowych. Pamiętać oczywiście trzeba, że mnożenie macierzy nie jest przemienne (kolejność przekształceń ma znaczenie). Niech zilustruje to przykład: punkt $(\sqrt{2}, 0)$ poddajemy obrotowi o 45 st. w lewo wokół początku układu współrzędnych, a następnie odbijamy

lustrzanie względem osi y, powinniśmy wyładować na punkcie $(-1, 1)$ odpowiada to następującym operacjom macierzowym:

$$\begin{bmatrix} -1 \\ 1 \end{bmatrix} = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix} \begin{bmatrix} \sqrt{2} \\ 0 \end{bmatrix} = \begin{bmatrix} -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix} \begin{bmatrix} \sqrt{2} \\ 0 \end{bmatrix} \quad (8)$$

Macierz operacji złożonych

Macierz obrotu

Wektor wyniku

Wektor początkowy

Wektor początkowy

Macierz lustrzanego odbicia

Z kolei przeprowadzenie tych operacji na ten sam wektor początkowy w odwrotnym porządku spowoduje, że wynikiem będzie punkt $(-1, -1)$, w zapisie macierzowym przedstawiło by się to tak:

$$\begin{bmatrix} -1 \\ -1 \end{bmatrix} = \begin{bmatrix} \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix} \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \sqrt{2} \\ 0 \end{bmatrix} = \begin{bmatrix} \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \\ -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix} \begin{bmatrix} \sqrt{2} \\ 0 \end{bmatrix} \quad (9)$$

Macierz operacji złożonych

Macierz lustrzanego odbicia

Wektor wyniku

Wektor początkowy

Wektor początkowy

Macierz obrotu

W zastosowaniach numerycznych: zazwyczaj przez macierz wyrażamy pewną zmianę stanu układu, a dany stan układu jest reprezentowany przez wektor. Dzięki temu skomplikowane rzeczywiste zależności (np. wzajemnie zależne zmiany parametrów złożonego układu elektronicznego) możemy wyrazić w postaci jednego mnożenia. W technice macierze często są wykorzystywane do tego celu.

Pozornie wyjątkiem będzie zapis układu równań np.:

$$\begin{bmatrix} 1 & 1 & 2 \\ 3 & 2 & 1 \\ 3 & 4 & 2 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 4 \\ 5 \\ 6 \end{bmatrix} \quad (10)$$

$$\mathbf{Ax} = \mathbf{b} \quad (11)$$

Jednak układ trzech równań z trzema niewiadomymi można interpretować graficznie (każde z równań wyznacza pewną płaszczyznę punktów). Jeżeli żadna para tych płaszczyzn nie jest równoległa, to istnieje dokładnie jeden punkt ich przecięcia -> szukane x, y i z. Jeżeli przynajmniej dwie płaszczyzny są równoległe, to albo wszystkie z nich się pokrywają (nieskończenie wiele rozwiązań), albo nie mają punktów wspólnych (układ sprzeczny). Podobne rozumowanie można przeprowadzić dla dowolnej liczby wymiarów, zatem metoda macierzowa rozwiązywania układów równań doskonale realizuje założenia algebry liniowej.

PRZYKŁAD

W zapisie cyfrowym obrazu każdemu pikselowi trójwymiarowego obrazu można przypisać współrzędną x, y, z względem ustalonego punktu odniesienia (najczęściej któregoś z rogów obrazu). W konsekwencji pojedynczy piksel może być opisany za pomocą wektora:

$$\mathbf{p} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} \quad (12)$$

Wyznaczenie obrazu będącego wynikiem obrotu obrazu podstawowego o kąt θ polega na przemnożeniu wszystkich pikseli obrazu przez macierz opisującą to przekształcenie. Ma ona postać:

$$\mathbf{Q} = \begin{bmatrix} \cos(\theta) & 0 & -\sin(\theta) \\ 0 & 1 & 0 \\ \sin(\theta) & 0 & \cos(\theta) \end{bmatrix} \quad (13)$$

W zastosowaniach praktycznych macierze zazwyczaj opisują działanie, któremu poddany jest system opisany wektorami stanu.

Oczywiście koncepcja macierzy i wektora nie jest ograniczona tylko do powyższych przykładów, ale w ramach metod numerycznych uświadomienie powyższych zależności pomaga znacznie zrozumieć logikę działania wielu metod. W szczególności pamiętać należy o odpowiedniej (pionowej) orientacji wektora reprezentującego stan układu w problemie numerycznym.

BŁĄD WZGLĘDNY I BEZWZGLĘDNY

W metodach numerycznych jednym z elementów, któremu poświęcimy najwięcej uwagi, jest dokładność metody, wyrażana za pomocą błędu rozwiązania. Wyróżniamy dwa podstawowe rodzaje błędu:

- Błąd bezwzględny

$$\Delta x = |\tilde{x} - x| \quad (14)$$

- Błąd względny

$$\delta x = \frac{|\tilde{x} - x|}{x} = \frac{\Delta x}{x} \quad (15)$$

UWAGA! W ramach zajęć przyjmujemy notację, wg której przez falkę nad symbolem będziemy rozumieć przybliżenie prawdziwej wartości. Zatem w powyższych wzorach $\tilde{x}$ oznacza wartość przybliżoną, a x wartość prawdziwą jakiejś wartości, albo rozwiązania problemu.

Błąd bezwzględny podaje ilościową wartość – różnicę pomiędzy wartością przybliżoną/otrzymaną, a wartością dokładną/prawdziwą (wyrażony jest w tych samych jednostkach, co dana wielkość). Jest on najczęściej używany do oszacowania, czy wynik nas zadowala z praktycznego punktu widzenia (np. jeżeli do wnęki 102 cm zamówimy szafę na 100 cm, tj. założymy 2 cm marginesu, to jeżeli w wyniku niedokładności/błędu wykonawczego szafa zostanie przewymiarowana o więcej, niż 2 cm, nie zmieści się nam w zaplanowane miejsce). W niektórych zastosowaniach (tak jak w powyższym przykładzie) wygodnie jest mówić o błędzie z uwzględnieniem znaku ($\Delta x = \tilde{x} - x$), nam to zazwyczaj nie będzie potrzebne. Czasami z kontekstu trzeba wyczuć, czy autor miał na myśli błąd z uwzględnieniem znaku, czy nie.

Błąd względny jest to stosunek (modułu) różnicy pomiędzy wartością przybliżoną/uzyskaną, a wartością dokładną/prawdziwą, do tej wartości. Służy do porównywania dokładności, własności numerycznych różnych metod i sposobów zapisu. W trakcie WNUM będziemy się nim posługiwać znacznie częściej, niż pojęciem błędu bezwzględnego. Rzadko stosowany z uwzględnieniem znaku.

Osobnego omówienia wymaga błąd obiektów innych niż skalary. W przypadku wektorów właściwym sposobem wyrażenia błędu jest odpowiednia norma wektora błędu, a nie błąd każdej ze współrzędnych osobno. Przykładowo na poniższym rysunku mamy dwa punkty. Punkty są jak wiemy obiektami opisanymi za pomocą wektora współrzędnych. Przypuśćmy, że prawidłowym rozwiązaniem jest (3,2), ale my uzyskaliśmy wynik (7,8). Można zadać pytanie jaki jest błąd naszego rozwiązania?


Różnica rozwiązania przybliżonego i dokładnego jest wektorem (nazywamy go wektorem błędu), ale w większości wypadków jest to niepraktyczna miara niedokładności. W szczególności trudno porównywać ją z innymi niedokładnościami. Dobrym rozwiązaniem jest przyjęcie jakiejś cechy (normy) wektora (najlepiej dającej się wyrazić w postaci liczby), która pozwoli wektory błędu porównywać ze sobą równie łatwo, jak mogliśmy porównywać błędy wielkości skalarnych. Najbardziej intuicyjną normą jest długość wektora. W dwuwymiarowym przypadku:

$$\delta = \sqrt{\Delta x^2 + \Delta y^2} \quad (16)$$

Można jednak porównywać wektory błędów za pomocą innych norm. Pojęcie to omówimy za chwilę nieco szerzej. Długość wektora jest nazywana również normą drugą.

Podsumowując: **za miarę niedokładności rozwiązania wielowymiarowego przyjmujemy normę wektora będącą różnicą rozwiązania przybliżonego i dokładnego.**

PRZYKŁADOWO



Przypuśćmy, że prawidłowym rozwiązaniem jest (3,2), ale my uzyskaliśmy wynik (7,8). Można zadać pytanie jaki jest błąd naszego rozwiązania?

Na powyższym rysunku wektor błędu to:

$$\delta = \begin{bmatrix} 7 - 3 \\ 8 - 2 \end{bmatrix} = \begin{bmatrix} 4 \\ 6 \end{bmatrix} \quad (17)$$

Jeżeli będziemy mówili o błędzie rozwiązania, to zazwyczaj będziemy mieli na myśli drugą normę wektora błędu, czyli:

$$\|\delta\|_2 = \sqrt{4^2 + 6^2} = 2\sqrt{13} \quad (18)$$

Dla normy drugiej wielowymiarowego wektora $\mathbf{x}$ prawdziwy będzie wzór:

$$\|\delta\|_2 = \sqrt{\sum_{i=1}^W \delta_i^2} = \sqrt{\Delta x_1^2 + \dots + \Delta x_W^2}, \text{ gdzie } W = \text{liczba wymiarów wektora } \mathbf{x}$$

W oznaczeniu normy pogrubione delta oznacza wektor błędu, ale suma pod pierwiastkiem jest po wszystkich elementach tego wektora. Teraz wartość liczbową błędu rozwiązania ma sens i jest po prostu odległością między dwoma punktami – dokładnym i przybliżonym w przestrzeni wielowymiarowej.

NORMY WEKTORÓW

Łatwo jest porównywać ze sobą liczby (dobrze zdefiniowana relacja większy/równy/mniejszy). W przypadku innych obiektów pojawić się mogą różne trudności: analogią z życia codziennego może być próba określenia relacji większy/mniejszy na ludziach – nie da się tego przeprowadzić, dopóki nie doprecyzujemy co jest dla nas cechą charakterystyczną: wzrost, waga, obwód bicepsa, czy może pewna wielkość abstrakcyjna zależna od tych różnych parametrów np. tzw. BMI. Dopiero określenie tej cechy i przypisanie jej wartości liczbowej pozwala dokonać porównania. Inaczej mówiąc, zanim obiekty nie liczbowe zostaną poddane porównaniu powinny zostać unormowane do wartości liczbowych (czasem nawet wartości liczbowe normuje się do jedności, żeby łatwiej było określić stosunek pomiędzy przedstawianymi na wykresie wielkościami). **Norma wektora** (oznaczana podwójnymi prostymi nawiasami - $\|\cdot\|$) **jest jednoznacznym przyporządkowaniem wartości liczbowej odpowiedniej dla zestawu cech tego wektora związanych z długością.** Dowolne jednoznaczne przyporządkowanie wektorowi liczby nieujemnej będzie nazywane normą, jeżeli spełnia ona pewne dodatkowe

warunki. Wykracza to jednak poza przedmiot niniejszego wykładu. Ograniczymy się do przedstawienia norm tworzonych wg wzoru Shura (wzoru Höldera):

$$\|\mathbf{x}\|_p = \left(\sum |x|^p \right)^{\frac{1}{p}} \quad \text{dla } p = 1, 2, \dots, \infty \quad (19)$$

Najczęściej stosuje się trzy z nich:

- Norma pierwsza

$$\|\mathbf{x}\|_1 = \sum_{n=1}^N |x_n| \quad (20)$$

- Norma druga


$$\|\mathbf{x}\|_2 = \sqrt{\sum_{n=1}^N |x_n|^2} \quad (21)$$

- Norma nieskończoność (maksimum)

$$\|\mathbf{x}\|_\infty = \sup \{ |x_n| \mid n = 1, 2, \dots, N \} \quad (22)$$

Przy czym N to liczba składowych elementów wektora (liczb wymiarów). Szczególnie często wykorzystywana jest norma 2 ponieważ w przestrzeni euklidesowej (czyli takiej z jaką mamy do czynienia na co dzień) jest liczbowo równa odległości między punktami.

Dla zobrazowania tych pojęć na poniższym rysunku wyznaczono obszary, w którym leży punkt (wektor) z normą (dla norm pierwszej, drugiej i normy nieskończoność) mniejszą od pewnego zadanego poziomu błędu oznaczonego, jako δ . Inaczej mówiąc, jeżeli punkt $(0, 0)$ byłby rozwiązaniem dokładnym, to wszystkie rozwiązania w zaznaczonych obszarach byłyby obciążone błędem (w sensie odpowiedniej normy) mniejszym, niż δ .



Przyjrzyjmy się teraz normom innych obiektów niż punkty (wektory stanu).

pozwala porównywać wielkość różnych wektorów

norma macierzy

pozwala porównywać wielkość różnych przekształceń (macierzy)

normy macierzy

norma wektora

Normą numer p macierzy $\mathbf{A}$, nazywamy maksymalną zmianę długości wektora $\mathbf{x}$ (długości w sensie normy p) spośród wszystkich wektorów, które mogą być przekształcone przez tą macierz. Formalnie zapisujemy to:

$$\|\mathbf{A}\|_p = \sup_{\mathbf{x} \neq \vec{0} \text{ i } \mathbf{x} \in X} \left\{ \frac{\|\mathbf{Ax}\|_p}{\|\mathbf{x}\|_p} \right\} \quad (23)$$

Zagadnienie wyznaczania normy macierzy w ogólności wykracza poza ramy tego wykładu, jednak przedstawiliśmy już wystarczająco dużo informacji, by wyciągać pewne wnioski, np.:

- druga norma macierzy obrotu jest równa 1 (w takim przekształceniu długości wektorów się nie zmieniają),
- w przekształceniach polegających na prostym rozciąganiu (macierz diagonalna) norma pierwsza, druga i numer nieskończoność wszystkie są równe największemu elementowi macierzy itp).

Cel wprowadzenia pojęcia normy macierzy jest taki sam jak wszystkich norm – pozwala porównać ilościowo (za pomocą liczby) siłę oddziaływania, jaką dane przekształcenie może wywrzeć na zbiór wejściowych wektorów stanu opisywanego systemu (w przypadku geometrii będzie to zbiór punktów traktowanych jako wektory współrzędnych).

NORMY FUNKCJI

Poza normami wektorów i macierzy będziemy mówili także o normach funkcji. Rozumowanie dotyczące normy funkcji wywodzi się również z norm wektorów. Przypuśćmy, że mamy jakiś przedział $[a, b]$. Następnie wyobraźmy sobie, że w tym przedziale mamy skończenie wiele punktów będących realizacjami wartości tej funkcji wewnątrz przedziału. Mamy zatem wektor $\mathbf{x}$ definiujący współrzędne niezależne punktów wewnątrz przedziału $[a, b]$ oraz wektor $\mathbf{y}$ będący wartościami funkcji (lub jej przybliżenia) w punktach zdefiniowanych przez $\mathbf{x}$.

Skoro $\mathbf{y}$ jest wektorem, to możemy policzyć jego normę. Jest to podstawą definicji normy funkcji. Tzn. można potraktować funkcję jako ciąg bardzo wielu nieskończenie małych punktów tworzących wektor $\mathbf{y}$, a następnie wyliczać jego normę. W zapisie matematycznym wygląda to następująco:

$$\mathbf{y} = f(\mathbf{x}) \quad (24)$$

- Norma pierwsza³

$$\|f(x)\|_1 = \sum_{n=0}^N |f(x_n)| \Rightarrow \left[\begin{matrix} h \rightarrow 0 \\ N \rightarrow \infty \end{matrix} \right] \Rightarrow \|f(x)\|_1 = \int_a^b |f(x)| dx \quad (25)$$

- Norma druga

$$\|f(x)\|_2 = \sqrt{\sum_{n=0}^N |f(x_n)|^2} \Rightarrow \left[\begin{matrix} h \rightarrow 0 \\ N \rightarrow \infty \end{matrix} \right] \Rightarrow \|f(x)\|_2 = \sqrt{\int_a^b f^2(x) dx} \quad (26)$$

- Norma nieskończoność

$$\|f(x)\|_\infty = \sup \{ |x_n|_{n=0, 1, \dots, N} \} \Rightarrow \left[\begin{matrix} h \rightarrow 0 \\ N \rightarrow \infty \end{matrix} \right] \Rightarrow \|f(x)\|_\infty = \sup (|f(x)|)_{x \in [a, b]} \quad (27)$$

Można zadać następujące pytanie: Skoro norma wektora jest wielowymiarową odległością pomiędzy początkiem układu współrzędnych w tej przestrzeni, a punktem opisanym za pomocą wektora, norma macierzy jest maksymalnym wydłużeniem dowolnego wektora, na który macierz może mieć wpływ, to czym jest norma funkcji?

Po pierwsze zwróćmy uwagę, że normy funkcji istnieją tylko wraz z połączeniem z pewnym przedziałem $[a, b]$. Wraz ze zmianą przedziału zmienia się też norma. Norma pierwsza to pole pod wykresem modułu funkcji na przedziale $[a, b]$. Norma druga odpowiada wartości średniej (średniokwadratowej) funkcji na tym przedziale, a norma numer nieskończoność zwraca największą wartość z modułu funkcji na przedziale.

Zatem norma funkcji mówi nam „ile jest” danej funkcji w danym przedziale i, jak każda norma, pozwala porównywać funkcje pod tym względem. Dla nas szczególne znaczenie będzie miała norma błędu – pokazywać będzie, ile jest błędu w odwzorowaniu w danym przedziale.

³We wzorze tym przez h oznaczyliśmy tzw. krok, czyli odległość pomiędzy dwoma sąsiednimi punktami

TWIERDZENIE TAYLORA I SZEREG TAYLORA


Ostatnim, kluczowym dla analizy numerycznej, twierdzeniem matematycznym jest twierdzenie Taylora. Twierdzenie Taylora dotyczy tzw. funkcji gładkich. W ujęciu matematycznym oznacza to, że taka funkcja ma nieskończenie wiele ciągłych pochodnych. Twierdzenie Taylora stosuje się też czasem do funkcji regularnych tzn. takich których tylko kilka pierwszych pochodnych jest ciągłych.

Idea twierdzenia Taylora jest następująca. Można wnioskować o właściwościach i zachowaniu oryginalnej funkcji $f(x)$ nie znając jej, ale znając jeden punkt z realizacji tej funkcji (dla ustalenia uwagi niech będzie to punkt $(a, f(a))$) i wartości pochodnej tej funkcji w tym punkcie. Można określić wszystkie właściwości funkcji jeżeli znalibyśmy wszystkie (nieskończoną ilość) pochodnych tej funkcji w danym punkcie. Ale nawet jeżeli nie znamy wszystkich pochodnych, ale tylko pewną ich część to jesteśmy w stanie odtworzyć $f(x)$ w miarę dokładnie **w pewnym otoczeniu** punktu a .

Matematycznie twierdzenie to opisane jest następującym równaniem⁴:

$$f(x) \equiv f(a) + f^{(1)}(a)(x-a) + \frac{1}{2}f^{(2)}(a)(x-a)^2 + \frac{1}{6}f^{(3)}(a)(x-a)^3 + \dots \quad (28)$$

Poniżej pokazano odwzorowanie kształtu i właściwości funkcji wynikających ze wzoru Taylora dla punktu $a=0$ i (w typowym przypadku nieznanej) funkcji, która na potrzeby tego przykładu jest po prostu funkcją $y=e^x$. Zwróć uwagę jak obszar dobrego odwzorowania właściwości funkcji powiększa się wraz z liczbą uwzględnionych składników⁵:



Szczególnie warte podkreślenia są dwie praktyczne dla metod numerycznych implikacje twierdzenia Taylora:

- Nawet w przypadku uwzględnienia małej liczby (np. jednego) wyrazów szeregu istnieje taki obszar, choć zazwyczaj jest on stosunkowo niewielki, że opis ten jest dostatecznie dokładny, dobrze oddaje rzeczywistość i wnioski z niego płynące są prawdziwe,

⁴Alternatywny zapis:

$$T_N(x) = \sum_{n=0}^N \frac{f^{(n)}(a)}{n!} (x-a)^n \quad \lim_{N \rightarrow \infty} f(x) - T_N(x) = 0$$

⁵Rysunek zaczerpnięto z <https://mathspace.pl/matematyka/genialny-wzor-taylora-czyli-o-informacji-zakodowanej-w-pochodnych/>

- To w jak dużym obszarze dane przybliżenie działa zależy nie tylko od liczby uwzględnionych wyrazów, ale również od oryginalnej funkcji (np. funkcje wielomianowe stopnia W zostaną przybliżone dokładnie za pomocą sumy Taylora po uwzględnieniu $W+1$ jej czynników, ponieważ wyższe pochodne wielomianu są zawsze zerowe). Z kolei jeżeli oryginalna (nieznana) funkcja była taka, że wartość pochodnych wysokiego rzędu jest duża, to uwzględnienie tylko pierwszych kilku wyrazów daje wynik bardzo niedokładny i oparte o taką analizę wnioski są nieprawdziwe. To bardzo duży problem w metodach numerycznych bowiem twierdzenie Taylora jest podstawą konstrukcji metod i analizy służącej wyprowadzaniu wniosków natury ogólnej. Mogą się jednak trafić takie zestawy danych (funkcje $f(x)$), że wyniki metod numerycznych nie dadzą wiarygodnego. Metoda numeryczna zawsze zwraca jakiś wynik, ale nie zawsze ma on sens!

Twierdzenie Taylora jest podstawą konstrukcji metod oraz analizy ogólnych właściwości danych problemów numerycznych, z której wynikają podstawowe reguły ich rozwiązania. Jednym z zastosowań, ale szczególnie dla naszej analizy krytycznym, jest zastosowanie do analizy zachowania się błędu w rozwiązaniu problemu numerycznego.

BŁĄD W OBLICZENIACH NUMERYCZNYCH, RODZAJE I PRZYCZYNY

BŁĄD REPREZENTACJI LICZB

Błąd reprezentacji liczby jest związany ze skończonymi zasobami pamięci maszyny numerycznej. Liczby w pamięci muszą być reprezentowane przez skończony ciąg symboli (w komputerze zer i jedynek). Liczby zapisuje się zatem wg ustalonego formatu zapisu. Uniwersalnością (w sensie zakresu liczb, które można wyrazić z określoną precyzją) pożądaną w obliczeniach inżynierskich cechuje się zmiennopozycyjny system zapisu liczb. Najprostszym przykładem zapisu zmiennopozycyjnego jest zapis inżynierski np.: $5,43e21$ lub równoważnie $5,43 \cdot 10^{21}$. Polega on na tym, że liczbę wyraża się w postaci iloczynu całkowitej potęgi liczby 10 oraz liczby z przedziału $[1, 10)$ (liczbę tę nazywać będziemy mantysą). Oczywiście zapis zmiennopozycyjny obowiązywać może w systemach liczbowych o różnych podstawach. Liczba x w zapisie zmiennopozycyjnym w systemie liczbowym o podstawie p wyraża się w postaci iloczynu $x = mp^c$, gdzie c jest pewną liczbą całkowitą (nazywamy ją wykładnikiem lub cechą), oraz $m \in [1, p)$, liczbę m nazywamy mantysą.

W takim zapisie o dokładności (maksymalnym błędzie względnym, który może się pojawić w związku z zapisaniem liczby) decydować będzie liczba cyfr użytych do zapisu mantysy. Dlatego czasami mówimy o dokładności n cyfr znaczących (liczba n odpowiada właśnie liczbie cyfr użytych do zapisania mantysy). Błąd liczby spowodowany zapisaniem jej w postaci mantysy o określonej liczbie cyfr będzie mniejszy, niż:

$$eps = \frac{1}{2}p^{1-n} \quad (29)$$

gdzie n jest liczbą cyfr użytych do zapisu mantysy.

Poniżej w tabeli podano kilka przykładów (same mantysy, bowiem przy obliczaniu błędu względnego czynnik p^n się zredukuje – będzie taki sam w wartości dokładnej i przybliżonej):

p=10, n=2				p=10, n=3				p=2, n=4			
x	$\tilde{x}$	δx	eps	x	$\tilde{x}$	δx	eps	$[x]_2$	$[\tilde{x}]_2$	$[\delta x]_{10}$	$[eps]_{10}$
1,0037	1,0	~0,37%	5%	1,0037	1,00	~0,37%	0,5%	1,0001	1,001	~5,9%	6,25%
1,04(9)	1,0	4,(9)%	5%	1,04(9)	1,05	~0%	0,5%	1,0111	1,100	~4,2%	6,25%
1,05	1,1	~4,8%	5%	1,05	1,05	0%	0,5%	1,011	1,011	0	6,25%
2,55	2,6	~2,0%	5%	1,004(9)	1,00	0,4(9)%	0,5%	1,01001	1,010	~2,4%	6,25%
6,9	6,9	0%	5%	2,673	2,67	~0,11%	0,5%	1,11011	1,111	~5,4%	6,25%
7,68	7,7	~0,26%	5%	9,295	9,30	~0,053%	0,5%	1,1001	1,101	2,5%	6,25%

Warto podkreślić, że błąd liczby rzeczywistej reprezentowanej w maszynie numerycznej zawsze należy do przedziału $[0, eps)$ – w szczególności może być równy zero. Znaczeniem eps (czasem zamiennie ε) jest górne oszacowanie błędu dla danego formatu zapisu liczby (wzór podano wyżej). Czasami można spotkać się z definicją:

$$eps = p^{1-n} \quad (30)$$

w takim przypadku znaczeniem eps (czasem zamiennie ϵ) jest minimalny kwant, o który może zostać powiększona liczba 1 w maszynie numerycznej. Stąd wywodzi się zwyczajowa nazwa eps – epsilon maszynowy. Dla szeroko stosowanego formatu podwójnej precyzji „double” (53 bity mantysy) $eps \cong 2.22 \cdot 10^{-16}$, z kolei dla tradycyjnego „float” (24 bity mantysy) $eps \cong 1.19 \cdot 10^{-7}$. Ma to ważne implikacje dla obliczeń prowadzonych komputerowo: bowiem maksymalna dokładność, którą jesteśmy w stanie osiągnąć jest na poziomie porównywalnym z eps (w praktyce błąd jest na ogół kilka rzędów wielkości większy od eps ze względu na zjawisko propagacji błędów, o którym będzie zaraz).

PROPAGACJA BŁĘDU

W ogólności jeżeli do obliczeń przyjmujemy wartości obarczone pewnym błędem, wynik również będzie obciążony błędem (nie licząc szczególnych przypadków takich jak np. $0=x-x$). Modelem matematycznym wykonywania obliczeń jest funkcja. Rozważmy zatem jak błąd argumentu wpływa na błąd wartości funkcji:

Niech $y = f(x)$, zatem wartość przybliżona $y + \Delta y = f(x + \Delta x)$, jaki jest błąd wartości przybliżonej: $\Delta y = ?$

Wpływ błędu argumentu na błąd wartości funkcji jest proporcjonalny do tego, jak silnie funkcja zależy od danego argumentu, co można przybliżyć:

$$\Delta y = \Delta x \frac{dy}{dx} \quad (31)$$

Z tego wyniku (powyższe równanie dzielimy stronami przez y , a błąd bezwzględny x wyrażamy jako iloczyn błędu względnego i x) zapis w notacji błędów względnych:

$$\delta y = \frac{x}{y} \delta x \frac{dy}{dx} \quad (32)$$

W przypadku funkcji wielu zmiennych:

$$\delta[y(x_1, x_2, \dots, x_M)] = \sum_{i=1}^M \frac{x_i}{y} \delta x_i \frac{\partial y}{\partial x_i} \quad (33)$$

Możemy zdefiniować współczynnik transmisji błędu jako stosunek błędu wyniku do błędu wejściowego:

$$T_i = \frac{\delta y}{\delta x_i} = \frac{x_i}{y} \frac{\partial y}{\partial x_i} \quad (34)$$

Jest to wygodny zapis, bowiem obrazuje jak mocno wzmacni się błąd wejściowy w danym działaniu.

Warto zwrócić uwagę, że:

1. Obliczane w ten sposób wartości to oszacowanie dokładności wyniku (oszacowanie błędu od góry), w praktyce może się zdarzyć, że do obliczeń przyjęto dane obarczone niezerowym błędem, a wynik otrzymano bezbłędny (np. $x - x = \tilde{x} - \tilde{x}$),
2. Niedokładność wyniku zależy nie tylko od tego, jaka jest niedokładność danych wejściowych, ale też od tego, jakie obliczenia trzeba wykonać, oraz od samych danych.
3. Współczynnik transmisji danych w zależności od działania (funkcji) może być niezależny od danych wejściowych (będzie tak np. w przypadku działań wielomianowych), ale może też od nich zależeć (np. transmisja błędu funkcji e^x jest równy x , zatem w przypadku większych danych błąd (względny!) się będzie wzmacniał bardziej).
4. Powyższa analiza opierała się na założeniu, że błędy są małe – w praktyce można ją stosować dla niedokładności do kilku ew. kilkunastu procent.

BŁĄD METODY NUMERYCZNEJ/BŁĄD ODCIĘCIA

Metody numeryczne polegają na tym, żeby rzeczywisty problem (którego rozwiązanie analityczne jest niemożliwe lub zbyt czasochłonne) wyrazić w postaci problemu numerycznego, który daje się rozwiązać za pomocą skończonej liczby operacji. Często wiąże się to z wprowadzaniem dodatkowych błędów, np. kiedy szereg lub całkę przybliżamy sumą skończoną, – stąd wywodzi się nazwa błędu odcięcia, bowiem „odcinamy” nieskończoną liczbę elementów o małym, ale niezerowym wpływie na wynik.


W szczególności rozwój metod numerycznych polega przede wszystkim na tym, żeby minimalizować błąd metody/obciążenia, a konkretnie minimalizować go nie kosztem nakładów obliczeniowych, ale właśnie kosztem modyfikacji metody. Szczegółowa wiedza na temat błędów metody będzie wprowadzana w trakcie semestru.

Warto podkreślić, że w niektórych sytuacjach (dalsze) minimalizowanie błędu metody może być niepotrzebne (gdy błąd ten jest porównywalny/mniejszy od innych błędów, np. od epsilon maszynowego) lub nawet niewskazane (gdy minimalizacja błędu obciążenia jest związana ze zwiększeniem liczby operacji, prowadzącej do nadmiernego wzrostu błędów innych rodzajów) – to dlatego dobór odpowiedniej metody numerycznej do problemu jest ważny!

BŁĄD ZAOKRĄGLEŃ

Nawet jeśli dane, które maszyna numeryczna przyjmuje do obliczeń są dokładne, fizyczna realizacja układu liczącego (np. procesora) może wymuszać pewne zaokrąglenia w trakcie obliczeń. Szczegółowa analiza tych zagadnień wykracza poza zakres przedmiotu WNUM. Nie możemy jednak pominąć wpływu tego rodzaju błędów. Dlatego przyjmować będziemy, że dana maszyna numeryczna wprowadza błąd charakterystyczny dla poszczególnych operacji elementarnych, które można na niej wykonać. W naszych rozważaniach zazwyczaj błąd ten będziemy oznaczać grecką literą eta: η .

LINIOWY MODEL PROPAGACJI BŁĘDU I „RACHUNEK EPSILONÓW”



Podsumowując powyższe akapity, prześledźmy drogę, od danych wejściowych do wyniku. Dane wejściowe mogą być obciążone błędem oszacowanym przez epsilon maszynowy. Gdy jest wykonywane jakieś obliczenie, błąd ten transmituje zgodnie z teorią transmisji błędów oraz dodatkowo wprowadzany jest błąd zaokrąglenia wynikający z fizycznej realizacji procesora, można to przedstawić na następującym schemacie:

Oczywiście w przypadku obliczeń złożonych z wielu operacji elementarnych schemat ten powtórzy się, przy czym błąd wejściowy n -tej operacji będzie błędem końcowym $n-1$ -szej operacji.

Powyższe zależności można przedstawić także w formie rachunkowej odwołując się do pojęć zdefiniowanych powyżej:

$$\delta y = T \bullet \delta x + \eta \quad (35)$$

Przykładowo dla serii 4 operacji:

$$\delta y = T_4(T_3(T_2(T_1\delta x + \eta_1) + \eta_2) + \eta_3) + \eta_4 \quad (36)$$

Sprawdźmy to na przykładzie obliczenia wyrażenia $y = \exp(x^2 + 1)$, na maszynie numerycznej, która dysponuje następującymi operacjami elementarnymi: (zapis wg zmiennej ξ , w celu uniknięcia dwuznaczności z zapisem wyrażenia): 1) $f(\xi) = \xi^2$, która wprowadza błąd zaokrąglenia η_{ξ^2} , 2) $f(\xi) = \xi + 1$, która wprowadza błąd zaokrąglenia $\eta_{\xi+1}$, oraz 3) $f(\xi) = \exp(\xi)$, która wprowadza błąd zaokrąglenia $\eta_{\exp(\xi)}$.

$$\delta y = T_{\exp(\xi)}(T_{\xi+1}(T_{\xi^2}\delta x + \eta_{\xi^2}) + \eta_{\xi+1}) + \eta_{\exp(\xi)} \quad (37)$$

Współczynnik transmisji błędu dla podnoszenia do kwadratu nie zależy od danych wejściowych i jest równy 2, współczynnik transmisji błędu dla dodawania stałej a jest zależny od danych wejściowych i wynosi $\frac{\xi}{\xi+a}$, natomiast współczynnik transmisji błędu dla funkcji $\exp(\xi)$ jest zależny od danych wejściowych i jest równy ξ . W naszym przypadku argumentem funkcji $\exp()$ jest $x^2 + 1$, zatem błąd δy po przekształceniu wyrazi się bezpośrednio:

$$\delta y = (x^2 + 1) \left[\frac{x^2}{x^2 + 1} (2\delta x + \eta_{\xi^2}) + \eta_{\xi+1} \right] + \eta_{exp(\xi)} = x^2(2\delta x + \eta_{\xi^2} + \eta_{\xi+1}) + \eta_{\xi+1} + \eta_{exp(\xi)} \quad (38)$$

Warto zwrócić uwagę, na ważną implikację praktyczną tych obliczeń, mianowicie okazało się, że **błąd wyniku może zależeć nie tylko od poziomu zaburzenia danych wejściowych, ale też w niektórych zagadnieniach od poziomu danych wejściowych**. Przy tym trzeba podkreślić, że analiza błędów prowadzona jest dla konkretnej algorytmicznej implementacji metody numerycznej. Szczególnie istotne jest to, że ta sama metoda może być zaimplementowana w różny sposób, co będzie przekładało się na różne transmisje błędów. Szczególnie pożądane są algorytmy, które są nieczułe na poziom danych wejściowych, bowiem charakteryzują się większą uniwersalnością – na tę potrzebę odpowiada zagadnienie optymalizacji algorytmów. Nie będziemy szczegółowo omawiać tego zagadnienia w ramach przedmiotu, ale będziemy odwoływać się do świadomości problemu.

W niektórych przypadkach do podobnych wniosków można dojść przeprowadzając tzw. rachunek epsilon – są to równoważne obliczenia polegające na wyrażeniu wartości przybliżonej w postaci $\tilde{x} = x(1 + \delta x)$. Dla rozważanego powyżej obliczenia:

$$\tilde{y} = exp \left(\left[\{x(1 + \varepsilon)\}^2 (1 + \eta_{pot}) + 1 \right] (1 + \eta_{dod}) \right) (1 + \eta_{exp}) \quad (39)$$

Po wymnożeniu tych czynników, które są argumentem funkcji exp , otrzymalibyśmy niezbyt czytelną wieloczynnikową sumę. Korzystając jednak z obserwacji, że można pominąć wszystkie czynniki, w których mnożone są co najmniej dwa elementy rzędu błędów (np. jeśli $\varepsilon = 2.2 e - 16$, to po podniesieniu do kwadratu $\varepsilon^2 = 4.6 e - 32$, czyli jest pomijalnie mały), wyrażenie się upraszcza do postaci:

$$\tilde{y} = exp \left(x^2 + 1 + x^2(2\varepsilon + \eta_{pot} + \eta_{dod}) + \eta_{dod} \right) (1 + \eta_{exp}) \quad (40)$$

Następnie można wyrazić argument funkcji exp w postaci iloczynu:

$$(x^2 + 1) \left(1 + \frac{x^2(2\varepsilon + \eta_{pot} + \eta_{dod}) + \eta_{dod}}{(x^2 + 1)} \right) \quad (41)$$

co jest równoznaczne z tym, że traktujemy to jak funkcję $exp(x^2 + 1)$, w której argument obarczony jest błędem względnym $\frac{x^2(2\varepsilon + \eta_{pot} + \eta_{dod}) + \eta_{dod}}{(x^2 + 1)}$. Ponieważ współczynnik transmisji błędów w tym wypadku wynosi $x^2 + 1$, zatem błąd obliczonego wyrażenia jest równy $x^2(2\varepsilon + \eta_{pot} + \eta_{dod}) + \eta_{dod}$. Ostatecznie dochodzimy do tego samego wniosku co poprzednio:

$$x^2(2\delta x + \eta_{pot} + \eta_{dod}) + \eta_{dod} + \eta_{exp} \quad (42)$$

Analizę jednej z powyższych metod można również przeprowadzić, żeby oszacować jak w danym algorytmie błąd wyjściowy zależy od poszczególnych błędów zaokrągleń (co można wziąć pod uwagę przy projektowaniu procesorów specyfikowanych do konkretnych obliczeń – np. procesorów sygnałowych).

UWARUNKOWANIE NUMERYCZNE

W powyższych akapitach wskazaliśmy, że poprzez optymalizację algorytmu można zminimalizować błędy wyników (a w szczególności wpływ poziomu danych wejściowych na transmisję błędów). W niektórych problemach, niezależnie od optymalizacji algorytmu wpływ danych wejściowych na dokładność (szybkość uzyskania) wyniku jest tak duża, że nie da się ich rozwiązać w zadowalający sposób. O takich zadaniach będziemy mówili, że są źle uwarunkowane numerycznie. Wpływ niedokładności danych wejściowych na niedokładność rozwiązania problemu niezależny od algorytmu, a jedynie od problemu nazywamy wskaźnikiem uwarunkowania. Zagadnienie to zostanie omówione szerzej już przy okazji rozwiązywania układów równań liniowych.

ZŁOŻONOŚĆ OBLICZENIOWA, KLASY ZŁOŻONOŚCI OBLICZENIOWEJ

Aby rozwiązać dany problem numeryczny trzeba ponieść koszty (nakłady obliczeniowe) zarówno w sensie wykonanych operacji, jak i w sensie zużytej pamięci. Ilościową miarą tych nakładów jest złożoność obliczeniowa. Czasami pojęcie złożoności obliczeniowej odnosi się do teoretycznego oszacowania koniecznych nakładów. Ponieważ rzeczywiste nakłady zależeć będą od danych wejściowych oszacować złożoność można w przypadku optymistycznym, pesymistycznym oraz oczekiwaną (po przyjęciu odpowiednich założeń statystycznych).

W ramach WNUM zajmować się będziemy jedynie oszacowaniem złożoności z góry, czyli złożonością pesymistyczną.

Dla porównania złożoności obliczeniowej algorytmów istotne jest asymptotyczne tempo wzrostu, czyli to jak zachowuje się złożoność w funkcji rozmiaru problemu dla odpowiednio dużych rozmiarów danych wejściowych. Będziemy definiować pojęcie klasy złożoności obliczeniowej jako klasy funkcji, którymi da się oszacować od góry wzrost nakładów obliczeniowych związany ze wzrostem rozmiaru problemu. Klasy złożoności oznaczать będziemy: $O(g(n))$. Ściśle rzecz biorąc złożoność $f(n)$ jest rzędu co najwyżej $g(n)$ (lub od góry oszacowana przez $g(n)$), gdy istnieje pewien współczynnik c , taki że dla wystarczająco dużych n : $f(n) < c g(n)$.

$$f(n) = O(g(n)) \leftrightarrow \bigvee_{c>0 \text{ oraz } n_0 \in \mathbb{N}} \bigwedge_{n \geq n_0} 0 \leq f(n) \leq c g(n) \quad (43)$$

Np. dla odpowiednio dużego rozmiaru problemu wzrost nakładów obliczeniowych algorytmu o złożoności klasy co najwyżej $O(n^2)$, będzie kwadratowo zależny od rozmiaru problemu (i drugorzędne znaczenie ma to, czy będzie to wzrost rzędu $2n^2$, czy $3n^2$, bowiem dla odpowiedniego dużego problemu nawet przy bardzo dużym c prawdziwe jest $cn^2 \leq n^3$).

Wyróżnić należy najważniejsze klasy złożoności: logarytmiczną, liniową, liniowo-logarytmiczną, kwadratową, sześcienną (to są klasy złożoności co najwyżej wielomianowej) oraz wykładniczą i silniową (te ostatnie nie nadają się do praktycznych implementacji, ponieważ wraz ze wzrostem problemu bardzo szybko osiągają złożoności przekraczające możliwości dostępnego sprzętu).

Choć w ogólności analiza złożoności pamięciowej i obliczeniowej wygląda podobnie, w ramach WNUM skupiać się będziemy na tej drugiej, bowiem pierwsza w większości współczesnych układów nie stanowi zagadnienia kluczowego.

METODY ITERACYJNE I ICH WŁAŚCIWOŚCI

Większość praktycznych problemów numerycznych sprowadza się do tego, aby znaleźć pewne rozwiązanie z zadaną dokładnością. W niektórych zagadnieniach możliwe jest stworzenie metody, która przyjmując pewną wartość bliską wartości szukanej, w wyniku obliczeń zwraca wartość jeszcze bliższą wartości szukanej. Przeprowadzenie powtórnie tych obliczeń (z przyjęciem otrzymanego wcześniej wyniku jako danej wejściowej) sprawia, że otrzymujemy liczbę jeszcze bliższą rozwiązania. Powtarzając taką operację wielokrotnie możemy dowolnie zwiększać dokładność metody (oczywiście bezcelowe jest zwiększanie dokładności metody powyżej poziomu innych błędów, którymi obciążone są obliczenia). Algorytmy cechujące się takimi właściwościami nazywamy algorytmami iteracyjnymi.

Inaczej mówiąc algorytmy iteracyjne są to algorytmy, które wymieniają złożoność czasową na dokładność rozwiązania. Z tego względu w przypadku algorytmów iteracyjnych nie ma sensu pojęcie złożoności obliczeniowej. Zamiast tego stosuje się pojęcie klasy zbieżności lokalnej. Służy ono określeniu jak szybko dokładność rozwiązania się zmienia, kiedy zwiększamy liczbę iteracji (zwiększamy nakłady obliczeniowe). Analiza klasy zbieżności przebiega analogicznie do analizy klasy złożoności obliczeniowej.

Idea metod iteracyjnych polega na tym, że z każdą iteracją zwiększamy dokładność rozwiązania. Wiąże się to z tym, że metody te muszą przyjąć pewien punkt startowy. Dodatkowo zazwyczaj wymagają, aby punkt startowy znajdował się dostatecznie blisko rozwiązania. W przeciwnym wypadku może się zdarzyć, że każda następna iteracja będzie nas oddalała od rozwiązania, zamiast do niego przybliżać. Odporność metody na wybór punktu początkowego jest szerokim zagadnieniem, które będziemy omawiać w ciągu semestru.