

# UKŁADY RÓWNAŃ LINIOWYCH

## POSTAĆ KANONICZNA UKŁADU RÓWNAŃ LINIOWYCH, DEFINICJA PROBLEMU

### POSTAĆ KANONICZNA

Pierwszym problemem numerycznym z jakim będziemy mieli do czynienia jest problem rozwiązywania układów równań liniowych. Problem może wydawać się trywialny, ale tylko w arytmetyce o nieskończonej dokładności. Okazuje się, że w przypadku rozwiązywania równań liniowych numerycznie natrafiamy na poważne trudności.

Zanim powiemy sobie, na czym polegają, musimy opisać ogólnie przyjętą notację, w jakiej opisujemy układ równań. Mianowicie zamiast pisać poszczególne równania tak jak to robiliśmy w szkole np.

$$\begin{cases} 2x_1 + 5x_2 - 6x_3 = 7 \\ 4x_1 + 2x_2 + 10x_3 = 2 \\ 8x_1 - 9x_2 - 3x_3 = 4 \end{cases} \quad (1)$$

Zapisujemy go w tzw. **postaci kanonicznej**. Jest to ustandaryzowany sposób zapisu problemu numerycznego, w tym przypadku problemu rozwiązywania układów równań liniowych, do którego przystosowane są wszystkie metody rozwiązywania tego problemu. W naszym przypadku postać kanoniczna wygląda następująco:

$$\mathbf{A} \cdot \mathbf{x} = \mathbf{b} \quad (2)$$

Gdzie wszystkie pogrubione litery oznaczają wektory lub macierze. I tak w naszym przykładzie postać kanoniczna wygląda następująco:

$$\mathbf{A} = \begin{bmatrix} 2 & 5 & -6 \\ 4 & 2 & 10 \\ 8 & -9 & -3 \end{bmatrix} \quad (3)$$

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} \quad (4)$$

$$\mathbf{b} = \begin{bmatrix} 7 \\ 2 \\ 4 \end{bmatrix} \quad (5)$$

$$\mathbf{A} \cdot \mathbf{x} = \begin{bmatrix} 2 & 5 & -6 \\ 4 & 2 & 10 \\ 8 & -9 & -3 \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 7 \\ 2 \\ 4 \end{bmatrix} = \mathbf{b} \quad (6)$$

Możesz szybko sprawdzić, że taki zapis odpowiada naszemu oryginalnemu opisowi.

### DLACZEGO JEST TO POSTAĆ KANONICZNA

Może zastanawiać, dlaczego wybrano akurat taką formę zapisu. Powodów jest kilka i mają związek z tym, gdzie głównie mamy do czynienia z układami równań liniowych (o czym w kolejnym podrozdziale), a także z rolą, jaką w tym zapisie pełnią poszczególne jego składniki.

Kluczem do zrozumienia, dlaczego zapis  $\mathbf{A} \cdot \mathbf{x} = \mathbf{b}$  jest właśnie **postacią kanoniczną** – czyli ustandaryzowanym, uniwersalnym zapisem problemu, a nie tylko skróconym sposobem zapisania konkretnego układu równań – jest interpretacja tego, co reprezentuje każdy z jego elementów:

- wektor  $\mathbf{x}$  to **stan opisywanego układu (systemu)** – zbiór liczb (parametrów), które w pełni go opisują w danej chwili czy konfiguracji (np. wychylenia węzłów konstrukcji, potencjały w węzłach obwodu elektrycznego, wartości niewiadomych poszukiwanych przez inną, nadrzędną metodę numeryczną),

- macierz **A** to **matematyczny opis przekształcenia lub oddziaływania**, jakie działa na ten stan – sposobu, w jaki poszczególne elementy stanu wpływają na siebie nawzajem (sprężenia, zależności, oddziaływania fizyczne opisane przez dany model),
- wektor **b** to wynik zadziałania tego przekształcenia na stan **x** – obserwowalny efekt (np. wymuszenie zewnętrzne, prawa strona układu).

Rozdzielenie *tego, co jest stanem* od *tego, jak ten stan jest przekształcany* sprawia, że dowolny układ równań liniowych – niezależnie od tego, skąd pochodzi i co fizycznie opisuje – sprowadza się do dokładnie tej samej, jednej operacji algebraicznej. To właśnie umożliwia budowę uniwersalnych metod numerycznych: metoda rozwiązująca układ równań liniowych nie musi „wiedzieć” nic o jego pochodzeniu, wystarczy że dostanie go w postaci macierzy **A** i wektora **b**.

Ten podział ma też praktyczne znaczenie numeryczne: danymi wejściowymi do problemu rozwiązania układu równań liniowych są dane liczbowe zawarte w układzie równań, a więc w naszej notacji są to macierz **A** i wektor **b**. Okazuje się, że niektóre z tych danych mają większy wpływ na rozwiązanie (niedokładności wektora **b**) niż inne (niedokładności macierzy **A**) – co również jest tak naprawdę jedną z przyczyn przyjęcia takiej, a nie innej notacji, rozdzielającej opis przekształcenia od jego efektu.

### GDZIE NAJCZĘŚCIEJ SPOTYKAMY RÓWNIANIA LINIOWE

Warto od razu zaznaczyć, że układów równań liniowych rzadko rozwiązujemy jako samodzielny, izolowany problem – w praktyce inżynierskiej i naukowej najczęściej stanowią one istotny, wewnętrzny element bardziej złożonych metod numerycznych. Znajomość właściwości i problemów metod ich rozwiązywania jest jednak niezbędna, żeby zrozumieć działanie, implementację i właściwości tych bardziej zaawansowanych, praktycznych metod, które się na nich opierają. Poniżej kilka typowych sytuacji, w których napotykamy ten problem.

Ogólnie tego typu problem rzadko występuje sam z siebie. Większość fizyki opisana jest równaniami różniczkowymi, albo co najmniej nieliniowymi. Ale często stosuje się coś co nazywamy linearyzacją problemów nieliniowych. Technika ta jest często stosowana w metodach numerycznych i opiera się na obserwacji, że dla każdego układu równań nieliniowych i danego punktu przestrzeni rozwiązania istnieje, ogólnie nieznany, ale niezerowy obszar bliskiego otoczenia tego układu w okolicy analizowanego punktu, w którym obciążenie rozwinięcia w szereg Taylora do pierwszego, liniowego elementu jest dostatecznie dokładne i układ równań nieliniowych zamienia się w układ równań liniowych. To podejście rzadko implementuje się bezpośrednio – mamy bowiem metody numeryczne dotyczące rozwiązywania układów równań nieliniowych. Ale bardzo często to podejście jest „wbudowane” w inne metody numeryczne rozwiązujące bardziej skomplikowane, ale znacznie bardziej rozpowszechnione problemy (równania różniczkowe cząstkowe – symulatory FEM i podobne).

**Przykład:** Rozważmy prosty układ mechaniczny – dwie masy zawieszone szeregowo na dwóch nieliniowych sprężynach (np. usztywniających się przy większym rozciągnięciu) zamocowanych do sztywnej ściany. Siłę takiej sprężyny opisuje nieliniowa zależność od jej wydłużenia  $\Delta$ :

$$F(\Delta) = k_1\Delta + k_3\Delta^3 \quad (7)$$

Niech  $x_1, x_2$  oznaczają położenia mas – wydłużenie pierwszej sprężyny wynosi wtedy  $x_1$ , a drugiej  $x_2 - x_1$ . Załóżmy, że znamy już stan pracy układu (np. z poprzedniego etapu obliczeń) – masy spoczywają w położeniach  $x_1^0 = 1, x_2^0 = 3$  (wydłużenia sprężyn wynoszą więc odpowiednio 1 i 2). Interesuje nas, jak układ zareaguje na niewielkie dodatkowe obciążenia  $\Delta F_1, \Delta F_2$  przyłożone do obu mas, czyli jakie przemieszczenia  $\Delta x_1, \Delta x_2$  one wywołają w otoczeniu tego stanu pracy.

Zamiast rozwiązywać od nowa pełny, nieliniowy problem, linearyzujemy siłę każdej sprężyny wokół jej bieżącego wydłużenia  $\Delta^0$ , biorąc pierwszy wyraz rozwinięcia w szereg Taylora:

$$F(\Delta^0 + \delta) \approx F(\Delta^0) + k_s \delta, \quad k_s = \left. \frac{dF}{d\Delta} \right|_{\Delta^0} = k_1 + 3k_3(\Delta^0)^2 \quad (8)$$

Tak wyznaczone  $k_s$  nazywamy **sztywnością styczną** sprężyny w danym punkcie pracy – lokalnym, liniowym odpowiednikiem jej nieliniowej charakterystyki, ważnym tylko w niewielkim otoczeniu tego konkretnego stanu (w odróżnieniu od zwykłej sprężyny liniowej, tutaj sztywność zależy od tego, jak bardzo sprężyna jest już rozciągnięta). Przyjmijmy  $k_1 = 1, k_3 = 0,1$  – sztywności styczne obu sprężyn w rozważanym punkcie pracy wynoszą:


$$k_A = k_1 + 3k_3(1)^2 = 1,3, \quad k_B = k_1 + 3k_3(2)^2 = 2,2 \quad (9)$$

Zlinearyzowany bilans sił na obu masach (analogiczny do bilansu dla zwykłej, liniowej sprężyny, ale z lokalnymi sztywnościami stycznymi zamiast stałych  $k$ ) daje układ równań liniowych na przemieszczenia  $\Delta x_1, \Delta x_2$ :

$$\begin{bmatrix} k_A + k_B & -k_B \\ -k_B & k_B \end{bmatrix} \cdot \begin{bmatrix} \Delta x_1 \\ \Delta x_2 \end{bmatrix} = \begin{bmatrix} \Delta F_1 \\ \Delta F_2 \end{bmatrix} \quad (10)$$

czyli, po podstawieniu liczb:

$$\begin{bmatrix} 3,5 & -2,2 \\ -2,2 & 2,2 \end{bmatrix} \cdot \begin{bmatrix} \Delta x_1 \\ \Delta x_2 \end{bmatrix} = \begin{bmatrix} \Delta F_1 \\ \Delta F_2 \end{bmatrix} \quad (11)$$



Widać tu dokładnie mechanizm opisany wyżej: sama sprężyna ma charakterystykę nieliniową, ale w otoczeniu konkretnego stanu pracy jej zachowanie można opisać liniowo – a to, jak cały układ (złożony z wielu takich elementów) zareaguje na niewielkie zaburzenie, sprowadza się właśnie do rozwiązania układu równań liniowych. Macierz  $\mathbf{A}$  (tzw. **macierz sztywności stycznej**) opisuje tu lokalne oddziaływanie między masami, wektor  $\mathbf{x} = [\Delta x_1 \ \Delta x_2]^T$  to niewielka zmiana stanu układu, a  $\mathbf{b} = [\Delta F_1 \ \Delta F_2]^T$  to dodatkowe wymuszenie. Dokładnie taka procedura – linearyzacja modelu wokół znanego stanu pracy i rozwiązanie powstałego układu równań liniowych – jest podstawą wielu praktycznych metod numerycznych w mechanice i innych działach inżynierii (np. w analizie MES przy niewielkich obciążeniach dodatkowych nakładanych na już odkształconą konstrukcję).

Istnieje również część zagadnień w technice, w których modele matematyczne są też celowo tak budowane, żeby miały postać liniową. Implementacja takich metod na maszynach numerycznych (komputerach) również prowadzi do problemu rozwiązywania układu równań liniowych, zazwyczaj średniej wielkości. W ramach wykładu poznamy wiele sytuacji, kiedy dochodzimy do konieczności rozwiązania układu równań liniowych jako części rozwiązania bardziej skomplikowanego problemu numerycznego.

Wreszcie na sam koniec wypada wspomnieć, że z powyższych względów rzadko rozwiązujemy układy równań liniowych mających tylko kilka równań – choć wszystkie przykłady, jakie będziemy przerabiać, będą bardzo prostymi układami równań tego typu. W praktyce najczęściej układy równań liniowych są automatycznie budowane i mogą mieć od kilkudziesięciu do kilku-kilkunastu tysięcy równań, a czasami więcej w specjalistycznym oprogramowaniu. Ponieważ **liczba równań jest wielkością problemu numerycznego** w przypadku problemu rozwiązywania układów liniowych kluczowe znaczenie ma jak zmieniają się parametry rozwiązania wraz ze wzrostem liczby równań. Różne metody mają różne właściwości stąd istnieje wiele ich rodzajów.

## PROBLEMY Z NAIWNYM ROZWIĄZYWANIEM UKŁADU RÓWNAŃ LINIOWYCH

Jakie są więc problemy związane z rozwiązaniem prostego, wydawałoby się, układu równań liniowych? Moglibyśmy to zrobić tak jak w szkole z pojedynczym równaniem, co pokazano poniżej:


| Równanie skalarne | Układ równań |                      |      |
|-------------------|--------------|----------------------|------|
| $ax = b$          | (12)         | $Ax = b$             | (14) |
| $x = a^{-1}b$     | (13)         | $A^{-1}Ax = A^{-1}b$ | (15) |
|                   |              | $A^{-1}A = I$        | (16) |
|                   |              | $x = A^{-1}b$        | (17) |

Ale najczęściej stosujemy znacznie bardziej skomplikowane metody, które opierają się na tej idei, z kilku powodów:

- Po pierwsze zazwyczaj mamy do czynienia z dużymi układami równań. Okazuje się, że bezpośrednie odwrócenie macierzy (np. metodą wyznacnikową, przez macierz dopełnień algebraicznych) wymaga rzędu  $O(n^3)$  operacji arytmetycznych lub więcej – i jest to najlepszy znany ogólny sposób na to konkretne zadanie<sup>1</sup>. Gdybyśmy zawsze rozwiązywali układ równań w ten sposób, to układ mający kilkaset tysięcy równań (a z takimi rozmiarami mamy do czynienia np. w symulacjach inżynierskich, patrz dalej) obliczałby się nieakceptowalnie długo.
- Po drugie okazuje się, że **odwracanie macierzy** dowolnym algorytmem, abstrahując od ilości czasu jaki taka operacja zajmie, **jest operacją źle uwarunkowaną numerycznie**. Oznacza to, że wraz ze wzrostem wielkości układu równań rosną błędy rozwiązania spowodowane drobnymi błędami danych wejściowych. Ten efekt jest na pierwszy rzut oka trudny do zaobserwowania, bo dla układów równań z jakimi mamy do czynienia w szkole (względnie małą liczbę równań) jest niezauważalny. Sytuacja jest tym gorsza, że nie da się go do końca wyeliminować (w przypadku metod algebraicznych) i możliwe są tylko takie implementacje metod, aby jego wpływ zminimalizować. W dodatku, **stopień jego nasilenia zależy od konkretnych danych wejściowych (liczb populujących macierz  $A$  i wektor  $b$ )**. Dla niektórych kombinacji jest większy niż dla innych. **Jest to tzw. problem uwarunkowania numerycznego układu równań liniowych** i będziemy o nim mówili dalej. Wszystkie metody algebraiczne, o których powiemy starają się ten efekt zminimalizować. Niemniej wraz ze wzrostem rozmiaru układu równań prędzej czy później efekt złego uwarunkowania będzie widoczny. Dlatego dla bardzo dużych układów równań stosujemy raczej innego typu metody (metody iteracyjne). Nie są one jednak zbieżne dla dowolnych danych układów równań (macierz  $A$  i wektor  $b$  muszą spełniać wymagania metody).

Poniżej pokazano to na prostym przykładzie: zmierzono czas rozwiązania losowego układu równań (naiwną, nieoptymalizowaną eliminacją Gaussa) dla kilku niewielkich rozmiarów, a następnie ekstrapolowano zaobserwowany trend  $O(n^3)$  na znacznie większe układy. To nie jest rygorystyczny dowód złożoności (do tego służy analiza teoretyczna) – chodzi tylko o wyobrażenie skali problemu: dla układu rzędu miliona równań (a więc rozmiaru, z jakim można się spotkać choćby w symulacjach MES) tak policzony czas sięga tysięcy lat.

<sup>1</sup>Nie jest to granica teoretyczna problemu, tylko najlepszy znany ogólny algorytm powszechnie stosowany w praktyce. Istnieją algorytmy o niższej złożoności teoretycznej (np. algorytm Strassena dla mnożenia macierzy, na którym opiera się też odwracanie, redukujący wykładnik z 3 do ok. 2.807, oraz dalsze, jeszcze bardziej wyrafinowane konstrukcje teoretyczne) – w praktyce nie są one jednak szeroko stosowane: mają duży narzut stałej, gorszą stabilność numeryczną i opłacają się dopiero dla bardzo dużych macierzy, dlatego pomijamy je na tym, podstawowym kursie.



Dlatego metody rozwiązywania układów równań liniowych dzielimy na dwie grupy:

- Metody algebraiczne – czyli opierające się o algebrę macierzy. Starają się one dokonać takiego rozkładu macierzy  $A$  na iloczyn innych macierzy, aby obliczenie jej odwrotności nie zajmowało tyle czasu, a także w niektórych przypadkach również starają się zapewnić minimalizację drugiego problemu uwarunkowania poprzez optymalizację. Metody algebraiczne działają dla każdego układu równań, ale ich klasa złożoności jest w najlepszym razie o jedną, w szczególnych przypadkach o dwie klasy, lepsza niż metody odwracania ogólnej (nie licząc nakładów na sam rozkład) – a więc dalej dość słaba. Dlatego nie znajdują zastosowania w bardzo dużych układach równań
- Metody iteracyjne – potrafią działać nawet na bardzo dużych układach równań. Ponieważ metody iteracyjne mają specyficzne działanie zawsze jesteśmy w stanie zagwarantować ich dokładność o ile metoda jest zbieżna i wykonamy odpowiednio wiele iteracji. Wadą metod iteracyjnych jest to, że większość tego typu metod nie jest zbieżna dla dowolnych danych wejściowych. Były one tworzone na potrzeby bardziej skomplikowanych metod numerycznych i są przystosowane do typów układów równań liniowych, które powstają w trakcie działania takich metod. Oznacza to, że zapewnienie zbieżności metod iteracyjnych rozwiązywania układów równań liniowych jest możliwe tylko dla konkretnych szczególnych rodzajów budowy macierzy  $A$  układu równań i może być niezbieżna dla innych rodzajów. Metody te tworzone z myślą o możliwości sterowania i optymalizacji szybkości zbieżności tak, żeby wykonać minimalną ilość iteracji, mniej przejmowano się ich uniwersalnością.

Duże układy równań, z jakimi mamy do czynienia w praktyce (np. dyskretyzacja równań różniczkowych cząstkowych metodą elementów skończonych (MES) czy metodą różnic skończonych), obok samego rozmiaru mają zwykle jeszcze jedną cechę sprzyjającą metodom iteracyjnym: są **rzadkie** (macierz układu równań jest macierzą rzadką)<sup>2</sup>. Możliwość implementacji metody tak, żeby pracowała z macierzami rzadkimi, jest bardzo pożądaną cechą, być może nawet najważniejszą w praktyce.

## NAJWAŻNIEJSZE INFORMACJE ROZDZIAŁU

- Postać kanoniczna układu równań liniowych to

$$A \cdot x = b \quad (18)$$

<sup>2</sup>Oznacza to, że przy dużej liczbie równań  $n$  zdecydowana większość elementów macierzy  $A$  to zera – każde równanie łączy zazwyczaj tylko niewielką, ograniczoną liczbę zmiennych (np. sąsiednie węzły siatki), niezależnie od tego, jak duży jest cały układ. Ma to znaczenie ważniejsze niż sama złożoność obliczeniowa – chodzi o możliwość zmieszczenia macierzy w pamięci: gęsta macierz  $n \times n$  wymaga pamięci rzędu  $O(n^2)$  niezależnie od tego, ile w niej faktycznie jest niezerowych wartości (dla układu z milionem równań, jak w symulacjach MES, oznaczałoby to zapisanie  $10^{12}$  liczb – petabajty pamięci, niemożliwe do zmieszczenia na żadnym komputerze), podczas gdy macierz rzadka – przechowywana w strukturze danych pomijającej zera – wymaga pamięci proporcjonalnej tylko do liczby elementów niezerowych, praktycznie  $O(n)$ . Metody iteracyjne potrafią wykorzystać tę rzadkość, bo operują na macierzy wyłącznie przez mnożenie razy wektor (koszt  $O(n)$  zamiast  $O(n^2)$ ); klasyczna eliminacja Gaussa czy rozkłady LU/QR w swojej podstawowej postaci w trakcie przekształceń niszczą rzadkość macierzy – zera „zapelniają się” niezerowymi wartościami – przez co tracą tę korzyść nawet wtedy, gdy macierz wejściowa była rzadka.

- Rozwiązanie tego układu wymaga odwrócenia macierzy  $A$  co jest w ogólnym przypadku operacją o złej klasie złożoności i o złym uwarunkowaniu numerycznym
- W zagadnieniu rozwiązywania układów równań liniowych istnieją dwa zasadnicze problemy – słaba klasa złożoności obliczeniowej metod algebraicznych oraz problem wpływu danych na błąd wyniku. Niektóre układy równań charakteryzują się bardzo dużą propagacją błędów danych wejściowych na błąd rozwiązania
- Istnieją dwa główne typy metod rozwiązywania układów równań liniowych – algebraiczne i iteracyjne. Metody algebraiczne zawsze znajdują rozwiązanie, ale mają niekorzystną klasę złożoności obliczeniowej. Metody iteracyjne nadają się dla dużych układów równań, gdzie są szybsze, potrafią efektywnie rozwiązywać układy rzadkie, ale nie są w stanie rozwiązywać układów równań o dowolnej budowie.

## ALGEBRAICZNE METODY ROZWIĄZYWANIA UKŁADU RÓWNAŃ LINIOWYCH

### METODA ELIMINACJI GAUSSA

Metoda eliminacji Gaussa jest najprostszą z metod i wykorzystuje podstawowy „trick” jaki stosujemy w metodach algebraicznych do rozwiązania problemu odwracania macierzy. Mianowicie będziemy starali się przekształcić tak układ równań w układ równań równoważny (o takim samym rozwiązaniu), żeby uzyskać macierz  $A$  tego naszego nowego układu równań w postaci którejś z macierzy trójkątnych

Macierzami trójkątnymi nazywamy jeden z dwóch rodzajów macierzy – macierz trójkątną górną (która ma elementy niezerowe wyłącznie nad diagonalą) albo macierz trójkątną dolną (która ma elementy niezerowe wyłącznie pod diagonalą). Przykładowe macierze trójkątne:

Macierz trójkątna górna ( $U$ ):

$$U = \begin{bmatrix} u_{1,1} & u_{1,2} & \dots & u_{1,N-1} & u_{1,N} \\ 0 & u_{2,2} & & u_{2,N-1} & u_{2,N} \\ & \vdots & \ddots & \vdots & \\ 0 & 0 & & u_{N-1,N-1} & u_{N-1,N} \\ 0 & 0 & & 0 & u_{N,N} \end{bmatrix} \quad (19)$$

Przykładowo:

$$A = \begin{bmatrix} 1 & 5 & 2 & 10 \\ 0 & 6 & 8 & 7 \\ 0 & 0 & 6 & 89 \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (20)$$

Macierz trójkątna dolna ( $R$ ):

$$R = \begin{bmatrix} r_{1,1} & 0 & \dots & 0 & 0 \\ r_{2,1} & r_{2,2} & & 0 & 0 \\ & \vdots & \ddots & \vdots & \\ r_{N-1,1} & r_{N-1,2} & \dots & r_{N-1,N-1} & 0 \\ r_{N,1} & r_{N,2} & & r_{N,N-1} & r_{N,N} \end{bmatrix} \quad (21)$$

Przykładowo:

$$A = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 2 & 6 & 0 & 0 \\ 6 & 2 & 6 & 0 \\ 7 & 3 & 6 & 1 \end{bmatrix} \quad (22)$$

Jeżeli macierz  $A$  układu równań liniowych byłaby właśnie macierzą trójkątną, to można znacznie zmniejszyć ilość obliczeń niezbędną do wykonania obliczeń, a w związku z tym przyspieszymy pracę naszej metody. Oczywiście poniesiemy dodatkowy koszt przekształcenia macierzy. Przykładowo poniżej pokazano układ równań z macierzą trójkątną:

$$\begin{bmatrix} 1 & 0 & 0 \\ 2 & 6 & 0 \\ 6 & 2 & 6 \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 7 \\ 2 \\ 4 \end{bmatrix} \quad (23)$$

Wyznaczenie pierwszego elementu  $x_1$  jest trywialne, drugiego  $x_2$ , znając już  $x_1$  też itd.

**Ważną praktyczną obserwacją jest to, że złożoność obliczeniowa rozwiązania układu o macierzy trójkątnej jest o klasę lepsza –  $O(n^2)$  – niż dla układu ogólnego.** Na pierwszy rzut oka nie znaczy to wiele, ale spójrz na poprzedni rysunek i zauważ, że złożoność kwadratowa na tamtej skali jest prostą o mniejszym nachyleniu. I nagle nie są to już godziny, a minuty; nie dni, a godziny.

W metodzie Gaussa korzystamy wyłącznie z tego właśnie tricku i staramy się przekształcić cały układ równań – zarówno macierz  $A$  jak i wektor  $b$ , do postaci takiej, w której macierz jest którąś z macierzy trójkątnych. Stosujemy do tego zestaw tzw. operacji elementarnych tzn. takich operacji wykonywanych na macierzy  $A$  i (w przypadku metody Gaussa) wektorze  $b$ , które nie zmieniają rozwiązania układu równań. Należą do nich:

- Zmiana kolejności wierszy (kolejność równań w układzie nie wpływa na jego rozwiązanie), czyli pivoting

$$\mathbf{A} = \begin{bmatrix} 8 & 2 & 2 \\ 5 & -3 & -1 \\ 0 & -5 & 5 \end{bmatrix}, \mathbf{b} = \begin{bmatrix} 10 \\ 5 \\ 10 \end{bmatrix} \rightarrow W_2 \leftrightarrow W_3 \rightarrow \mathbf{A} = \begin{bmatrix} 8 & 2 & 2 \\ 0 & -5 & 5 \\ 5 & -3 & -1 \end{bmatrix}, \mathbf{b} = \begin{bmatrix} 10 \\ 10 \\ 5 \end{bmatrix}$$

- Odjęcie/dodanie wielokrotności wiersza od drugiego wiersza

$$\mathbf{A} = \begin{bmatrix} 8 & 2 & 2 \\ 5 & -3 & -1 \\ 0 & -5 & 5 \end{bmatrix}, \mathbf{b} = \begin{bmatrix} 10 \\ 5 \\ 10 \end{bmatrix} \rightarrow W_2 - \frac{5}{8} \cdot W_1 \rightarrow \mathbf{A} = \begin{bmatrix} 8 & 2 & 2 \\ 0 & -\frac{17}{4} & -\frac{9}{4} \\ 0 & -5 & 5 \end{bmatrix}, \mathbf{b} = \begin{bmatrix} 10 \\ -\frac{5}{8} \\ 5 \end{bmatrix}$$

Odpowiada to następującemu przekształceniu układu równań:

$$\begin{cases} 8x_1 + 2x_2 + 2x_3 = 10 \\ 5x_1 - 3x_2 - 1x_3 = 5 \\ -5x_2 + 5x_3 = 5 \end{cases} \rightarrow W_2 - \frac{5}{8} \cdot W_1 \rightarrow \begin{cases} 8x_1 + 2x_2 + 2x_3 = 10 \\ -\frac{17}{4}x_2 - \frac{9}{4}x_3 = -\frac{5}{4} \\ -5x_2 + 5x_3 = 5 \end{cases}$$

Eliminacja Gaussa jest metodą historyczną (opracowano ją na początku XIX w. – Gauss opisał ją ok. 1809-1810 r., przy okazji obliczania orbity planetoidy Ceres), i nie jest implementowana dzisiaj w praktyce, ale jest podstawą do pokazania podstawowych problemów metod algebraicznych i do współczesnych metod. Jest to świetna metoda, ze względu na swoją prostotę, do przećwiczenia notacji kanonicznej i posługiwania się zapisem macierzowym układu równań. Ponadto koncepcja macierzy trójkątnej i związane z nią ułatwienie rozwiązywania układu równań jest czymś z czego korzystają wszystkie metody algebraiczne i nie tylko.

Dwie kluczowe koncepcje, które dzięki niej poznamy, to:

- **Pivoting** – czyli w jakiej kolejności wybierać wiersze/kolumny do eliminacji, żeby uniknąć katastrofalnej utraty precyzji (patrz niżej).
- Fakt, że eliminacja Gaussa przekształca **cały** układ – macierz **A** i wektor **b** jednocześnie. Oznacza to, że nawet jeśli zmieni się tylko wektor **b** (przy tej samej **A**), całą eliminację trzeba powtórzyć od nowa. To właśnie ta niedogodność jest motywacją do rozkładu LU, w którym przekształceniu poddajemy tylko **A** raz, a każdy nowy wektor **b** rozwiązujemy już dużo taniej.

### PIVOTING (WYBÓR ELEMENTU GŁÓWNEGO)

Wróćmy na chwilę do operacji zamiany wierszy, którą opisaliśmy wyżej jako jedną z dopuszczalnych operacji elementarnych. W praktyce nie jest to tylko formalna ciekawostka – to właśnie ta operacja ratuje eliminację Gaussa przed katastrofą numeryczną.

Problem pojawia się, kiedy element, przez który dzielimy przy eliminacji kolumny (nazywamy go **pivotem**, czyli elementem głównym), jest bliski zeru. Mnożnik potrzebny do wyzerowania kolejnego wiersza jest wtedy odwrotnością pivota, więc robi się bardzo duży. Duży mnożnik oznacza, że przy odejmowaniu wierszy odejmujemy od siebie liczby bardzo różnych rzędów wielkości – a jak wiemy z poprzedniego rozdziału, powoduje to dramatyczny wzrost błędu rozwiązania. Jest to wada prostej eliminacji Gaussa. Rozwiązaniem jest właśnie pivoting.

Zobaczmy to na przykładzie liczbowym. Weźmy układ:

$$\begin{bmatrix} 0,0001 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad (24)$$

którego dokładne rozwiązanie (bez żadnych zaokrągleń) to w przybliżeniu  $x_1 \approx 1,0001$ ,  $x_2 \approx 0,9999$ .

Założmy, że liczymy „na piechotę”, zaokrąglając wynik każdego działania do 3 cyfr znaczących (tak w uproszczeniu zachowuje się każda arytmetyka zmiennoprzecinkowa – ma skończoną precyzję).

**Bez pivotingu** (pivot = 0,0001, czyli pierwszy element na diagonalu „jak leci”):

- Mnożnik:  $\frac{1}{0,0001} = 10000$ , więc odejmujemy  $W_2 - 10000 \cdot W_1$ .
- Drugi wiersz:  $1 - 10000 \cdot 1 = -9999$ , po zaokrągleniu do 3 cyfr znaczących:  $-10000$ .
- Wyraz wolny:  $2 - 10000 \cdot 1 = -9998$ , po zaokrągleniu:  $-10000$ .
- Stąd  $x_2 = \frac{-10000}{-10000} = 1,00$  – na razie nieźle.
- Podstawiając z powrotem do pierwszego równania:  $x_1 = \frac{1 - 1,00}{0,0001} = \frac{0}{0,0001} = 0$ .



Zaokrąglenie „zjadło” różnicę między  $1 - 10000$  a  $2 - 10000$ , sprowadzając oba wyniki do tej samej wartości  $-10000$  – więc w liczniku dla  $x_1$  zostało czyste zero zamiast właściwej, małej różnicy. Wynik:  $x_1 = 0$  zamiast  $x_1 \approx 1,0001$  – błąd względny bliski 100%.

Z **pivotingiem** (najpierw zamieniamy wiersze, żeby na diagonalu znalazł się element o większej wartości bezwzględnej, tu: 1):  $W_1 \Leftrightarrow W_2$ .

- Mnożnik jest teraz mały: 0,0001, więc odejmujemy  $W_2 - 0,0001 \cdot W_1$ .
- Drugi wiersz:  $1 - 0,0001 \cdot 1 = 0,9999 \rightarrow 1,00$  (po zaokrągleniu do 3 cyfr).
- Wyraz wolny:  $1 - 0,0001 \cdot 2 = 0,9998 \rightarrow 1,00$ .
- Stąd  $x_2 = 1,00$ , a z pierwszego (przestawionego) wiersza  $x_1 = 2 - x_2 = 1,00$ .

Wynik bardzo bliski dokładnemu rozwiązaniu ( $1,0001 / 0,9999$ ), mimo dokładnie takiego samego zaokrąglenia do 3 cyfr znaczących co w wariancie bez pivotingu.

Różnica bierze się wyłącznie z tego, przez jak duży czy mały element dzieliliśmy – macierz i przyjęta dokładność zaokrągleń były identyczne w obu wariantach.

Stąd praktyczna reguła, nazywana **pivotingiem częściowym (partial pivoting)**: przed eliminacją każdej kolejnej kolumny, spośród wierszy, które jeszcze nie zostały użyte jako pivot, wybieramy ten, w którym element w danej kolumnie ma **największą wartość bezwzględną**, i zamieniamy go (operacją zamiany wierszy) na pozycję diagonalną. Dzięki temu mnożniki używane w eliminacji nigdy nie przekraczają co do wartości bezwzględnej 1, co znacząco ogranicza narastanie błędów zaokrągleń. Jest to na tyle istotne, że w praktyce każda sensowna implementacja eliminacji Gaussa i rozkładu LU (w tym te używane w bibliotekach numerycznych, z których będzie – pominięcie go jest raczej wyjątkiem uzasadnionym szczególnymi właściwościami macierzy (np. symetryczna dodatnio określona), a nie normą.

## METODA ROZKŁADU LU

Metoda rozkładu LU jest bardziej zaawansowaną formą poprzedniego podejścia. Wadą eliminacji Gaussa było to, że za każdym razem musieliśmy przekształcać macierz **A** i wektor **b** razem. Tymczasem często mamy do czynienia z sytuacją, kiedy w kolejnych rozwiązaniach/iteracjach jakiejś bardziej skomplikowanej metody korzystające z metody rozwiązywania układu równań liniowych macierz **A** układu pozostaje niezmienna, a zmieniają się jedynie wartości wektora **b** (np. stałe wymuszenie działające na ten sam układ w kolejnych chwilach czasowych). W metodzie Gaussa musieliśmy przekształcać za każdym razem cały układ równań od nowa, tymczasem w metodzie LU działań będziemy dokonywać wyłącznie na macierzy **A**, a wektor **b** zostawimy w spokoju. Mianowicie dokonamy rozkładu macierzy **A** na iloczyn dwóch macierzy **L** (dolnej trójkątnej) i **U** (górnej trójkątnej)<sup>3</sup>.

$$\mathbf{A} \cdot \mathbf{x} = \mathbf{b} \quad (25)$$

$$\mathbf{A} = \mathbf{LU} \quad (26)$$

$$\mathbf{LU} \cdot \mathbf{x} = \mathbf{b} \quad (27)$$

Po dokonaniu rozkładu obliczenia rozbija się na dwa etapy – układy równań o trywialnym rozwiązaniu. Każdy mający macierz w postaci macierzy trójkątnej i w związku z tym rozwiązywany o rząd wielkości szybciej (każdy ze złożonością  $O(n^2)$ ). W pierwszym kroku obliczamy układ zewnętrzny:

$$\mathbf{Ly} = \mathbf{b} \quad (28)$$

Znając rozwiązanie **y** można rozwiązać wewnętrzny układ równań, równie trywialny.

$$\mathbf{Ux} = \mathbf{y} \quad (29)$$

<sup>3</sup>Jako ciekawostkę podam, że metodę wymyślił i udowodnił twierdzenie, że każdą macierz kwadratową da się rozłożyć wg wzorca LU Tadeusz Banachiewicz w 1938 r.



## PRZYKŁAD ROZKŁADU LU

Rozłóżmy na LU macierz  $\mathbf{A}$ :

$$\mathbf{A} = \begin{bmatrix} 2 & 1 & 1 \\ 4 & 3 & 3 \\ 8 & 7 & 9 \end{bmatrix} \quad (30)$$

Robimy to dokładnie tak samo, jak zwykłą eliminację Gaussa – z jedną różnicą: zamiast odrzucać mnożnik użyty przy zerowaniu danego elementu, **zapisujemy go (bez zmiany znaku) w tym samym miejscu macierzy L**, która na diagonalu ma zawsze same jedynki. Cała operacja dotyczy wyłącznie macierzy  $\mathbf{A}$  – wektor  $\mathbf{b}$  w ogóle się tu nie pojawia, nic się z nim nie dzieje.

- Krok pierwszy – zerujemy pierwszą kolumnę poniżej pivotu  $a_{1,1} = 2$ . Mnożnik dla wiersza 2:  $l_{21} = 4/2 = 2$ ; dla wiersza 3:  $l_{31} = 8/2 = 4$ . Formalnie odpowiada to przemnożeniu  $\mathbf{A}$  z lewej strony przez macierz eliminującą  $\mathcal{L}_1$  (macierz jednostkowa z mnożnikami wpisanymi ze znakiem minus w odpowiednich elementach macierzy):

$$\mathcal{L}_1 = \begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ -4 & 0 & 1 \end{bmatrix}, \quad \mathcal{L}_1 \mathbf{A} = \begin{bmatrix} 2 & 1 & 1 \\ 0 & 1 & 1 \\ 0 & 3 & 5 \end{bmatrix} \quad (31)$$

- Krok drugi – zanim wyzerujemy drugą kolumnę, sprawdzamy **pivoting**: spośród wierszy 2 i 3 większą wartość bezwzględną w kolumnie 2 ma wiersz 3 ( $a_{3,2} = 3 > a_{2,2} = 1$ ), więc najpierw zamieniamy  $W_2 \leftrightarrow W_3$  – **razem z już zapisanymi w tych wierszach mnożnikami  $l_{21}$  i  $l_{31}$** , bo są przypisane do fizycznych wierszy, a nie do numerów kroków:

$$\begin{bmatrix} 2 & 1 & 1 \\ 0 & 3 & 5 \\ 0 & 1 & 1 \end{bmatrix}, \quad l_{21} = 4, \quad l_{31} = 2 \quad (32)$$

Dopiero teraz eliminujemy kolumnę 2, pivotem 3 (zamiast 1, jak byłoby bez pivotingu). Mnożnik dla wiersza 3:  $l_{32} = 1/3$ . Formalnie odpowiada to przemnożeniu przez macierz eliminującą  $\mathcal{L}_2$  (dopasowaną już do przestawionych wierszy):

$$\mathcal{L}_2 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -\frac{1}{3} & 1 \end{bmatrix}, \quad \mathbf{U} = \begin{bmatrix} 2 & 1 & 1 \\ 0 & 3 & 5 \\ 0 & 0 & -\frac{2}{3} \end{bmatrix} \quad (33)$$

Zapise przy okazji mnożniki (już z uwzględnioną zamianą wierszy) tworzą macierz  $\mathbf{L}$ :

$$\mathbf{L} = \begin{bmatrix} 1 & 0 & 0 \\ 4 & 1 & 0 \\ 2 & \frac{1}{3} & 1 \end{bmatrix} \quad (34)$$

a sama zamiana wierszy 2 i 3 to macierz permutacji, potrzebna do zorientowania się, które równanie oryginalnie było gdzie (jak poprzestawiasz wiersze tak, żeby macierz  $\mathbf{P}$  była macierzą jednostkową, to odtworzysz stan sprzed pivotingu):

$$\mathbf{P} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix} \quad (35)$$

Możesz szybko sprawdzić, że  $\mathbf{PA} = \mathbf{LU}$ . Żadnego odwracania macierzy nie trzeba robić. Sama operacja rozkładu dalej ma złożoność  $O(n^3)$ , ale każde następne rozwiązanie praktycznie korzysta z macierzy trójkątnych, o ile macierz  $\mathbf{A}$  się nie zmienia, tylko wektor  $\mathbf{b}$  (często tak się zdarza), więc możemy przyspieszyć obliczenia do poziomu  $O(n^2)$ .

Formalnie rozkład LU definiuje się nieco inaczej – jako iloczyn macierzy eliminujących i (w razie pivotingu) permutujących<sup>4</sup>. To matematycznie poprawna definicja i tak zwykle podaje się ją w podręcznikach – ale **w praktyce implementacje opierają się na pokazanych właściwościach**.

<sup>4</sup>Formalnie:  $\mathcal{L}_2 \mathbf{P} \mathcal{L}_1 \mathbf{A} = \mathbf{U}$  ( $\mathbf{P}$  to zamiana wierszy 2 i 3 wymuszona przez pivoting, wykonana pomiędzy  $\mathcal{L}_1$  a  $\mathcal{L}_2$ ). Odwracając po kolei

## ROZKŁAD QR

Rozkład QR jest najbardziej zaawansowanym rozkładem z jakim się zapoznamy. W rozkładzie QR, podobnie jak w rozkładzie LU, dokonamy przekształcenia macierzy  $\mathbf{A}$  tak, żeby jedna z macierzy, które powstaną, była macierzą trójkątną ( $\mathbf{R}$ ). Natomiast druga macierz ( $\mathbf{Q}$ ) będzie specjalnie zbudowaną macierzą tak, żeby mieć unikatowe właściwości, którą będziemy nazywali macierzą ortogonalną<sup>5</sup>.

Macierz ortogonalna ma dwie ważne właściwości, z których chcemy skorzystać:

- Odwrotność macierzy ortogonalnej jest równa jej sprzężeniu Hermitowskiemu<sup>6</sup> (w przestrzeni liczb zespolonych). W przypadku liczb rzeczywistych, jest równa po prostu jej transpozycji. To niezwykle wygodna właściwość bo w takim wypadku odwrócenie macierzy  $\mathbf{Q}$  nie wprowadza żadnego błędu numerycznego – ponieważ nie wykonujemy żadnych obliczeń, polega wyłącznie na przeniesieniu indeksów w pamięci i zmianie bitu znaku w zapisie zmiennoprzecinkowym. Brak konieczności wykonywania jakichkolwiek obliczeń pozytywnie odbija się na właściwościach tej metody jeżeli chodzi o problem złego uwarunkowania numerycznego problemu odwracania macierzy – efekt ten jest znacznie zminimalizowany. Jednak nie jest wyeliminowany. Właściwość tę zapisujemy dla przestrzeni liczb rzeczywistych jako:

$$\mathbf{Q}^T = \mathbf{Q}^{-1} \quad (42)$$

- Druga właściwość to fakt, że skoro tak to:

$$\mathbf{Q}^T \mathbf{Q} = \mathbf{I} \quad (43)$$

Dlatego rozwiązanie układu równań liniowych wg rozkładu QR przebiega, podobnie jak w przypadku rozkładu LU, w kilku etapach:

- 1) W etapie pierwszym dokonujemy samego rozkładu:

$$\mathbf{A}\mathbf{x} = \mathbf{b} \quad (44)$$

$$\mathbf{Q}\mathbf{R}\mathbf{x} = \mathbf{b} \quad (45)$$

każdy krok i przemnażając obie strony przez  $\mathbf{P}$  dostajemy  $\mathbf{P}\mathbf{A} = (\mathbf{P}\mathcal{L}_1^{-1}\mathbf{P})\mathcal{L}_2^{-1}\mathbf{U}$ , czyli  $\mathbf{L} = (\mathbf{P}\mathcal{L}_1^{-1}\mathbf{P})\mathcal{L}_2^{-1}$ . Macierz  $\mathbf{P}\mathcal{L}_1^{-1}\mathbf{P}$  to po prostu  $\mathcal{L}_1^{-1}$  (odwrócone przez zwykłą zmianę znaku mnożników) z zamienionymi wierszami i kolumnami 2 i 3 – czyli dokładnie ta sama zamiana mnożników  $l_{21} \leftrightarrow l_{31}$ , którą zrobiliśmy „ręcznie” w kroku drugim:

$$\mathcal{L}_1^{-1} = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 4 & 0 & 1 \end{bmatrix} \longrightarrow \mathbf{P}\mathcal{L}_1^{-1}\mathbf{P} = \begin{bmatrix} 1 & 0 & 0 \\ 4 & 1 & 0 \\ 2 & 0 & 1 \end{bmatrix}, \quad \mathcal{L}_2^{-1} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & \frac{1}{3} & 1 \end{bmatrix} \quad (36)$$

a ich iloczyn, jak łatwo sprawdzić, daje dokładnie macierz  $\mathbf{L}$  policzoną wyżej metodą skrótową:

$$(\mathbf{P}\mathcal{L}_1^{-1}\mathbf{P})\mathcal{L}_2^{-1} = \begin{bmatrix} 1 & 0 & 0 \\ 4 & 1 & 0 \\ 2 & \frac{1}{3} & 1 \end{bmatrix} = \mathbf{L} \quad (37)$$

<sup>5</sup>Macierz ortogonalna to taka macierz, że wszystkie jej wektory są parami ortonormalne. Dwa wektory  $\mathbf{p}$  i  $\mathbf{q}$  są ortonormalne, jeżeli mają długość (drugą normę Höldera) równą 1, oraz są ortogonalne (ich iloczyn skalarny jest równy zero), co jest równoważne ze spełnieniem trzech warunków:

$$\mathbf{p}^T \mathbf{q} = 0 \quad (38)$$

$$\mathbf{p}^T \mathbf{p} = 1 \quad (39)$$

$$\mathbf{q}^T \mathbf{q} = 1 \quad (40)$$

<sup>6</sup>Macierz Hermitowsko sprzężoną względem macierzy  $\mathbf{A}^{M \times N} = [a_{MN}] \in \mathbb{C}^{M \times N}$  oznaczaną  $\mathbf{A}^H$  jest to macierz taka, że:

$$\mathbf{A}^H = \begin{bmatrix} a_{1,1}^* & \cdots & a_{M,1}^* \\ \vdots & \ddots & \vdots \\ a_{1,N}^* & \cdots & a_{M,N}^* \end{bmatrix} \quad (41)$$

Elementy tej macierzy są transponowane i sprzężone. W przestrzeni liczb rzeczywistych macierzą Hermitowską jest macierz transponowana.

2) W etapie drugim korzystamy z właściwości rozkładu uzyskując układ równoważny:

$$Q^{-1}QRx = Q^{-1}b \quad (46)$$

$$Q^TQRx = Q^Tb \quad (47)$$

$$IRx = Q^Tb \quad (48)$$

$$Rx = Q^Tb \quad (49)$$

3) W etapie trzecim rozwiązujemy „zewnątrzny” układ równań

$$y = Q^Tb \quad (50)$$

4) Na koniec rozwiązujemy „wewnętrzny” układ równań z macierzą trójkątną

$$Rx = y \quad (51)$$

Rozkład QR jest bardzo ważnym rozkładem, ponieważ pozwala obliczyć coś co nazywamy macierzą pseudoodwrotną (o tym dalej). Dodatkowo minimalizuje wpływ problemu złego uwarunkowania. Jak wszystkie metody algebraiczne, rozkład QR ma w typowym przypadku klasę złożoności obliczeniowej  $O(n^3)$ , przy czym dominuje tutaj nakład na wykonanie samego rozkładu, który jest nieco większy niż w metodzie LU. Podobnie jak w LU, dopóki macierz  $A$  się nie zmienia, kolejne obliczenia wykonujemy już z  $O(n^2)$ . W praktyce rozkład QR ma istotne znaczenie praktyczne i wymyślono wiele metod jego tworzenia. Z koncepcją ortogonalności macierzy w metodach numerycznych spotkamy się jeszcze nie raz przy bardziej skomplikowanych problemach. Podręcznikową metodą dokonania rozkładu QR jest ortogonalizacja Grama-Schmidta, ale najczęściej implementuje się bardziej zaawansowane metody oparte o przekształcenia Householdera.

Warto na koniec zaznaczyć, dlaczego rozkładowi QR poświęcamy tu mniej miejsca niż rozkładowi LU, mimo że w praktyce jest od niego **ważniejszy**. Nie wynika to ze znaczenia – pomijamy jedynie samą mechanikę tworzenia rozkładu (ortogonalizację Grama-Schmidta, przekształcenia Householdera), bo nie wnosi ona nic nowego do zrozumienia podstaw, które poznaliśmy już przy okazji LU. Prawdziwe znaczenie rozkładu QR wynika z tego, czego LU po prostu nie potrafi: LU wymaga macierzy kwadratowej i nieosobliwej, natomiast QR działa również dla macierzy prostokątnych, dzięki czemu pozwala rozwiązywać układy nadokreślone (więcej równań niż niewiadomych) metodą najmniejszych kwadratów – a to jest scenariusz występujący w bardzo wielu zastosowaniach (o niektórych będziemy mówić na tym wykładzie), np. przy dopasowywaniu modelu do danych pomiarowych. Dodatkowo, ponieważ  $Q$  jest macierzą ortogonalną, sam rozkład ma **gwarantowaną** stabilność numeryczną, niezależną od konkretnej macierzy  $A$  – czego LU, jak zobaczymy dalej, w ogólności zagwarantować nie może – a do tego QR stanowi fundament wielu bardziej zaawansowanych i niezwykle istotnych metod numerycznych (m.in. obliczania wartości własnych macierzy).

## NAJWAŻNIEJSZE INFORMACJE ROZDZIAŁU

- Koncepcja macierzy trójkątnej i sposób jej uzyskiwania na podstawie przykładowej metody eliminacji Gaussa – układ z macierzą trójkątną można rozwiązać wykonując algorytm mający klasę złożoności  $O(N^2)$  zamiast  $O(N^3)$ . Niestety standardowa metoda Gaussa doprowadzenia dowolnego układu do postaci macierzy trójkątnej ma klasę złożoności  $O(N^3)$
- **Pivoting (wybór elementu głównego)** – dzielenie przez mały pivot przy eliminacji prowadzi do dużych mnożników i utraty dokładności przy zaokrągleniach; zamiana wierszy tak, by na diagonalu znalazł się element o największej wartości bezwzględnej (pivoting częściowy), jest praktycznym standardem stosowanym zarówno w eliminacji Gaussa, jak i w rozkładzie LU ( $PA = LU$ )
- Właściwości rozkładu LU, zakres jego stosowania, sposób zastosowania, przykładowe rozłożenie macierzy  $A$  na iloczyn LU – metoda LU ma zastosowanie dla problemów rozwiązywanych wielokrotnie z różnymi wymuszeniami działającymi na system. Rozkład LU pozwala na uzyskanie macierzy trójkątnej bez konieczności przekształcania wektora  $b$  (wektora wymuszeń) dzięki czemu nie trzeba ponosić dodatkowych kosztów rozkładu (złożoność klasy  $O(N^3)$ ) w kolejnych rozwiązaniach. W długiej perspektywie zatem złożoność tej metody jest  $O(N^2)$

$$\mathbf{L}\mathbf{y} = \mathbf{b} \quad (52)$$

$$\mathbf{U}\mathbf{x} = \mathbf{y} \quad (53)$$

- Koncepcja macierzy ortogonalnej i jej właściwości:

$$\mathbf{Q}^T = \mathbf{Q}^{-1} \quad (54)$$

$$\mathbf{Q}^T \mathbf{Q} = \mathbf{I} \quad (55)$$

- Sposób rozkładu QR i jego właściwości praktyczne, umiejętność przeprowadzenia obliczeń zgodnych z tym schematem – rozkład QR ma te same korzystne właściwości co LU. Ponadto pozwala na zmniejszenie wpływu niekorzystnych danych na dokładność wyniku. Okupione jest to bardziej skomplikowaną procedurą samego rozkładu co może być niekorzystne dla danych dobrej jakości nie powodujących znacznej propagacji błędów

$$\mathbf{y} = \mathbf{Q}^T \mathbf{b} \quad (56)$$

$$\mathbf{R}\mathbf{x} = \mathbf{y} \quad (57)$$

#### UWARUNKOWANIE NUMERYCZNE PROBLEMU ROZWIĄZYWANIA UKŁADU RÓWNAŃ LINIOWYCH, WSPÓŁCZYNNIK UWARUNKOWANIA


Jak już wspomniano wcześniej problem odwracania macierzy, a co za tym idzie problem rozwiązywania układów równań liniowych szczególnie za pomocą metod algebraicznych jest problemem źle uwarunkowanym. Dla przypomnienia – uwarunkowanie numeryczne ma ścisły związek z rozmiarem problemu. Ponieważ rozmiar problemu w naszym przypadku to liczba niewiadomych (a więc i równań) oznacza to, że utrata dokładności rozwiązania (wzrost błędów). Dlatego mogłeś dotychczas nie obserwować tego typu zjawisk – pracowałeś dotychczas na zbyt małych układach równań.

Co jednak ważniejsze wraz z rosnącym rozmiarem problemu błąd rozwiązania będzie większy lub mniejszy również w zależności od – a więc konkretnych liczb i konkretnych ich układów wewnątrz macierzy  $\mathbf{A}$  i wektora  $\mathbf{b}$ . Sytuacja wygląda zatem następująco – zasadniczo zawsze wraz ze wzrostem liczby równań rośnie nam błąd rozwiązania (co do zasady). Niemniej na ten długofalowy trend nakłada się wpływ danych wejściowych – niektóre układy liczb w macierzy  $\mathbf{A}$  i wektorze  $\mathbf{b}$  powodują większy wzrost błędów niż inne, a w konsekwencji np. na wykresie błędów od rozmiaru układu równań może się nawet wydawać, że momentami błąd spada – wtedy, kiedy kolejny układ równań jest co prawda większy, ale układ liczb wewnątrz macierzy  $\mathbf{A}$  i wektora  $\mathbf{b}$  jest lepszy niż poprzednio.

Zobaczymy to na wykresie. Dla wielu losowych układów równań o rosnącym rozmiarze  $n$  zbudowano układ o znanym z góry, dokładnym rozwiązaniu (przyjmując dowolny wektor  $\mathbf{x}$  i licząc  $\mathbf{b} = \mathbf{A}\mathbf{x}$ ), rozwiązano go zwykłym solverem w standardowej, podwójnej precyzji i porównano wynik z dokładnym rozwiązaniem – różnica między nimi to czysta propagacja błędów zaokrągleń popełnionych w trakcie samych obliczeń, o której mowa w przypisie Linia przerywana to **długoterminowy trend** (mediana błędów po wielu losowych układach dla każdego  $n$ ) – rzeczywiście rośnie wraz z rozmiarem układu, bo więcej operacji arytmetycznych daje więcej okazji do skumulowania błędów. Linia ciągła to jednak **jedna konkretna sekwencja** kolejnych, coraz większych układów – i widać, że lokalnie zachowuje się chaotycznie, czasem nawet malejąc, mimo że  $n$  rośnie – bo konkretne dane w danym układzie akurat wzmacniają błąd słabiej niż w poprzednim, mniejszym układzie. Cienka czarna linia

<sup>7</sup>To **nie jest** zjawisko odrębne od uwarunkowania numerycznego problemu (patrz niżej) – przeciwnie, uwarunkowanie numeryczne to właśnie ta właściwość: to, jak (w najgorszym przypadku) błąd danych wejściowych propaguje się na błąd wyniku, niezależnie od tego, skąd ten błąd faktycznie pochodzi – z niedokładnego pomiaru danych, czy z zaokrągleń popełnianych w trakcie samych obliczeń (z punktu widzenia tej propagacji jest to równoważne niewielkiemu zaburzeniu danych wejściowych). Powodem, dla którego błąd rośnie wraz z  $n$ , jest więc to, że większy układ to po prostu więcej operacji arytmetycznych (rzędu  $O(n^3)$  w eliminacji Gaussa) – każda z nich wprowadza swój własny, niewielki błąd zaokrąglenia, który później – tak jak każdy błąd danych wejściowych – podlega tej samej propagacji. Żeby tę propagację dało się mierzyć i porównywać liczbowo (a nie tylko jakościowo, jak tutaj), potrzebny jest konkretny wskaźnik – dla układów równań liniowych jest nim **współczynnik uwarunkowania**  $\text{cond}(\mathbf{A})$ , który poznamy za chwilę. Efekt jest w pełni widoczny już przy zwykłej, podwójnej precyzji (patrz wykres niżej) – błąd pojedynczej operacji jest wprawdzie rzędu  $10^{-16}$ , ale skumulowany błąd rozwiązania rośnie systematycznie z  $n$  i dla układów rzędu kilku tysięcy równań jest już o 3-4 rzędy wielkości większy niż dla układów rzędu kilkunastu równań.

to klasyczne **oszacowanie teoretyczne**  $\text{cond}(\mathbf{A}) \cdot \varepsilon_{\text{maszynny}}$  (współczynnik uwarunkowania *tej samej, konkretnej macierzy* razy błąd pojedynczej operacji zmiennoprzecinkowej), policzone dla dokładnie tych samych układów co chaotyczna linia niebieska – widać, że rzeczywiście dominuje realny błąd w każdym punkcie, tak jak powinno oszacowanie z góry.



Zwróć uwagę, że oszacowanie  $\text{cond}(\mathbf{A}) \cdot \varepsilon_{\text{maszynny}}$  jest tu uproszczeniem – milcząco zakłada, że sam algorytm rozwiązywania (tu: standardowy solver, LU z pivotingiem) nie dokłada nic ponad to, czego wymaga uwarunkowanie problemu. Dla macierzy losowych (jak tutaj) to założenie w praktyce trzyma się dobrze, ale nie zawsze musi – do tego wrócimy za chwilę, po wprowadzeniu współczynnika uwarunkowania, w krótkiej sekcji o tzw. **czynniku wzrostu**.

Dla kogoś nierozumiejącego metod numerycznych i ich właściwości może to sprawiać wrażenie chaosu. Co więcej musimy mieć jakiś sposób przewidywania jakości wyniku bez konieczności rozwiązywania dużej ilości układów i ponoszenia kosztów z tym związanych, wymaga to głębszej systematycznej analizy. Będziemy się starali odpowiedzieć na następujące pytania:

- Jak stwierdzić, który zestaw liczb w danych wejściowych jest lepszy od innych – z problemem tym wiąże się pojęcie **współczynnika uwarunkowania układu równań**.
- Jak wyglądają szczególne przypadki testowe zaprojektowane w ten sposób, aby wypreparować jeden z tych efektów, minimalizując drugi – w praktyce takie układy równań zostały stworzone do testowania nowych metod numerycznych.

Zastanówmy się na chwilę nad pierwszym punktem. Taki mechanizm jest nam bardzo potrzebny, bo po pierwsze pozwala podjąć próbę automatycznego przekształcenia układu równań do postaci o lepszej dokładności (np. stosując przekształcenia równoważne takie jak w metodzie eliminacji Gaussa), po drugie pozwala wysnuć wnioski natury ogólnej dotyczącej tego, jak powinien wyglądać układ równań liniowych, aby wpływ złego uwarunkowania był zminimalizowany – to bardzo istotne w konstrukcji metod wyższych rzędów, które korzystają w toku swojego działania z rozwiązywania układów równań liniowych (nawet na tym wykładzie poznamy takich metod wiele), wreszcie po trzecie pozwala nam oszacować błąd rozwiązania lub wybrać najbardziej optymalną metodę numeryczną, biorąc pod uwagę dokładność i koszt obliczeniowy.

## WSPÓŁCZYNNIK UWARUNKOWANIA UKŁADU RÓWNAŃ LINIOWYCH I JEGO ZWIĄZEK Z BŁĘDEM ROZWIĄZANIA

Na początek zajmiemy się problemem pierwszym. Z definicji złe uwarunkowanie numeryczne jest wtedy, kiedy mały błąd danych wejściowych daje duży błąd rozwiązania, i typowo wtedy, kiedy ten efekt pogarsza się wraz z rozmiarem problemu. Nasze dane wejściowe to macierz  $\mathbf{A}$  i wektor  $\mathbf{b}$ . Zajmiemy się na początek wektorem

$\mathbf{b}$  (analiza tego przypadku jest prostsza) i będziemy się starali stworzyć jakiś sposób oszacowania tego, jak błąd wektora  $\mathbf{b}$  wpływa na błąd rozwiązania.

W naszym przypadku zakładamy więc, że macierz  $\mathbf{A}$  jest znana dokładnie, a błąd w rozwiązaniu  $\Delta \mathbf{x}$  wynika wyłącznie z błędów danych wejściowych wektora  $\mathbf{b}$  ( $\Delta \mathbf{b}$ ). Zwróć uwagę, że analizujemy tutaj błąd metody bo pominiemy tutaj wpływ błędów reprezentacji i błędów zaokrągleń, które w każdym rzeczywistym przypadku również istnieją. W dalszej części wykładu takie założenie będzie robione w milczący sposób.

Nasz przypadek możemy zapisać jako:

$$\mathbf{A}(\mathbf{x} + \Delta \mathbf{x}) = \mathbf{b} + \Delta \mathbf{b} \quad (58)$$

A ponieważ  $\Delta \mathbf{x}$  wynika wyłącznie z  $\Delta \mathbf{b}$  oraz w przypadku dokładnym zachodzi równość  $\mathbf{A}\mathbf{x} = \mathbf{b}$  to możemy zapisać:

$$\mathbf{A}\Delta \mathbf{x} = \Delta \mathbf{b} \quad (59)$$

$$\Delta \mathbf{x} = \mathbf{A}^{-1} \Delta \mathbf{b} \quad (60)$$

Mamy już zatem wyrażony wektor błędu rozwiązania za pomocą błędu wektora  $\mathbf{b}$ . Tylko, że wielkość ta jest dalej wektorem, a nam przydałaby się jakaś wartość liczbową, żeby mieć proste porównanie pozwalające nam skorzystać z niej w sposób opisany wcześniej. Dlatego też posłużymy się właściwościami norm i zapiszemy oszacowanie od góry błędu względnego. Z właściwości norm, o których już mówiliśmy, możemy zapisać<sup>8</sup>:

$$\|\Delta \mathbf{x}\| = \|\mathbf{A}^{-1} \Delta \mathbf{b}\| \quad (61)$$

$$\|\Delta \mathbf{x}\| \leq \|\mathbf{A}^{-1}\| \cdot \|\Delta \mathbf{b}\| \quad (62)$$

Mamy teraz oszacowanie, ale błędu bezwzględnego. Aby przejść do błędu względnego zapiszemy podobne równania, ale dla dokładnego układu równań:

$$\mathbf{A}\mathbf{x} = \mathbf{b} \quad (63)$$

$$\|\mathbf{b}\| = \|\mathbf{A}\mathbf{x}\| \quad (64)$$

$$\|\mathbf{b}\| \leq \|\mathbf{A}\| \cdot \|\mathbf{x}\| \quad (65)$$

$$\frac{\|\mathbf{b}\|}{\|\mathbf{x}\|} \leq \|\mathbf{A}\| \quad (66)$$

Mnożąc stronami powyższe równanie z oszacowaniem dokonanym dla naszego założenia pochodzenia błędu otrzymujemy następującą ważną właściwość:

$$\frac{\|\Delta \mathbf{x}\|}{\|\mathbf{x}\|} \leq \|\mathbf{A}\| \|\mathbf{A}^{-1}\| \frac{\|\Delta \mathbf{b}\|}{\|\mathbf{b}\|} \quad (67)$$

Powyższe równanie pokazuje, że wpływ zaburzenia wektora  $\mathbf{b}$  na wynik jest zależny od tego, jak wygląda w danym układzie równań macierz  $\mathbf{A}$ , i jest tym mniejszy, im wartość  $\|\mathbf{A}\| \|\mathbf{A}^{-1}\|$  jest mniejsza. Wartość ta ma specjalną nazwę - **współczynnik uwarunkowania**. Powyższe równanie jest równaniem definiującym go. Współczynnik uwarunkowania oznaczamy następująco:

$$\text{cond}(\mathbf{A}) = \|\mathbf{A}\| \|\mathbf{A}^{-1}\| \quad (68)$$

I jest on z definicji współczynnikiem w jakim błąd danych wejściowych wektora  $\mathbf{b}$  wpływa na oszacowanie błędu wektora rozwiązania (częściej mówi się po prostu w jaki błąd wektora  $\mathbf{b}$  wpływa na błąd rozwiązania). Współczynnik uwarunkowania jest tym lepszy im mniejsza jest jego wartość, a wartość minimalna wynosi 1. Jest też tym gorszy im wartość ta jest wyższa.

<sup>8</sup>Dla przypomnienia ogólne właściwości norm to:

$\|\mathbf{x}\| \geq 0$  oraz  $\|\mathbf{x}\| = 0$  wtedy gdy  $\mathbf{x}$  jest wektorem zerowym

$\|\alpha \mathbf{x}\| = \|\mathbf{x}\| \cdot |\alpha|$

$\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|$

Można analogiczną procedurę przeprowadzić dla analizy błędów macierzy  $A$  – uzyskalibyśmy wtedy następujące równanie:

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\text{cond}(A) \frac{\|\Delta A\|}{\|A\|}}{1 - \text{cond}(A) \frac{\|\Delta A\|}{\|A\|}} \quad (69)$$

A całkowity błąd danych wejściowych wpływa na błąd wyniku w następujący sposób:

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\text{cond}(A) \frac{\|\Delta A\|}{\|A\|}}{1 - \text{cond}(A) \frac{\|\Delta A\|}{\|A\|}} + \text{cond}(A) \frac{\|\Delta b\|}{\|b\|} \quad (70)$$

Jeżeli zadamy sobie pytanie, które z tych dwóch zjawisk jest bardziej znaczące, to okaże się, że w większości przypadków to właśnie błąd danych wektora  $b$  ma najistotniejsze znaczenie. Dla większości przypadków różnica jest tak duża, że często drugiego składnika nawet się nie szacuje.

Dzięki tej analizie jesteśmy w stanie odpowiedzieć na wiele z naszych pytań:

- potrafimy oszacować błąd rozwiązania – wystarczy znać  $\text{cond}(A)$  i zastosować powyższe oszacowania.
- Potrafimy stwierdzić, który z dwóch układów równań da nam mniejszy błąd rozwiązania, a zatem wiemy już, jak przekształcić nasz wejściowy układ równań, aby zminimalizować błąd (np. przez prostą zamianę kolejności równań/ wierszy w macierzy  $A$  tak, żeby zminimalizować współczynnik uwarunkowania takiego układu równań)
- W toku dalszych analiz określono też pewne reguły, które musi spełniać macierz  $A$ , aby współczynnik uwarunkowania układu równań z tą macierzą był jak najlepszy. Jedną z tych reguł, która istotnie wpływa na bardziej skomplikowane metody, o których będziemy mówić jest reguła mówiąca, że dobrze uwarunkowane układy równań da (słabo bądź silnie).
- Wreszcie systematyczne podejście do analizy problemu pozwoliło na stworzenie testowych układów równań

### CZYNNIK WZROSTU (GROWTH FACTOR) – DLACZEGO LU I QR JEDNAK SIĘ RÓŻNIĄ

Oszacowanie  $\text{cond}(A) \cdot \varepsilon_{\text{maszynny}}$  z poprzedniej sekcji mówi o wrażliwości samego **problemu** – jest identyczne bez względu na to, czy układ rozwiążemy przez LU, czy przez QR, bo obie metody rozwiązują ten sam układ z tą samą macierzą  $A$ . Oba rozkłady są zresztą **stabilne numerycznie wstecznie** (obliczony wynik jest dokładnym

<sup>9</sup>**Macierz diagonalnie silnie dominująca** – jest to taka macierz, której każdy element diagonalny jest co do modułu większy od sumy modułów elementów pozadiagonalnych w danym wierszu:

$$|a_{m,m}| > \sum_{n=1, n \neq m}^N |a_{m,n}| \quad (71)$$

$$\text{Np. } B = \begin{bmatrix} 10 & 1 & 4 & 1 & 3 & 0 \\ 5 & 33 & 6 & 6 & -7 & 0 \\ -8 & -2 & -24 & 5 & 0 & 8 \\ 3 & -6 & 0 & 22 & -3 & 9 \\ 1 & 0 & -2 & 4 & 9 & 1 \\ 0 & -3 & 4 & 7 & 3 & 20 \end{bmatrix}$$

**Macierz diagonalnie słabo dominująca** – jest to taka macierz, której każdy element diagonalny jest co do modułu co najmniej równy sumie modułów elementów pozadiagonalnych w danym wierszu:

$$|a_{m,m}| \geq \sum_{n=1, n \neq m}^N |a_{m,n}| \quad (72)$$

Oraz przynajmniej jeden element diagonalny jest większy niż suma elementów pozadiagonalnych:

$$|a_{m,m}| > \sum_{n=1, n \neq m}^N |a_{m,n}| \quad (73)$$

$$\text{np. } A = \begin{bmatrix} 10 & 1 & 4 & 1 & 3 & 0 \\ 5 & 33 & 6 & 6 & -7 & 0 \\ -8 & -2 & -24 & 5 & 0 & 8 \\ 3 & -6 & 0 & 22 & -3 & 9 \\ 1 & 0 & -2 & 4 & 8 & 1 \\ 0 & -3 & 4 & 7 & 3 & 20 \end{bmatrix}$$




rozwiązaniem lekko zaburzonego układu). Pełne oszacowanie błędu uwzględnia jednak dodatkowo, ile błędu dokłada **sam algorytm** po drodze:


$$\frac{\|\Delta x\|}{\|x\|} \approx \text{cond}(\mathbf{A}) \cdot \rho_n \cdot \varepsilon_{\text{maszyny}} \quad (74)$$

gdzie  $\rho_n$  to tzw. **czynn timer wzrostu** (*growth factor*) – miara tego, jak bardzo metoda powiększa liczby w trakcie obliczeń (dla LU: stosunek największej wartości w macierzy  $\mathbf{U}$  do największej wartości w  $\mathbf{A}$ ; dla QR analogicznie dla  $\mathbf{R}$ ). Nie będziemy tu wchodzić w szczegóły dowodu – najważniejszy jest sam fakt: **to  $\rho_n$ , a nie  $\text{cond}(\mathbf{A})$ , jest tym, co różni LU od QR**, i to on stoi za częstym (i często źle rozumianym) twierdzeniem, że QR jest "stabilniejsze" od LU. Nie znaczy to, że QR zawsze daje mniejszy błąd: dla **LU**  $\rho_n$  zależy od konkretnej macierzy – w typowej praktyce jest mały (dla macierzy symetrycznych dodatnio określonych dowiedzione jest nawet  $\rho_n = 1$ ), ale w najgorszym przypadku (rzadkie, specjalnie skonstruowane macierze) może rosnać **wykładniczo**, aż do  $2^{n-1}$ , niezależnie od tego, jak dobre jest  $\text{cond}(\mathbf{A})$ . Dla **QR**  $\rho_n$  też nie jest stałe, ale jest **z góry dowodnie ograniczone** przez  $\sqrt{n}$  dla każdej możliwej macierzy – wzrost wykładniczy, możliwy przy LU, jest dla QR strukturalnie niemożliwy. Realna przewaga QR to więc gwarancja w najgorszym przypadku, a nie mniejszy błąd zawsze – na "zwyczajnych" macierzach (typowe dane inżynierskie) LU bywa w praktyce co najmniej tak dokładne jak QR, a czasem nawet dokładniejsze, bo QR wykonuje po drodze więcej działań arytmetycznych.

Zobaczymy to na dwóch wykresach błędu w funkcji rozmiaru układu  $n$ , dla tej samej pary metod (LU i QR) na dwóch różnych macierzach.



Dla macierzy Lehmera (symetrycznej dodatnio określonej)  $\rho_n = 1$  dla LU jest dowiedzione – LU i QR trzymają się więc razem oszacowania teoretycznego  $\text{cond}(\mathbf{A}) \cdot \varepsilon_{\text{maszyny}}$ , bez rozjeżdżania się.



Na macierzy zaprojektowanej specjalnie tak, by wystawić na próbę LU (same jedynki na diagonalu i w ostatniej kolumnie,  $-1$  poniżej diagonalu) obraz jest zupełnie inny:  $\text{cond}(\mathbf{A})$  pozostaje przez cały czas mały (rośnie od ok. 2 do ok. 27), a mimo to błąd LU eksploduje wykładniczo, aż do całkowitej bezużyteczności wyniku już przy  $n \approx 55-60$ . Błąd QR pozostaje przez cały ten czas na poziomie precyzji maszynowej. To dowód, że winowajcą nie jest tu uwarunkowanie problemu (identyczne dla obu metod), tylko sam algorytm LU – jego  $\rho_n$  eksplodowało wykładniczo, podczas gdy  $\rho_n$  dla QR pozostało ograniczone.

### PRZYPADEK GRANICZNY (MACIERZ OSOBLIWA)

Wszystkie dotychczasowe rozważania o uwarunkowaniu zakładały milcząco, że macierz  $\mathbf{A}$  w ogóle da się odwrócić – że układ ma dokładnie jedno rozwiązanie  $\mathbf{x}$ . Warto zatrzymać się na chwilę i zapytać, co się dzieje, kiedy to założenie przestaje być prawdziwe.

Macierz  $\mathbf{A}$  nazywamy **osobliwą**, jeśli jej wyznacznik wynosi zero ( $\det(\mathbf{A}) = 0$ ) – równoważnie: nie istnieje macierz odwrotna  $\mathbf{A}^{-1}$ . W takim przypadku układ  $\mathbf{Ax} = \mathbf{b}$  nie ma jednoznacznego rozwiązania – w zależności od konkretnego wektora  $\mathbf{b}$  albo nie ma żadnego rozwiązania, albo ma ich nieskończenie wiele – całą podprzestrzeń postaci

$$\{\mathbf{x} : \mathbf{Ax} = \mathbf{b}\} = \mathbf{x}_p + \ker(\mathbf{A}), \quad \ker(\mathbf{A}) = \{\mathbf{v} : \mathbf{Av} = \mathbf{0}\}, \quad (75)$$

gdzie  $\mathbf{x}_p$  to dowolne jedno (partykularne) rozwiązanie, a  $\ker(\mathbf{A})$  (**jądro** macierzy  $\mathbf{A}$ ) to podprzestrzeń wszystkich wektorów, które macierz  $\mathbf{A}$  przekształca w zero. Żadna metoda numeryczna, jakkolwiek dobra, tego nie naprawi – to nie jest problem numeryczny, tylko właściwość samego układu równań.<sup>10</sup>

Z punktu widzenia współczynnika uwarunkowania macierz osobliwa to przypadek graniczny:  $\text{cond}(\mathbf{A}) \rightarrow \infty$ , bo  $\mathbf{A}^{-1}$  w ogóle nie istnieje. Znacznie częściej niż ze ściśle osobliwą macierzą spotykamy się jednak w praktyce z sytuacją pośrednią – macierzą, która nie jest osobliwa (wyznacznik nie jest dokładnie zerem, odwrotność formalnie istnieje), ale jest jej **bardzo bliska** (wyznacznik bliski zeru,  $\text{cond}(\mathbf{A})$  ogromny). Taki układ formalnie ma jednoznaczne rozwiązanie, ale numerycznie jest praktycznie bezużyteczny – nawet najmniejszy błąd danych

<sup>10</sup>Prosty przykład: weźmy macierz  $\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$ . Drugi wiersz to dokładnie podwojony pierwszy, więc  $\det(\mathbf{A}) = 1 \cdot 4 - 2 \cdot 2 = 0$  – macierz

jest osobliwa. To, czy układ  $\mathbf{Ax} = \mathbf{b}$  ma jakiekolwiek rozwiązanie, zależy teraz wyłącznie od konkretnego wektora  $\mathbf{b}$ : dla  $\mathbf{b} = \begin{bmatrix} 1 \\ 3 \end{bmatrix}$  pierwsze równanie to  $x_1 + 2x_2 = 1$ , a podwojone daje  $2x_1 + 4x_2 = 2$  – tymczasem drugie równanie układu mówi  $2x_1 + 4x_2 = 3$ , czyli sprzeczność – układ **nie ma żadnego rozwiązania**. Za to dla  $\mathbf{b} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$  drugie równanie ( $2x_1 + 4x_2 = 2$ ) to dokładnie podwojone pierwsze – de facto mamy tylko jedno niezależne równanie na dwie niewiadome, więc układ ma **nieskończenie wiele rozwiązań**: każdy punkt spełniający  $x_1 + 2x_2 = 1$  (np.  $x_1 = 1, x_2 = 0$  albo  $x_1 = -1, x_2 = 1$ ).

wejściowych (albo sam błąd reprezentacji liczb w komputerze) zostaje tak silnie wzmocniony przez  $\text{cond}(\mathbf{A})$ , że obliczone rozwiązanie może nie mieć nic wspólnego z prawdziwym.

Dlatego w praktyce ogromna wartość  $\text{cond}(\mathbf{A})$  jest sygnałem ostrzegawczym – warto go zawsze sprawdzić, zanim zaufa się obliczonemu wynikowi.

### TESTOWE UKŁADY RÓWNAŃ

Ponieważ uwarunkowanie numeryczne układu równań wynika tylko z jego macierzy  $\mathbf{A}$  do testów nowych metod numerycznych stworzono wzorce do budowania nowych macierzy  $\mathbf{A}$  o coraz większych rozmiarach mające tę właściwość, że szybko, wraz ze wzrostem wielkości tej macierzy (liczby równań układu), wzrasta (pogarsza się), współczynnik uwarunkowania. Są to macierze:

- Macierz Vandermonda

Rozpina się ją na wektorze początkowym i ma postać:

$$\mathbf{A} = \begin{pmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^{n-1} \\ 1 & x_2 & x_2^2 & \cdots & x_2^{n-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^{n-1} \end{pmatrix} \quad (76)$$

Przykładowo np. rozpięta na wektorze  $\mathbf{x}=[1 \ 2 \ 3 \ 4]$

$$\mathbf{A} = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & 2 & 4 & 8 \\ 1 & 3 & 9 & 27 \\ 1 & 4 & 16 & 64 \end{bmatrix} \quad (77)$$

- Macierz Hilberta

Zdefiniowana jako:

$$h_{i,j} = \frac{1}{i+j-1} \quad (78)$$

Np.

$$\mathbf{H} = \begin{bmatrix} 1 & \frac{1}{2} & \frac{1}{3} & \frac{1}{4} & \frac{1}{5} \\ \frac{1}{2} & \frac{1}{3} & \frac{1}{4} & \frac{1}{5} & \frac{1}{6} \\ \frac{1}{3} & \frac{1}{4} & \frac{1}{5} & \frac{1}{6} & \frac{1}{7} \\ \frac{1}{4} & \frac{1}{5} & \frac{1}{6} & \frac{1}{7} & \frac{1}{8} \\ \frac{1}{5} & \frac{1}{6} & \frac{1}{7} & \frac{1}{8} & \frac{1}{9} \end{bmatrix} \quad (79)$$

### NAJWAŻNIEJSZE INFORMACJE ROZDZIAŁU

- Przyczyny i skutki problemu złego uwarunkowania
- Sposób zależności błędu rozwiązania od danych i rozmiaru problemu
- Definicja i zastosowanie współczynnika uwarunkowania – współczynnik uwarunkowania pozwala nam oszacować błąd rozwiązania układu równań liniowych przed jego rozwiązaniem. Dzięki temu możemy zmodyfikować ten układ tak, żeby miał lepsze właściwości (np. podobnie jak w metodzie Gaussa)

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\text{cond}(\mathbf{A}) \frac{\|\Delta \mathbf{A}\|}{\|\mathbf{A}\|}}{1 - \text{cond}(\mathbf{A}) \frac{\|\Delta \mathbf{A}\|}{\|\mathbf{A}\|}} \quad (80)$$

- Sposób szacowania błędu rozwiązania przy pomocy współczynnika uwarunkowania

- **Czynnik wzrostu** ( $\rho_n$ ) – pełne oszacowanie błędu to  $\text{cond}(\mathbf{A}) \cdot \rho_n \cdot \varepsilon_{\text{maszynny}}$ , nie sam  $\text{cond}(\mathbf{A}) \cdot \varepsilon_{\text{maszynny}}$ ; to  $\rho_n$ , nie  $\text{cond}(\mathbf{A})$ , jest tym, co różni LU od QR (dla LU zależy od macierzy, w skrajnym przypadku rośnie wykładniczo; dla QR jest zawsze ograniczone) – pełne wyjaśnienie w rozdziale o rozkładzie QR
- Macierze Vandermonda i Hilberta są to macierze o niekorzystnych uwarunkowaniach numerycznych, dlatego dobrze nadają się jako dane testowe do analizy właściwości poszczególnych metod.
- Macierz **osobliwa** ( $\det(\mathbf{A}) = 0$ ) oznacza brak jednoznacznego rozwiązania (brak rozwiązania albo nieskończenie wiele) – to nie da się naprawić żadną metodą numeryczną. Macierz bliska osobliwej (ogromny  $\text{cond}(\mathbf{A})$ ) formalnie ma jednoznaczne rozwiązanie, ale numerycznie jest ono niewiarygodne – warto zawsze sprawdzić  $\text{cond}(\mathbf{A})$  przed zaufaniem wynikowi.

## ITERACYJNE METODY ROZWIĄZYWANIA UKŁADÓW RÓWNAŃ LINIOWYCH

Jak pamiętamy każda metoda iteracyjna jest w swojej istocie sposobem na zamianę ilości obliczeń (złożoności) na dokładność. Dlatego też problem uwarunkowania numerycznego układu równań liniowych w odniesieniu do metod numerycznych traci na znaczeniu – zawsze możemy wykonać więcej iteracji i zwiększyć dokładność o ile metoda jest zbieżna. W przypadku metod iteracyjnych nie pytamy jak błąd danych wejściowych wpływa na wynik, tylko ile iteracji będziemy musieli zrobić, żeby uzyskać dostatecznie dokładne rozwiązanie? Ponadto na podstawie przeprowadzonej analizy ogólnej metod iteracyjnych dodajemy pytanie – dla jakich danych metoda będzie zbieżna? Czyli interesują nas głównie parametry zbieżności tych metod.

Podobnie jak w przypadku metod algebraicznych i dokładności rozwiązania, zbieżność metod iteracyjnych jest również silnie związana z danymi liczbowymi opisującymi dany układ równań. Rozpocniemy więc od informacji natury ogólnej – powiemy sobie w jakich sytuacjach metoda iteracyjna jest zbieżna w ogóle. Wadą metod iteracyjnych jest bowiem to, że niekoniecznie są zbieżne dla dowolnych układów równań.

## POSTAĆ OGÓLNA METOD ITERACYJNYCH I ICH WARUNKI ZBIEŻNOŚCI

Postać kanoniczna układu równań liniowych wygląda następująco:

$$\mathbf{Ax} = \mathbf{b} \quad (81)$$

Natomiast każda metoda iteracyjna opisana jest wzorem iteracyjnym o postaci ogólnej:

$$\mathbf{y}_{i+1} = \phi_i(\mathbf{y}_i, \mathbf{y}_{i-1}, \dots; \mathbf{x}) \quad (82)$$

W przypadku metod iteracyjnych rozwiązywania układów równań liniowych ogólna postać wzoru iteracyjnego wygląda następująco:

$$\mathbf{x}^{(i+1)} = \mathbf{M}\mathbf{x}^{(i)} + \mathbf{w}$$

Wszystkie elementy tego wzoru są macierzami lub wektorami. Przez oznaczenie  $\mathbf{x}^{(i)}$  rozumiem wartość danej wielkości w  $i$ -tej iteracji. Poszczególne metody różnią się między sobą:

- Sposobem w jaki tworzone są macierz  $\mathbf{M}$  i wektor  $\mathbf{w}$  – to definiuje metodę
- Budową i właściwościami macierzy  $\mathbf{M}$  dla jakich dana metoda jest zbieżna
- Szybkością zbieżności

Ogólnie jednak każda metoda iteracyjna jest zbieżna jeżeli promień spektralny macierzy  $\mathbf{M}$  stworzonej wg opisu danej metody jest mniejszy od jedności<sup>11</sup>:

$$\rho(\mathbf{M}) < 1 \quad (84)$$

Jest to warunek konieczny i wystarczający zbieżności. Dodatkowo jak w przypadku każdej metody iteracyjnej spełniony musi być warunek zgodności:

$$\dot{\mathbf{x}} = \mathbf{M}\dot{\mathbf{x}} + \mathbf{w} \quad (85)$$

<sup>11</sup>Promień spektralny macierzy jest to wartość bezwzględna największej wartości własnej. Oznaczamy go jako  $\rho(\mathbf{A})$

$$\rho(\mathbf{A}) = \{\max(|\lambda|) \mid \lambda \in \text{Spect}(\mathbf{A})\} \quad (83)$$

Zbiór wszystkich wartości własnych macierzy  $\mathbf{A}$  nazywamy spektrum  $\mathbf{A}$  –  $\text{Spect}(\mathbf{A})$

gdzie  $\mathbf{x}$  oznacza wartości dokładne.

Szybkość zbieżności jest tym większa im mniejszy jest promień spektralny macierzy.

## METODA JAKOBIEGO

Metoda Jakobiego jest najprostszą metodą iteracyjną. Brak jej dodatkowych cech wbudowanych w działanie wpływających na szybkość zbieżności, dlatego zazwyczaj jest najwolniej zbieżna ze wszystkich metod o jakich będziemy mówić, ale jej zaletą jest stosunkowo najszerszy zakres danych dla jakich jest zbieżna – nakłada najmniejsze wymagania na budowę i postać macierzy  $\mathbf{A}$ .

W metodzie Jakobiego macierz  $\mathbf{M}$  i wektor  $\mathbf{w}$  otrzymujemy następująco:

$$\mathbf{Ax} = \mathbf{b} \quad (86)$$

Macierz  $\mathbf{A}$  oryginalnego układu równań jest rozkładana na sumę macierzy:

$$\mathbf{A} = \mathbf{L} + \mathbf{D} + \mathbf{U} \quad (87)$$

gdzie:  $\mathbf{L}$  – macierz trójkątna dolna,  $\mathbf{U}$  – macierz trójkątna górna,  $\mathbf{D}$  – macierz diagonalna  
następnie wzór iteracyjny otrzymuje się w drodze następujących przekształceń:

$$\mathbf{Dx} = -(\mathbf{L} + \mathbf{U})\mathbf{x} + \mathbf{b} \quad (88)$$

$$\mathbf{x} = -\mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})\mathbf{x} + \mathbf{D}^{-1}\mathbf{b} \quad (89)$$

---


$$\mathbf{x}^{(i+1)} = -\mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})\mathbf{x}^{(i)} + \mathbf{D}^{-1}\mathbf{b} \quad (90)$$


---

W konsekwencji:

$$\mathbf{M} = -\mathbf{D}^{-1}(\mathbf{L} + \mathbf{U}) \quad (91)$$

$$\mathbf{w} = \mathbf{D}^{-1}\mathbf{b} \quad (92)$$

Warunkiem koniecznym i wystarczającym zbieżności tego procesu iteracyjnego jest, aby macierz  $\mathbf{A}$  była nieredukowalna i co najmniej diagonalnie słabo dominująca<sup>12</sup>.

## METODA RICHARDSONA

Metoda Richardsona jest rodzajem metody w której wprowadzony jest specjalny współczynnik  $p$ , mający wpływ na szybkość zbieżności. W konsekwencji poprzez optymalny dobór wielkości tego współczynnika można zredukować ilość obliczeń, co przy dużych układach równań ma istotne znaczenie. Okupione jest to jednak po pierwsze zwiększeniem wymagań dotyczących danych wejściowych, dla których metoda jest zbieżna, po drugie dodatkowym problemem doboru wartości tego współczynnika.

Wzór iteracyjny tej metody powstaje w następujący sposób:

$$\mathbf{Ax} = \mathbf{b} \quad (94)$$

$$p\mathbf{Ax} = p\mathbf{b} \quad (95)$$

$$\mathbf{x} - \mathbf{x} + p\mathbf{Ax} = p\mathbf{b} \quad (96)$$

$$\mathbf{x} = \mathbf{Ix} - p\mathbf{Ax} + p\mathbf{b} \quad (97)$$

---

<sup>12</sup>Macierz redukowalna – jest to taka macierz, dla której istnieje macierz permutacji  $\mathbf{P}$  taka, że:

$$\mathbf{P}^{-1}\mathbf{AP} = \begin{bmatrix} \mathbf{A}_{1,1} & \mathbf{A}_{1,2} \\ 0 & \mathbf{A}_{1,3} \end{bmatrix} \quad (93)$$

---


$$\mathbf{x}^{(i+1)} = (\mathbf{I} - \mathbf{pA})\mathbf{x}^{(i)} + \mathbf{pb} \quad (98)$$


---

W konsekwencji:

$$\mathbf{M} = \mathbf{I} - \mathbf{pA} \quad (99)$$

$$\mathbf{w} = \mathbf{pb} \quad (100)$$

Zamiast mówić o tym dla jakich danych metoda jest w ogóle zbieżna mówi się raczej o tym dla jakich układów danych wejściowych potrafimy dobrać odpowiednio współczynnik  $p$ . Potrafimy to zrobić tylko dla niektórych rodzajów układów choć, zakres zbieżności tej metody jest większy niż tylko one, ale nieznane są sposoby określania optymalnej wartości współczynnika  $p$ .

Parametr  $p$  oczywiście dobiera się tak, żeby promień spektralny macierzy  $\mathbf{M}$  był jak najmniejszy. Przykładowo:

Jeżeli macierz  $\mathbf{A}$  ma rzeczywiste wartości własne tego samego znaku (jest np. macierzą symetryczną dodatnio określoną), to promień spektralny macierzy jest najmniejszy, gdy

$$p = \frac{2}{\lambda_{\min} + \lambda_{\max}} \quad (101)$$

Natomiast dla macierzy symetrycznych zachodzi warunek:

$$\left| \frac{\lambda_{\max}}{\lambda_{\min}} \right| = \text{cond}(\mathbf{A}) \quad (102)$$

więc:

$$\rho(\mathbf{I} - \mathbf{pA}) = \frac{\text{cond}(\mathbf{A}) - 1}{\text{cond}(\mathbf{A}) + 1} \quad (103)$$

Metodę Richardsona ogólnie stosuje się tam, gdzie spodziewamy się układów równań o budowie znanej i kompatybilnej ze znanymi rozwiązaniami tego problemu. Głównie jako element większych, bardziej skomplikowanych metod numerycznych.

## METODA GAUSSA-SEIDLA

Metoda Gaussa-Seidla jest wariacją metody Jakobiego zbudowaną w taki sposób, aby w swoim działaniu mieć wbudowane przyspieszanie zbieżności. Wzór iteracyjny tej metody powstaje w następujący sposób. Początek jest podobny jak w metodzie Jakobiego:

Macierz  $\mathbf{A}$  oryginalnego układu równań jest rozkładana na sumę macierzy:

$$\mathbf{A} = \mathbf{L} + \mathbf{D} + \mathbf{U} \quad (104)$$

gdzie:  $\mathbf{L}$ -macierz trójkątna dolna,  $\mathbf{U}$  - macierz trójkątna górna,  $\mathbf{D}$  - macierz diagonalna  
następnie:

$$(\mathbf{L} + \mathbf{D})\mathbf{x} = -\mathbf{Ux} + \mathbf{b} \quad (105)$$

$$\mathbf{Dx}^{(i+1)} = -\mathbf{Lx}^{(i+1)} - \mathbf{Ux}^{(i)} + \mathbf{b} \quad (106)$$

---


$$\mathbf{x}^{(i+1)} = -\mathbf{D}^{-1}\mathbf{Lx}^{(i+1)} - \mathbf{D}^{-1}\mathbf{Ux}^{(i)} + \mathbf{D}^{-1}\mathbf{b} \quad (107)$$


---

To co może dziwić to fakt, że we wzorze iteracyjnym element  $\mathbf{x}^{(i+1)}$  występuje po obu stronach równania. Przyspieszanie szybkości zbieżności polega na tym, że w trakcie obliczeń kolejnych nowych przybliżeń wektora  $\mathbf{x}$ :  $x_1, x_2, x_3$  itd. Bierzymy te wartości z nowej iteracji, które znamy. Można to zapisać następująco:

$$x_m^{(i+1)} = -\frac{1}{a_{mm}} \left( \sum_{n=1}^{m-1} a_{mn}x_n^{(i+1)} + \sum_{n=m+1}^N a_{mn}x_n^{(i)} - b_m \right) \quad i = 0, 1, \dots, N \quad (108)$$

**PRZYKŁADOWO**

Niech jednym z równań będzie równanie:

$$14x_1 + 5x_2 - 8x_3 + 2x_4 = 22 \quad (109)$$

W i-tej iteracji uzyskujemy wynik (wektorowo)  $\mathbf{x}^{(i)}$ :

$$14x_1^{(i)} + 5x_2^{(i)} - 8x_3^{(i)} + 2x_4^{(i)} = 22 \quad (110)$$

Teraz nasz wektor  $\mathbf{x}^{(i+1)}$  nie jest już pusty i wygląda tak:

$$\mathbf{x}^{(i+1)} = [x_1^{(i+1)} \ 0 \ 0 \ 0] \quad (111)$$

Zatem przy wyliczaniu  $x_2^{(i+1)}$  można już uwzględnić obliczoną wartość  $x_1^{(i+1)}$

$$x_2^{(i+1)} = -\frac{1}{a_{1,1}} \left( \sum_{n=1}^1 a_{2,n} x_n^{(i+1)} + \sum_{n=2}^4 a_{2,n} x_n^{(i)} - b_2 \right) \quad (112)$$

I tak dalej...

Metoda ta jest zbieżna, między innymi, dla macierzy nieredukowalnych i diagonalnie słabo dominujących oraz dla macierzy symetrycznych dodatnio określonych<sup>13</sup>.

**METODA SUKCESYWNEJ NADRELAKSACJI (SOR)**

Ostatnia metoda jaką poznamy jest najczęściej implementowana. Jest to rozwinięcie metody Gaussa-Seidla – zatem ogólnie pomysł jest taki sam jak poprzednio. Dodany jest jednak parametr  $\omega$ :

$$\mathbf{D}\mathbf{x}^{(i+1)} = (1 - \omega)\mathbf{D}\mathbf{x}^{(i)} - \omega(\mathbf{L}\mathbf{x}^{(i+1)} + \mathbf{U}\mathbf{x}^{(i)} - \mathbf{b}) \quad (114)$$

$$x_m^{(i+1)} = -\frac{\omega}{a_{mm}} \left( \sum_{n=1}^{m-1} a_{mn} x_n^{(i+1)} + \sum_{n=m}^N a_{mn} x_n^{(i)} - b_m \right) \quad i = 0, 1, \dots, N \quad (115)$$

W metodzie tej:

$$\mathbf{M} = (\mathbf{D} + \omega\mathbf{L})^{-1}((1 - \omega)\mathbf{D} - \omega\mathbf{U}) \quad (116)$$

$$\mathbf{w} = \omega(\mathbf{D} + \omega\mathbf{L})^{-1}\mathbf{b} \quad (117)$$

Parametr został dodany w tym samym celu jak w metodzie Richardsona – wpływa (i to silnie!) na szybkość zbieżności, można bowiem udowodnić, że:

$$\rho(\mathbf{M}) \geq |\omega - 1| \quad (118)$$

dla dowolnej nieosobliwej macierzy  $\mathbf{A}$  i dowolnej liczby  $\omega$ . Aby metoda SOR była zbieżna parametr  $\omega$  musi przyjmować wartość z przedziału (0,2):

$$\rho(\mathbf{M}) \geq |\omega - 1| \quad (119)$$

oraz z warunku zbieżności:

$$\rho(\mathbf{M}) < 1 \quad (120)$$

stąd jeżeli  $\omega > 2$  to  $|\omega - 1| > 1 \rightarrow \rho(\mathbf{M}) \geq 1$

Natomiast nieznan jest ogólny wzór na dobór optymalnej wartości  $\omega$ . Wiemy, że:

<sup>13</sup>Macierz dodatnio określona – jest to taka macierz, która dla każdego rzeczywistego wektora  $\mathbf{x}$  spełnia równanie:

$$\mathbf{x}^T \mathbf{A} \mathbf{x} > 0 \quad (113)$$



Jeżeli macierz **A** jest symetryczna i dodatnio określona, to metoda ta jest zbieżna dla dowolnej wartości  $\omega \in (0, 2)$

Jeżeli macierz **A** jest symetryczna, dodatnio określona i ma własność A wartość optymalna jest równa:

$$\omega_{opt} = 2 / \left( 1 + \sqrt{1 - \lambda_{\max}^2} \right) \quad (121)$$

gdzie  $\lambda_{\max}$  jest wartością własną macierzy  $\mathbf{D}^{-1}(\mathbf{L}+\mathbf{U})$

Metody Jakobiego, Gaussa-Seidla i SOR, które tu poznaliśmy, są też fundamentem, na którym budowane są bardziej zaawansowane metody iteracyjne stosowane w praktyce do naprawdę dużych układów równań – tzw. **metody Kryłowa**, takie jak metoda gradientów sprzężonych (CG, dla macierzy symetrycznych dodatnio określonych) czy GMRES (dla macierzy ogólnych) – np. jako tzw. *smoothers* w metodach wielosiatkowych albo jako prekondycjonery przyspieszające ich zbieżność.

## MAPA DECYZYJNA – JAK WYBRAĆ METODĘ

Poznaliśmy już kilka metod rozwiązywania układów równań liniowych – eliminację Gaussa, rozkłady LU i QR oraz metody iteracyjne (Jakobiego, Gaussa-Seidla, SOR). Czas zebrać rozproszone dotąd po tekście wskazówki w jeden spójny schemat wyboru. Pytania, które warto sobie zadać, to: jak duży (i czy rzadki) jest układ, czy trzeba go rozwiązać wielokrotnie z różnymi wymuszeniami **b**, oraz jak dobre jest jego uwarunkowanie.

| Sytuacja                                                                                                                              | Zalecana metoda                                   | Dlaczego                                                                                                                                                                                                                                                                            |
|---------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Mały/średni układ, rozwiązywany raz                                                                                                   | Eliminacja Gaussa (z pivotowaniem)                | Najprostsza, wystarczająco dokładna dla jednorazowego rozwiązania                                                                                                                                                                                                                   |
| Ten sam układ <b>A</b> , wiele różnych <b>b</b> (np. symulacja z wieloma wymuszeniami)                                                | Rozkład LU ( $\mathbf{PA} = \mathbf{LU}$ )        | Koszt rozkładu ( $O(n^3)$ ) ponosimy raz, każde kolejne rozwiązanie kosztuje tylko $O(n^2)$                                                                                                                                                                                         |
| Układ prostokątny/nadokreślony (zadanie najmniejszych kwadratów), albo brak pewności co do stabilności LU dla danej macierzy <b>A</b> | Rozkład QR                                        | Jedyna z tych metod działająca też dla macierzy prostokątnych; gwarantowana stabilność numeryczna niezależna od konkretnej macierzy <b>A</b> (patrz zastrzeżenie niżej – to <b>nie</b> to samo, co mniejszy błąd przy dużym $\text{cond}(\mathbf{A})$ ), kosztem droższego rozkładu |
| Duży, rzadki układ (np. z MES, różnic skończonych)                                                                                    | Metody iteracyjne (Jakobiego, Gaussa-Seidla, SOR) | Gęsta reprezentacja fizycznie nie mieści się w pamięci – metody iteracyjne wykorzystują rzadkość macierzy zamiast ją niszczyć                                                                                                                                                       |

Ważne zastrzeżenie: metody iteracyjne nie są uniwersalne – wymagają, żeby macierz **A** spełniała określone warunki zbieżności (np. dominacja diagonalna, symetryczność i dodatnia określoność). Jeśli te warunki nie są spełnione, metoda może w ogóle nie zbiegać do rozwiązania, niezależnie od liczby wykonanych iteracji.

Warto też wspomnieć o jednym szczególnym przypadku: jeśli macierz **A** jest symetryczna i dodatnio określona (SPD), dużo bardziej efektywny niż ogólny rozkład LU jest **rozkład Choleskyego** – wykorzystuje symetrię macierzy, żeby policzyć rozkład około dwukrotnie taniej; nie będziemy się nim szczegółowo zajmować na tym wykładzie, ale warto wiedzieć, że istnieje, i kiedy sięgnąć po niego samodzielnie.

## NAJWAŻNIEJSZE INFORMACJE ROZDZIAŁU

- Jakie są warunki zbieżności metod iteracyjnych rozwiązywania układów równań liniowych

$$\rho(\mathbf{M}) < 1 \quad (122)$$

- Świadomość ograniczeń metod iteracyjnych w ogóle i poszczególnych metod osobno
- Sposoby przyspieszania zbieżności metod iteracyjnych
  - Metoda Richardsona -> wprowadzenie parametru  $p$  pozwalającego na sterowanie szybkością zbieżności
  - Metoda SOR -> wprowadzenie parametru  $\omega$

- Jakobiego, Gaussa-Seidla i SOR to fundament dla bardziej zaawansowanych metod iteracyjnych używanych w praktyce (**metody Kryłowa** – CG, GMRES)
- **Mapa decyzyjna wyboru metody:** Gauss dla jednorazowego rozwiązania małego/średniego układu, LU dla wielu wymuszeń  $\mathbf{b}$  przy tej samej  $\mathbf{A}$ , QR dla układów prostokątnych/MNK albo gdy stabilność LU jest niepewna (uwaga: to kwestia growth factor metody, nie samego  $\text{cond}(\mathbf{A})$  problemu), metody iteracyjne dla dużych rzadkich układów (o ile spełnione są warunki zbieżności); dla macierzy SPD osobny, tańszy rozkład Choleskyego

## LINIOWE ZADANIE NAJMNIEJSZYCH KWADRATÓW

### Materiał dodatkowy.


Liniowe zadanie najmniejszych kwadratów (LZNK) nie jest *stricte* metodą rozwiązywania układów równań liniowych, choć jest z tym zagadnieniem ściśle powiązane – w praktyce służy do rozwiązywania układów **nadokreślonych**, czyli takich, w których równań jest więcej niż niewiadomych. Jest to najprostszy i najczęściej spotykany przypadek szerszego problemu numerycznego zwanego **regresją** (dokładniej: regresją liniową, pod którą to nazwą LZNK najczęściej występuje w praktyce). O samej regresji w ogólności nie będziemy tu mówić – wrócimy do niej przy okazji aproksymacji.

### PRZYKŁAD: KALIBRACJA CZUJNIKA

Rozważmy typowy problem inżynierski. Mamy prosty czujnik, którego napięcie wyjściowe  $U$  chcemy przeliczać na temperaturę  $T$ . Zakładamy, że w interesującym nas zakresie charakterystyka czujnika jest w przybliżeniu liniowa:

$$T \approx aU + b \quad (123)$$

Współczynniki  $a$  i  $b$  nie są jednak znane – żeby je wyznaczyć, wykonujemy serię pomiarów: dla kilku wartości napięcia  $U$  mierzymy odpowiadającą mu temperaturę  $T$  wzorcowym termometrem. W naszym przykładzie mamy  $M = 7$  takich pomiarów:




Gdyby czujnik był idealnie liniowy, a pomiar bezbłędny, każdy punkt  $(U_i, T_i)$  spełniałby dokładnie  $aU_i + b = T_i$ . Zapisując to dla wszystkich siedmiu pomiarów, dostajemy układ równań liniowych o dwóch niewiadomych ( $a$  i  $b$ ):

$$\begin{cases} aU_1 + b = T_1 \\ \vdots \\ aU_7 + b = T_7 \end{cases} \quad (124)$$

Mamy tu **7 równań i tylko 2 niewiadome** – układ jest nadokreślony i (poza wyjątkowym przypadkiem, w którym wszystkie punkty leżałyby idealnie na jednej prostej) nie ma rozwiązania spełniającego wszystkie

równania naraz. To normalny stan rzeczy – pomiary zawsze są obarczone pewnym szumem. Zamiast szukać (nieistniejącego) dokładnego rozwiązania, LZNK szuka takiej prostej, która pasuje do wszystkich punktów *możliwie najlepiej* – czyli minimalizuje sumę kwadratów odchyłeń między pomiarami a prostą. Te odchylenia nazywamy **residuumi**; zaznaczono je poniżej na zielono:



## OGÓLNA DEFINICJA LZNK

Powyższy przykład uogólniamy teraz na dowolny układ nadokreślony. Ogólnie LZNK jest zdefiniowane następująco:

1. Dla układu nadokreślonego

$$\mathbf{A} \in \mathbb{R}^{M \times N} \quad i \quad M > N \quad (125)$$

2. Znajdź takie rozwiązanie, które minimalizuje normę residuów (używamy normy 2):

$$\|\Delta \mathbf{x}\|_2 = \|\mathbf{b} - \mathbf{Ax}^*\|_2 = \inf \{ \|\mathbf{b} - \mathbf{Ax}\|_2 \mid \mathbf{x} \in \mathbb{R}^N \} \quad (126)$$

gdzie  $\mathbf{b} - \mathbf{Ax}^*$  to wektor błędu (residuów).

W naszym przykładzie kalibracji  $\mathbf{A}$  to macierz  $7 \times 2$  (kolumna napięć  $U$  i kolumna jedynek dla wyrazu wolnego),  $\mathbf{b}$  to wektor siedmiu zmierzonych temperatur  $T$ , a szukany wektor niewiadomych to  $\mathbf{x} = [a, b]^T$ .

Liniowe zadanie najmniejszych kwadratów jest uogólnieniem problemu rozwiązywania układów równań liniowych, i w przypadku, kiedy macierz  $\mathbf{A}^{N \times N}$  jest macierzą kwadratową (układ jest poprawnie określony), powyższe równanie sprowadza się do:

$$\mathbf{x} = \mathbf{A}^{-1} \mathbf{b} \quad (127)$$

a wartość normy wektora błędu dąży do 0 (rozwiązanie jest dokładne).

Popularne metody rozwiązania LZNK starają się iść tropem powyższego równania – będą starały się stworzyć tzw. macierz pseudoodwrotną<sup>14</sup>. W ogólnym przypadku macierz ta nie jest macierzą kwadratową, ale pod wszystkimi praktycznymi względami będziemy się nią posługiwać jak macierzą odwrotną, a rozwiązanie LZNK ma wtedy postać:

$$\mathbf{x}^* = \mathbf{A}^+ \mathbf{b} \quad (128)$$

Obliczenie pseudoodwrotności ma ważne znaczenie praktyczne – nie jest bowiem w ogólnym przypadku źle uwarunkowane. Odpadają więc wszystkie problemy poznane wcześniej. Obliczenie pseudoodwrotności może stać się problemem źle uwarunkowanym w momencie, kiedy kształt macierzy  $\mathbf{A}$  dąży do macierzy kwadratowej

<sup>14</sup>Dokładniej macierz pseudoodwrotną w sensie Penrosa-Moora, którą będziemy oznaczać jako  $\mathbf{A}^+$

(a pseudoodwrotność dąży do odwrotności). Nawet wtedy jednak zastosowanie metod opracowanych w celu obliczania pseudoodwrotności daje najlepsze wyniki pod względem minimalizacji efektu uwarunkowania numerycznego.

W praktyce rzadko obliczamy macierz pseudoodwrotną  $A^+$  jawnie – potrzebujemy tylko samego rozwiązania  $x^*$ , a prowadzą do niego dwie drogi, które już znamy z wcześniejszych rozdziałów: **równania normalne** albo **rozkład QR**.

## ROZWIĄZANIE PRZEZ RÓWNIANIA NORMALNE

Najprostszym podejściem jest bezpośrednie rozwiązanie tzw. **równań normalnych**:

$$A^T A x^* = A^T b \quad (129)$$

Tym będziemy się zajmować bardziej szczegółowo przy okazji omawiania interpolacji i aproksymacji.

Macierz  $A^T A$  jest kwadratowa ( $N \times N$ ) i symetryczna, więc powyższy układ można rozwiązać dowolną z poznanych metod algebraicznych (np. eliminacją Gaussa albo rozkładem LU). Wygląda to na najprostsze możliwe rozwiązanie problemu – i faktycznie bywa stosowane w praktyce – ale ma poważną wadę numeryczną: tworząc iloczyn  $A^T A$  psujemy uwarunkowanie numeryczne problemu. Zachodzi bowiem zależność:

$$\text{cond}(A^T A) = \text{cond}(A)^2 \quad (130)$$

Oznacza to, że jeżeli macierz  $A$  była już niedoskonale uwarunkowana (a w praktyce zwykle jest), to macierz  $A^T A$  ma współczynnik uwarunkowania podniesiony do kwadratu – błąd rozwiązania może więc być znacznie większy niż wynikałoby to z samego uwarunkowania  $A$ . To bezpośrednie nawiązanie do rozdziału o współczynniku uwarunkowania: metoda równań normalnych jest prosta koncepcyjnie, ale w praktyce zalecana tylko dla dobrze uwarunkowanych macierzy  $A$ .

Wróćmy do przykładu kalibracji czujnika. Podstawiając nasze dane do wzoru na równania normalne, dostajemy:

$$A^T A = \begin{bmatrix} 47,31 & 15,70 \\ 15,70 & 7,00 \end{bmatrix} \quad A^T b = \begin{bmatrix} 998,79 \\ 338,54 \end{bmatrix} \quad (131)$$

Rozwiązanie tego (już kwadratowego) układu daje  $x^* = [a, b]^T \approx [19,80, 3,96]^T$  – dokładnie te same współczynniki, które widać na dopasowanej prostej na wykresie wyżej. Dla naszych danych  $\text{cond}(A) \approx 5,73$ , a  $\text{cond}(A^T A) \approx 32,80 = \text{cond}(A)^2$  – w tym niewielkim, dobrze uwarunkowanym przykładzie różnica jest nieszkodliwa, ale przy gorzej uwarunkowanych danych (np. punktach pomiarowych leżących blisko siebie albo dopasowywaniu wielomianu wysokiego stopnia) mogłaby już realnie zaszkodzić dokładności wyniku.

## ROZWIĄZANIE PRZEZ ROZKŁAD QR

Znacznie bezpieczniejszym numerycznie podejściem jest wykorzystanie już poznanego rozkładu QR. Dla macierzy nadokreślonej  $A$  ( $M > N$ ) stosujemy tzw. **ekonomiczny rozkład QR**: zamiast pełnej macierzy ortogonalnej  $Q^{M \times M}$ , wyznaczamy tylko jej pierwsze  $N$  kolumn – macierz  $Q_1^{M \times N}$  o ortonormalnych kolumnach – oraz kwadratową macierz trójkątną górną  $R^{N \times N}$ , takie że:

$$A = Q_1 R \quad (132)$$

Korzystając z ortogonalności  $Q_1$  ( $Q_1^T Q_1 = I$ ) można pokazać, że minimalizacja normy residuów sprowadza się do rozwiązania układu z macierzą trójkątną:

$$R x^* = Q_1^T b \quad (133)$$

czyli dokładnie tego samego trywialnego kroku „wewnętrzny”, który znamy już z rozkładu QR dla układów kwadratowych. Ponieważ rozkład QR nie wprowadza dodatkowego pogorszenia uwarunkowania (w przeciwieństwie do tworzenia  $A^T A$ ), jest to metoda preferowana w praktycznych implementacjach LZNK – kosztem nieco droższego samego rozkładu.

Dla naszej macierzy  $A$  ( $7 \times 2$ ) ekonomiczny rozkład QR daje:

$$R = \begin{bmatrix} -6,88 & -2,28 \\ 0 & -1,34 \end{bmatrix} \quad Q_1^T b = \begin{bmatrix} -145,21 \\ -5,30 \end{bmatrix} \quad (134)$$

Rozwiązanie układu  $R\mathbf{x}^* = Q_1^T \mathbf{b}$  daje  $\mathbf{x}^* \approx [19,80, 3,96]^T$  – dokładnie te same współczynniki co przez równania normalne. Inaczej być nie mogło – to wciąż to samo zadanie, tylko rozwiązane inną, bezpieczniejszą numerycznie drogą.

#### NAJWAŻNIEJSZE INFORMACJE ROZDZIAŁU

- Definicja i zastosowanie LZNK – rozwiązywanie nadokreślonych układów równań (więcej równań niż niewiadomych) poprzez minimalizację normy residuów; typowy przykład: dopasowanie prostej do zaszumionych pomiarów (regresja liniowa, np. kalibracja czujnika)
- Rozwiązanie LZNK przez macierz pseudoodwrotną:  $\mathbf{x}^* = \mathbf{A}^+ \mathbf{b}$ , ale w praktyce liczymy je pośrednio, jednym z dwóch sposobów:
  - **równania normalne** –  $\mathbf{A}^T \mathbf{A} \mathbf{x}^* = \mathbf{A}^T \mathbf{b}$ , proste, ale  $\text{cond}(\mathbf{A}^T \mathbf{A}) = \text{cond}(\mathbf{A})^2$  – niebezpieczne numerycznie dla gorzej uwarunkowanych  $\mathbf{A}$ ,
  - **cieńki rozkład QR** –  $R\mathbf{x}^* = Q_1^T \mathbf{b}$ , bezpieczniejszy numerycznie, preferowany w praktyce.