

UKŁADY RÓWNAŃ LINIOWYCH

**Wstęp do metod numerycznych
(WNUM)**



RÓŻNE POSTACIE UKŁADU RÓWNAŃ LINIOWYCH – POSTAĆ KANONICZNA


Klasyczny „szkolny” układ równań zapisujemy w postaci:

$$\begin{cases} 8x_1 + 8x_2 + 2x_3 = 10 \\ -2x_1 + 2x_2 + 10x_3 = 12 \\ 8x_1 - 9x_2 - 3x_3 = 10 \end{cases}$$

Układ równań jest obiektem diametralnie innym niż samo równanie, co w powyższym zapisie symbolizuje klamra.

Układ równań symbolizuje system jako całość.

PRZYKŁAD:



$$\begin{cases} E_1 = I_1 R_1 + I_2 R_2 \\ E_2 = I_4 R_4 + I_3 R_3 - I_2 R_2 \\ E_3 = I_5 (R_5 + R_6) - I_4 R_4 \\ I_1 = I_2 + I_3 \\ I_3 = I_4 + I_5 \end{cases}$$

$$\begin{cases} 10 = 8I_1 + 2I_2 \\ 12 = 7I_4 + 3I_3 - 2I_2 \\ 10 = 10I_5 - 7I_4 \\ I_1 = I_2 + I_3 \\ I_3 = I_4 + I_5 \end{cases}$$

$$\begin{cases} E_1 = I_2 R_1 + I_3 R_1 + I_2 R_2 \\ E_2 = I_4 R_4 + I_4 R_3 + I_5 R_3 - I_2 R_2 \\ E_3 = I_5 (R_5 + R_6) - I_4 R_4 \end{cases}$$

$$\begin{cases} 10 = 8I_2 + 8I_3 + 2I_2 \\ 12 = 7I_4 + 3I_4 + 3I_5 - 2I_2 \\ 10 = 10I_5 - 7I_4 \end{cases}$$

RÓŻNE POSTACIE UKŁADU RÓWNAŃ LINIOWYCH – POSTAĆ KANONICZNA


Klasyczny „szkolny” układ równań zapisujemy w postaci:

$$\begin{cases} 2x_1 + 5x_2 - 6x_3 = 7 \\ 4x_1 + 2x_2 + 10x_3 = 2 \\ 8x_1 - 9x_2 - 3x_3 = 4 \end{cases}$$

Układ równań jest obiektem diametralnie innym niż samo równanie, co w powyższym zapisie symbolizuje klamra.

Układ równań symbolizuje system jako całość. W związku z czym zmienne $x_1, x_2, \dots, x_N$ są to zmienne stanu systemu – czyli wartości charakterystyczne danego systemu pozwalające na całkowity jego opis.

PRZYKŁAD:



$$\begin{cases} E_1 = I_1 R_1 + I_2 R_2 \\ E_2 = I_4 R_4 + I_3 R_3 - I_2 R_2 \\ E_3 = I_5 (R_5 + R_6) - I_4 R_4 \\ I_1 = I_2 + I_3 \\ I_3 = I_4 + I_5 \end{cases}$$

~~$$\begin{cases} E_1 = I_2 R_1 + I_3 R_1 + I_2 R_2 \\ E_2 = I_4 R_4 + I_4 R_3 + I_5 R_3 - I_2 R_2 \\ E_3 = I_5 (R_5 + R_6) - I_4 R_4 \end{cases}$$~~

$$\begin{cases} 10 = 8I_1 + 2I_2 \\ 12 = 7I_4 + 3I_3 - 2I_2 \\ 10 = 10I_5 - 7I_4 \\ I_1 = I_2 + I_3 \\ I_3 = I_4 + I_5 \end{cases}$$

Rozwiązanie tego układu równań nie opisuje całkowitego stanu systemu

~~$$\begin{cases} 10 = 8I_2 + 8I_3 + 2I_2 \\ 12 = 7I_4 + 3I_4 + 3I_5 - 2I_2 \\ 10 = 10I_5 - 7I_4 \end{cases}$$~~

RÓŻNE POSTACIE UKŁADU RÓWNAŃ LINIOWYCH – POSTAĆ KANONICZNA

Klasyczny „szkolny” układ równań zapisujemy w postaci:


$$\begin{cases} 2x_1 + 5x_2 - 6x_3 = 7 \\ 4x_1 + 2x_2 + 10x_3 = 2 \\ 8x_1 - 9x_2 - 3x_3 = 4 \end{cases}$$

Układ równań jest obiektem diametralnie innym niż samo równanie, co w powyższym zapisie symbolizuje klamra.

Współczynniki przy niewiadomych opisują parametry systemu.

A współczynniki niezależne opisują parametry niezależne – tutaj np. wymuszenia systemu.

PRZYKŁAD:



$$\begin{cases} E_1 = I_1 R_1 + I_2 R_2 \\ E_2 = I_4 R_4 + I_3 R_3 - I_2 R_2 \\ E_3 = I_5 (R_5 + R_6) - I_4 R_4 \\ I_1 = I_2 + I_3 \\ I_3 = I_4 + I_5 \end{cases}$$

$$\begin{cases} 10 = 8I_1 + 2I_2 \\ 12 = 7I_4 + 3I_3 - 2I_2 \\ 10 = 10I_5 - 7I_4 \\ I_1 = I_2 + I_3 \\ I_3 = I_4 + I_5 \end{cases}$$

RÓŻNE POSTACIE UKŁADU RÓWNAŃ LINIOWYCH – POSTAĆ KANONICZNA

Dlatego **kanoniczny zapis** układu równań liniowych różni się od „szkolnego” i uwzględnia tę logikę:

Wszystkie
implementacje
metod oczekują
równania w takiej
postaci


$$\begin{bmatrix} 2 & 5 & -6 \\ 4 & 2 & 10 \\ 8 & -9 & -3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 7 \\ 2 \\ 4 \end{bmatrix}$$

$$\mathbf{Ax} = \mathbf{b}$$

$$\begin{cases} 2x_1 + 5x_2 - 6x_3 = 7 \\ 4x_1 + 2x_2 + 10x_3 = 2 \\ 8x_1 - 9x_2 - 3x_3 = 4 \end{cases}$$

$\mathbf{A}$ – macierz parametrów systemu, $\mathbf{x}$ – wektor stanu systemu, $\mathbf{b}$ – wektor parametrów niezależnych (wymuszeń)

PRZYKŁAD:



$$\begin{cases} E_1 = I_1 R_1 + I_2 R_2 \\ E_2 = I_4 R_4 + I_3 R_3 - I_2 R_2 \\ E_3 = I_5 (R_5 + R_6) - I_4 R_4 \\ I_1 = I_2 + I_3 \\ I_3 = I_4 + I_5 \end{cases}$$

$$\begin{bmatrix} R_1 & R_2 & 0 & 0 & 0 \\ 0 & -R_2 & R_3 & R_4 & 0 \\ 0 & 0 & 0 & -R_4 & (R_5 + R_6) \\ -1 & 1 & 1 & 0 & 0 \\ 0 & 0 & -1 & 1 & 1 \end{bmatrix} \begin{bmatrix} I_1 \\ I_2 \\ I_3 \\ I_4 \\ I_5 \end{bmatrix} = \begin{bmatrix} E_1 \\ E_2 \\ E_3 \\ 0 \\ 0 \end{bmatrix}$$

$$\begin{bmatrix} 8 & 2 & 0 & 0 & 0 \\ 0 & -2 & 3 & 7 & 0 \\ 0 & 0 & 0 & -7 & (4 + 6) \\ -1 & 1 & 1 & 0 & 0 \\ 0 & 0 & -1 & 1 & 1 \end{bmatrix} \begin{bmatrix} I_1 \\ I_2 \\ I_3 \\ I_4 \\ I_5 \end{bmatrix} = \begin{bmatrix} 10 \\ 12 \\ 10 \\ 0 \\ 0 \end{bmatrix}$$

PRZYKŁAD:

Punkt w przestrzeni możemy potraktować jako system współrzędnych. Zgodnie z logiką stosowania macierzy obrót punktu wokół osi OY układu współrzędnych o kąt Θ można opisać macierzą:

$$A = \begin{bmatrix} \cos(\theta) & 0 & -\sin(\theta) \\ 0 & 1 & 0 \\ \sin(\theta) & 0 & \cos(\theta) \end{bmatrix}$$


Problem rozwiązania układu równań liniowych zachodzi np. wtedy kiedy znamy współrzędne punktu po przekształceniu (np. $[1 \ 1 \ 1]$) i kąt Θ (np. $\Theta = 90^\circ$), a chcemy poznać pierwotne położenie punktu przed przekształceniem. Odpowiedni układ równań będzie wyglądał następująco:

$$\begin{cases} x' = \cos(\theta)x - \sin(\theta)z \\ y' = y \\ z' = \sin(\theta)x + \cos(\theta)z \end{cases} \quad \begin{bmatrix} \cos(\theta) & 0 & -\sin(\theta) \\ 0 & 1 & 0 \\ \sin(\theta) & 0 & \cos(\theta) \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} x' \\ y' \\ z' \end{bmatrix}$$

$$\text{Dla } \Theta=90^\circ \quad \begin{bmatrix} 0 & 0 & -1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

Tego typu problemy mogą być numerycznie często rozwiązywane, zmieniając tylko analizowany punkt.

PROBLEM Z ROZWIĄZANIEM UKŁADU RÓWNAŃ LINIOWYCH PRZY POMOCY ALGEBRY MACIERZY



PROBLEM Z ROZWIĄZANIEM UKŁADU RÓWNAŃ LINIOWYCH PRZY POMOCY ALGEBRY MACIERZY

Teoretycznie układ równań w postaci kanonicznej jesteśmy w stanie rozwiązać w ten sam sposób, w jaki rozwiązywalibyśmy pojedyncze równanie — przez odwrócenie macierzy:

Układ równań:

$$\mathbf{Ax} = \mathbf{b}$$

$$\mathbf{A}^{-1}\mathbf{Ax} = \mathbf{A}^{-1}\mathbf{b}$$

$$\mathbf{A}^{-1}\mathbf{A} = \mathbf{I}$$

$$\mathbf{x} = \frac{\mathbf{b}}{\mathbf{A}} = \mathbf{A}^{-1}\mathbf{b}$$

*Pojedyncze
równanie:*

$$ax = b$$

$$x = \frac{b}{a}$$

To podejście ma jednak dwa poważne problemy:

1. Jest bardzo podatne na wpływ błędów zaokrągleń — każdy element rozwiązania zależy od wszystkich współczynników zawartych w macierzy $\mathbf{A}$ i wektorze $\mathbf{b}$. Im większe stają się te elementy, tym rozwiązanie może być obarczone coraz większym błędem — to problem złego uwarunkowania numerycznego układu równań (wracamy do tego w rozdziale o dokładności rozwiązania).
2. Algorytmy odwracania macierzy są niewydajne — bezpośrednie odwrócenie wymaga rzędu $O(n^3)$ operacji arytmetycznych, i nie jest znany ogólny, praktycznie stosowany algorytm o istotnie lepszej klasie złożoności.

PROBLEM Z ROZWIĄZANIEM UKŁADU RÓWNAŃ LINIOWYCH PRZY POMOCY ALGEBRY MACIERZY

Teoretycznie układ równań w postaci kanonicznej jesteśmy w stanie rozwiązać w ten sam sposób, w jaki rozwiązalibyśmy pojedyncze równanie — przez odwrócenie macierzy:

Układ równań:

$$\mathbf{Ax} = \mathbf{b}$$

$$\mathbf{A}^{-1}\mathbf{Ax} = \mathbf{A}^{-1}\mathbf{b}$$

$$\mathbf{A}^{-1}\mathbf{A} = \mathbf{I}$$

$$\mathbf{x} = \frac{\mathbf{b}}{\mathbf{A}} = \mathbf{A}^{-1}\mathbf{b}$$

To podejście ma jednak dwa poważne problemy:


1. Jest bardzo podatne na wpływ błędów zaokrągleń — każdy element rozwiązania zależy od wszystkich współczynników zawartych w macierzy $\mathbf{A}$ i wektorze $\mathbf{b}$. Im większe stają się te elementy, tym rozwiązanie może być obciążone coraz większym błędem — to problem złego uwarunkowania numerycznego układu równań (wracamy do tego w rozdziale o dokładności rozwiązania).

2. Algorytmy odwracania macierzy są niewydajne — bezpośrednie odwrócenie wymaga rzędu $O(n^3)$ operacji arytmetycznych, i nie jest znany ogólny, praktycznie stosowany algorytm o istotnie lepszej klasie złożoności.


- Rozwiązanie problemu 2. nie jest znane w sensie fundamentalnym — dlatego metody algebraiczne stosuje się dla układów równań stosunkowo małych, powiedzmy ~ 100 równań. Znane metody wykorzystują różne właściwości macierzy, żeby uzyskać złożoność $O(n^2)$ (dla samego etapu rozwiązania, po jednorazowym rozkładzie) — co jest okupione pewnym nakładem obliczeniowym na sam rozkład. Mimo to pozostaje to złożoność wielomianowa.
- Z problemem 1. (błędy zaokrągleń) staramy się walczyć poprzez zastosowanie kombinacji kilku metod eliminujących/ograniczających błędy zaokrągleń — o czym w kolejnych rozdziałach (pivoting, LU, QR).

PROBLEM Z ROZWIĄZANIEM UKŁADU RÓWNAŃ LINIOWYCH – ILE TO ZAJMUJE, ILE TO TRWA?

Ile pamięci zajmuje gęsta macierz A: pamięć vs. rozmiar układu



Naiwna eliminacja Gaussa: czas rozwiązania vs. rozmiar układu



Gęsta macierz A ($n \times n$) zajmuje w pamięci $O(n^2)$ liczb — już dla układu rzędu kilkunastu tysięcy równań potrzeba więcej niż 1 GB, a dla dużej siatki inżynierskiej ($n \sim 10^6$) — kilka terabajtów. To drugi, równie namacalny argument zasobowy obok czasu obliczeń.

PROBLEM Z ROZWIĄZANIEM UKŁADU RÓWNAŃ LINIOWYCH – MACIERZE RZADKIE I SOLVERY CAD/MES



Układy rzędu 10^6+ równań pojawiają się w praktyce głównie w dyskretyzacji równań różniczkowych cząstkowych (MES/MRS w solverach CAD) — i są w takich przypadkach prawie zawsze **rzadkie**: każde równanie łączy tylko sąsiednie węzły siatki, niezależnie od całkowitego rozmiaru układu.

Dzięki temu pamięć potrzebna do przechowania macierzy rośnie jak $O(n)$, nie $O(n^2)$ — **ale tylko jeśli metoda potrafi wykorzystać tę rzadkość – metody algebraiczne nie potrafią skorzystać z takich struktur danych**. To właśnie dlatego dla dużych, rzadkich układów sięgamy po metody iteracyjne.

PODSTAWOWE METODY ALGEBRAICZNE

Macierze trójkątne:

* Macierz trójkątna górna

- Wszystkie elementy **poniżej** diagonalii są zerowe

$$A = \begin{bmatrix} a_{1,1} & a_{1,2} & \dots & a_{1,N-1} & a_{1,N} \\ 0 & a_{2,2} & & a_{2,N-1} & a_{2,N} \\ & \vdots & \ddots & \vdots & \\ & 0 & 0 & a_{N-1,N-1} & a_{N-1,N} \\ & 0 & 0 & 0 & a_{N,N} \end{bmatrix}$$

Przykład:

$$A = \begin{bmatrix} 1 & 5 & 2 & 10 \\ 0 & 6 & 8 & 7 \\ 0 & 0 & 6 & 89 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

* Macierz trójkątna dolna

- Wszystkie elementy **powyżej** diagonalii są zerowe

$$B = \begin{bmatrix} b_{1,1} & 0 & \dots & 0 & 0 \\ b_{2,1} & b_{2,2} & & 0 & 0 \\ & \vdots & \ddots & \vdots & \\ b_{N-1,1} & b_{N-1,2} & \dots & b_{N-1,N-1} & 0 \\ b_{N,1} & b_{N,2} & & b_{N,N-1} & b_{N,N} \end{bmatrix}$$

Przykład:

$$B = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 2 & 6 & 0 & 0 \\ 6 & 2 & 6 & 0 \\ 7 & 3 & 6 & 1 \end{bmatrix}$$

PODSTAWOWE METODY ALGEBRAICZNE

Macierze trójkątne:

$$\begin{bmatrix} 2 & 7 & 1 & 8 & 2 \\ 0 & 8 & 1 & 8 & 2 \\ 0 & 0 & 8 & 4 & 5 \\ 0 & 0 & 0 & 9 & 0 \\ 0 & 0 & 0 & 0 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{bmatrix} = \begin{bmatrix} 3 \\ 1 \\ 4 \\ 1 \\ 5 \end{bmatrix}$$

$$2 \cdot x_1 + 7 \cdot x_2 + 1 \cdot x_3 + 8 \cdot x_4 + 2 \cdot x_5 = 3$$

$$8 \cdot x_2 + 1 \cdot x_3 + 8 \cdot x_4 + 2 \cdot x_5 = 1$$

$$8 \cdot x_3 + 4 \cdot x_4 + 5 \cdot x_5 = 4$$

$$9 \cdot x_4 + 0 \cdot x_5 = 1$$

$$4 \cdot x_5 = 5$$

Metoda ta nosi nazwę metody eliminacji prostej.

Operacja eliminacji prostej ma złożoność $O(n^2)$

ZI_R_LIN_ILUSTR2

1. W oczywisty sposób $x_5 = \frac{5}{4}$

2. Podstawiamy we wszystkich równaniach:

$$2 \cdot x_1 + 7 \cdot x_2 + 1 \cdot x_3 + 8 \cdot x_4 + 2 \cdot \frac{5}{4} = 3$$

$$8 \cdot x_2 + 1 \cdot x_3 + 8 \cdot x_4 + 2 \cdot \frac{5}{4} = 1$$

$$8 \cdot x_3 + 4 \cdot x_4 + 5 \cdot \frac{5}{4} = 4$$

$$9 \cdot x_4 + 0 \cdot \frac{5}{4} = 1$$

$$4 \cdot \frac{5}{4} = 5$$

3. Redukujemy do postaci trójkątnej

$$2 \cdot x_1 + 7 \cdot x_2 + 1 \cdot x_3 + 8 \cdot x_4 = \frac{1}{2}$$

$$8 \cdot x_2 + 1 \cdot x_3 + 8 \cdot x_4 = -\frac{3}{2}$$

$$8 \cdot x_3 + 4 \cdot x_4 = -\frac{9}{4}$$

$$9 \cdot x_4 = 1$$

4. Wracamy do kroku 1

PODSTAWOWE METODY ALGEBRAICZNE – METODA ELIMINACJI GAUSSA

Najprostsza metodą uzyskiwania macierzy trójkątnej jest metoda eliminacji Gaussa. Polega ona na wykorzystaniu obserwacji, że układy równań można przekształcać do postaci innego układu (o innych współczynnikach), ale takim samym rozwiązaniem stosując tylko dwie operacje elementarne – czyli takie, które właśnie nie zmieniają rozwiązania:

1. Dodanie wielokrotności wiersza do innego wiersza

PRZYKŁAD:

$$\left\{ \begin{array}{l} 8x_1 + 2x_2 + 2x_3 = 10 \\ 5x_1 - 3x_2 - 1x_3 = 5 \\ -5x_2 + 5x_3 = 10 \end{array} \right. \rightarrow W_2 - \frac{5}{8} \cdot W_1 \rightarrow \left\{ \begin{array}{l} 8x_1 + 2x_2 + 2x_3 = 10 \\ -\frac{17}{4}x_2 - \frac{9}{4}x_3 = -\frac{5}{4} \\ -5x_2 + 5x_3 = 10 \end{array} \right.$$

Operacja zmiany wierszy ma kluczowe znaczenie dla powodzenia!

Rozwiązanie:

$$x_1 = 1, x_2 = -\frac{1}{2}, x_3 = \frac{3}{2}$$

Rozwiązanie:

$$x_1 = 1, x_2 = -\frac{1}{2}, x_3 = \frac{3}{2}$$

PODSTAWOWE METODY ALGEBRAICZNE – METODA ELIMINACJI GAUSSA

Najprostsza metodą uzyskiwania macierzy trójkątnej jest metoda eliminacji Gaussa. Polega ona na wykorzystaniu obserwacji, że układy równań można przekształcać do postaci innego układu (o innych współczynnikach), ale takim samym rozwiązaniem stosując tylko dwie operacje elementarne – czyli takie, które właśnie nie zmieniają rozwiązania:

2. Zamiana miejscami wiersza

PRZYKŁAD:

$$\left\{ \begin{array}{l} 8x_1 + 2x_2 + 2x_3 = 10 \\ 5x_1 - 3x_2 - 1x_3 = 5 \\ -5x_2 + 5x_3 = 10 \end{array} \right. \rightarrow W_2 \leftrightarrow W_3 \rightarrow \left\{ \begin{array}{l} 8x_1 + 2x_2 + 2x_3 = 10 \\ -5x_2 + 5x_3 = 10 \\ 5x_1 - 3x_2 - 1x_3 = 5 \end{array} \right.$$

Rozwiązanie:

$$x_1 = 1, x_2 = -\frac{1}{2}, x_3 = \frac{3}{2}$$

Rozwiązanie:

$$x_1 = 1, x_2 = -\frac{1}{2}, x_3 = \frac{3}{2}$$

Taką zamianę wierszy zwykło się zapisywać w postaci tzw. Macierzy permutacji.

Choć sama eliminacja prosta ma złożoność $O(n^2)$ to przekształcenie macierzy do postaci trójkątnej ma złożoność $O(n^3)$.

RÓŻNA POSTACIE UKŁADU RÓWNAŃ LNIOWYCH – POSTAĆ KANONICZNA

PRZYKŁAD:

Punkt w przestrzeni możemy potraktować jako system współrzędnych. Zgodnie z logiką stosowania macierzy obrót punktu wokół osi OY układu współrzędnych o kąt Θ można opisać macierzą:

$$A = \begin{bmatrix} \cos(\theta) & 0 & -\sin(\theta) \\ 0 & 1 & 0 \\ \sin(\theta) & 0 & \cos(\theta) \end{bmatrix}$$

Problem rozwiązania układu równań liniowych zachodzi np. wtedy kiedy znamy współrzędne punktu po przekształceniu (np. $[1 \ 1 \ 1]$) i kąt Θ (np. $\Theta = 90^\circ$), a chcemy poznać pierwotne położenie punktu przed przekształceniem. Odpowiedni układ równań będzie wyglądał następująco:

$$\begin{cases} x' = \cos(\theta)x - \sin(\theta)z \\ y' = y \\ z' = \sin(\theta)x + \cos(\theta)z \end{cases}$$

$$\begin{bmatrix} \cos(\theta) & 0 & -\sin(\theta) \\ 0 & 1 & 0 \\ \sin(\theta) & 0 & \cos(\theta) \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} x' \\ y' \\ z' \end{bmatrix}$$

$$\text{Dla } \Theta=90^\circ \quad \begin{bmatrix} 0 & 0 & -1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$


Tego typu problemy mogą być numerycznie często rozwiązywane, zmieniając tylko analizowany punkt.

PODSTAWOWE METODY ALGEBRAICZNE – PIVOTING

Idea pivotingu polega na takim przestawieniu wierszy, żeby na diagonalu zawsze znalazł się element o największym module. Jest to tzw. Pivoting częściowy.

$$m = \frac{a_{ik}}{a_{kk}}$$

PODSTAWOWE METODY ALGEBRAICZNE – CZYNNIK WZROSTU



Przykład pokazał coś więcej niż tylko to, że pivoting jest potrzebny: pokazał, że **sam algorytm — nie tylko jakość danych wejściowych — potrafi w trakcie obliczeń nadmiernie powiększać liczby.**

Ten efekt nazywamy czynnikiem wzrostu (growth factor, ρ_n).

To coś innego niż uwarunkowanie danych wejściowych, którą poznamy niedługo – opisaną przez współczynnik uwarunkowania $cond(A)$.

W przypadku tego typu zagadnień warto zastosować inny sposób rozkładu macierzy A – tym razem na iloczyn dwóch macierzy trójkątnych. Rozkład taki nosi nazwę rozkładu LU:

$$A \cdot x = b$$

$$A = L \cdot U$$


Obie te macierze są trójkątne

*Stosujemy eliminację prostą
dwa razy:*

$$L \cdot U \cdot x = b$$

$$L \cdot (U \cdot x) = b$$

$$L \cdot y = b$$


$$\text{gdzie } y = U \cdot x$$

- W przeciwieństwie do eliminacji Gaussa taki rozkład, choć też generuje macierze trójkątne, to nie wymaga przekształcania wektora b
- Dzięki temu w kolejnych powtórzeniach rozwiązywania problemu nie ponosimy kosztów rozkładu i w efekcie złożoność uzyskania wyniku jest taka sama jak eliminacji prostej $O(n^2)$
- Od czasu do czasu jednak musimy wykonać sam rozkład jeżeli wektor b ulegnie zmianie – wtedy złożoność wynosi $O(n^3)$. Metoda LU nie pogarsza klasy złożoności (jeżeli w każdym wywołaniu musimy zrobić rozkład)

Rozkład QR również wykorzystuje macierz trójkątną (macierz R), ale oprócz tego korzysta z unikalnych cech wektorów i macierzy ortogonalnych.

Twierdzenie:

Każdą macierz **A** można przedstawić w postaci:



gdzie:

E – jest macierzą permutacji

Q – jest macierzą ortogonalną

R – jest macierzą trójkątną

Mówimy, że dwa wektory **p** i **q** są ortogonalne, jeżeli:

$$\langle p, q \rangle = 0$$

czyli inaczej:

$$p^T q = 0$$

Jeżeli dodatkowo dwa wektor ortogonalny **u** ma taką cechę, że :

$$u^T u = 1$$

To mówimy, że taki wektor jest ortonormalny.

Macierz kwadratową $Q^{N \times N}$ nazywamy macierzą ortogonalną, jeżeli wszystkie wektory kolumnowe tej macierzy są wektorami ortonormalnymi względem pozostałych.

Rozkład QR również wykorzystuje macierz trójkątną (macierz R), ale oprócz tego korzysta z unikalnych cech wektorów i macierzy ortogonalnych.

Kluczowa właściwość opiera się na specjalnych regułach jakim rządzi się odwracanie macierzy ortogonalnych:

$$\mathbf{Q}^{-1} = \mathbf{Q}^H$$

Macierz Hermitowsko sprzężoną względem macierzy $\mathbf{A}^{M \times N} = [a_{M \times N}] \in \mathbb{C}^{M \times N}$ oznaczaną $\mathbf{A}^H$ jest to macierz taka, że:

$$\mathbf{A}^H = \begin{bmatrix} a_{1,1}^* & \cdots & a_{M,1}^* \\ \vdots & \ddots & \vdots \\ a_{1,N}^* & \cdots & a_{M,N}^* \end{bmatrix}$$

Elementy są zamienione położeniem (transpozycja) oraz dodatkowo sprzężone względem elementu oryginalnego macierzy $\mathbf{A}$

Ponieważ liczby rzeczywiste stanowią podzbiór liczb zespolonych w których $\text{Im}(x)=0$ zatem:

$$\mathbf{A}^H = \mathbf{A}^T = \begin{bmatrix} a_{1,1} & \cdots & a_{M,1} \\ \vdots & \ddots & \vdots \\ a_{1,N} & \cdots & a_{M,N} \end{bmatrix}$$

Rozkład QR również wykorzystuje macierz trójkątną (macierz R), ale oprócz tego korzysta z unikalnych cech wektorów i macierzy ortogonalnych.

Kluczowa właściwość opiera się na specjalnych regułach jakim rządzi się odwracanie macierzy ortogonalnych:

Własność I

$$Q^T = Q^{-1}$$

tzn. odwracanie macierzy ortogonalnej można przeprowadzić numerycznie **bez wprowadzenia jakiegokolwiek błędu**

Własność II


Odwrócenie macierzy ortogonalnej nie wymaga żadnych działań na liczbach – wystarczy **zmienić kolejność zapisu w pamięci!**

$$Q^T Q = I$$

Ponieważ odwrócenie Q nie wprowadza błędu, **rozkład QR ma gwarantowaną stabilność numeryczną**, niezależną od konkretnej macierzy A. Zobaczmy dokładnie dlaczego przy współczynniku uwarunkowania.

PODSTAWOWE METODY ALGEBRAICZNE – ROZKŁAD QR


Rozkład QR również wykorzystuje macierz trójkątną (macierz R), ale oprócz tego korzysta z unikalnych cech wektorów i macierzy ortogonalnych.



- Rozkładu dokonuje się w procesie ortogonalizacji, popularne algorytmy to tzw. przekształcenia Hausholdera, albo ortogonalizacji Gramma-Shmidta
- Złożoność każdego z tych algorytmów ma klasę $O(n^3)$ i taka jest też złożoność metody QR (ze względu na konieczność rozłożenia. Mimo to rozkład wypada korzystnie w porównaniu z innymi metodami
- Rozkład cechuje się bardzo dobrymi właściwościami ze względu na wprowadzany błąd (jest on niewielki)
- Rozkład QR może być wykorzystany do obliczenia macierzy pseudoodwrotnej w sensie Penrosa-Moora (Patrz LZNK)

Rozkład QR konstruowany jest specjalnie tak, żeby **ograniczyć wzrost błędu wprowadzanego przez algorytm** w każdym przypadku.

BŁĘDY ZAOKRĄGLEŃ – ANALIZA I ZALEŻNOŚĆ OD DANYCH



Np. Dokonanie rozkładu


Np. Eliminacja prosta

- Na ogólną dokładność wyniku poza samymi operacjami matematycznymi mają wpływ także dane. W przypadku układów równań liniowych może to być wpływ decydujący – niezależnie od metody
- Każda z poznanych metod składa się z kilku kroków, z których każdy wprowadza jakiś błąd, choć dzięki poznany przekształceniom staramy się ten błąd minimalizować

Jaką formę przybierają dane wejściowe dla zagadnienia rozwiązywania układów równań liniowych?

$$Ax = b$$

BŁĘDY ZAOKRĄGLEŃ – ANALIZA I ZALEŻNOŚĆ OD DANYCH



Np. Dokonanie rozkładu

Np. Eliminacja prosta

- Na ogólną dokładność wyniku poza samymi operacjami matematycznymi mają wpływ także dane. W przypadku układów równań liniowych może to być wpływ decydujący – niezależnie od metody
- Każda z poznanych metod składa się z kilku kroków, z których każdy wprowadza jakiś błąd, choć dzięki poznany przekształceniom staramy się ten błąd minimalizować

Jaką formę przybierają dane wejściowe dla zagadnienia rozwiązywania układów równań liniowych?

$$Ax = b$$

Potrzebny nam jest sposób na określenie dokładności rozwiązania niezależnie od użytej metody. W dodatku na takiej podstawie można wybierać między różnymi metodami (również niepoznanymi na przedmiocie) przed przystąpieniem do rozwiązania.

Zanalizujmy jak błąd wektora $\mathbf{b}$ wpływa na dokładność wyniku końcowego:

$$\mathbf{A}(\mathbf{x} + \Delta\mathbf{x}) = \mathbf{b} + \Delta\mathbf{b}$$

$$\mathbf{Ax} = \mathbf{b}$$

$$\|\mathbf{b}\| = \|\mathbf{Ax}\|$$

$$\|\mathbf{b}\| \leq \|\mathbf{A}\| \cdot \|\mathbf{x}\|$$

$$\frac{\|\mathbf{b}\|}{\|\mathbf{x}\|} \leq \|\mathbf{A}\|$$

$$\mathbf{A}\Delta\mathbf{x} = \Delta\mathbf{b}$$

$$\Delta\mathbf{x} = \mathbf{A}^{-1}\Delta\mathbf{b}$$

$$\|\Delta\mathbf{x}\| = \|\mathbf{A}^{-1}\Delta\mathbf{b}\|$$

$$\|\Delta\mathbf{x}\| \leq \|\mathbf{A}^{-1}\| \cdot \|\Delta\mathbf{b}\|$$

Z własności norm

Mnożąc stronami:

$$\frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} \leq \|\mathbf{A}\| \|\mathbf{A}^{-1}\| \frac{\|\Delta\mathbf{b}\|}{\|\mathbf{b}\|}$$

Współczynnik
uwarunkowania
 $\text{cond}(\mathbf{A})$

Jest to oszacowanie (najgorszego przypadku) wielkości błędu wprowadzanego przez niedokładność wektora $\mathbf{b}$

Potrzebny nam jest sposób na określenie dokładności rozwiązania niezależnie od użytej metody. W dodatku na takiej podstawie można wybierać między różnymi metodami (również niepoznanymi na przedmiocie) przed przystąpieniem do rozwiązania.

$$\text{cond}(\mathbf{A}) = \|\mathbf{A}\| \|\mathbf{A}^{-1}\|$$

$$\frac{\|\Delta x\|}{\|x\|} \leq \text{cond}(\mathbf{A}) \frac{\|\Delta \mathbf{b}\|}{\|\mathbf{b}\|}$$

- Współczynnik uwarunkowania pozwala na oszacowanie skali problemu wpływu danych przed podjęciem obliczeń
- Pozwala oszacować dokładność wyniku (niezależnie od zastosowanej metody)
- Minimalna wartość współczynnika uwarunkowania układu równań liniowych wynosi 1 – jest to wartość odpowiadająca minimalnemu wpływowi błędów zaokrągleń

Potrzebny nam jest sposób na określenie dokładności rozwiązania niezależnie od użytej metody. W dodatku na takiej podstawie można wybierać między różnymi metodami (również niepoznanymi na przedmiocie) przed przystąpieniem do rozwiązania.


$$\text{cond}(\mathbf{A}) = \|\mathbf{A}\| \|\mathbf{A}^{-1}\|$$

$$\frac{\|\Delta x\|}{\|x\|} \leq \text{cond}(\mathbf{A}) \frac{\|\Delta \mathbf{b}\|}{\|\mathbf{b}\|}$$

- To jak bardzo błędy zaokrągleń i reprezentacji (oraz np. błędy pomiarowe i wszystkie inne) zawarta w wektorze $\mathbf{b}$ wpływają na wynik zależy od budowy i struktury macierzy $\mathbf{A}$.
- Macierz $\mathbf{A}$ możemy przekształcać tak, żeby nie zmieniać wyniku, ale uzyskać macierz cechującą się bardzo dobrymi właściwościami pod względem współczynnika uwarunkowania (w istocie poznane metody w pewnym stopniu to robią)
- Prawidłowa implementacja praktyczna zazwyczaj stara się to osiągnąć np. poprzez przestawienie równań

WSPÓŁCZYNNIK UWARUNKOWANIA

Ta sama zmiana danych (1%) → jak bardzo myli się rozwiązanie?



Potrzebny nam jest sposób na określenie dokładności rozwiązania niezależnie od użytej metody. W dodatku na takiej podstawie można wybierać między różnymi metodami (również niepoznanymi na przedmiocie) przed przystąpieniem do rozwiązania.

Potrzebny nam jest sposób na określenie dokładności rozwiązania niezależnie od użytej metody. W dodatku na takiej podstawie można wybierać między różnymi metodami (również niepoznanymi na przedmiocie) przed przystąpieniem do rozwiązania.

$$\text{cond}(\mathbf{A}) = \|\mathbf{A}\| \|\mathbf{A}^{-1}\|$$

$$\frac{\|\Delta x\|}{\|x\|} \leq \text{cond}(\mathbf{A}) \frac{\|\Delta \mathbf{b}\|}{\|\mathbf{b}\|}$$

Istnieją struktury macierzy, które w naturalny sposób mają małe współczynniki uwarunkowania są to np. macierze diagonalnie silnie i słabo dominujące. Wiele metod numerycznych stara się z tego powodu stworzyć lub przekształcić układ równań do postaci z taką właśnie macierzą.

Macierz diagonalnie słabo dominująca – każdy element diagonalny jest co do modułu co najmniej równy sumie modułów elementów pozadiagonalnych w danym wierszu:

$$|a_{m,m}| \geq \sum_{n=1, n \neq m}^N |a_{m,n}|$$

Oraz przynajmniej jeden element diagonalny jest większy niż suma elementów pozadiagonalnych:

$$|a_{m,m}| > \sum_{n=1, n \neq m}^N |a_{m,n}|$$

Macierz diagonalnie silnie dominująca – każdy element diagonalny jest co do modułu większy od sumy modułów elementów pozadiagonalnych w danym wierszu:

$$|a_{m,m}| > \sum_{n=1, n \neq m}^N |a_{m,n}|$$

Potrzebny nam jest sposób na określenie dokładności rozwiązania niezależnie od użytej metody. W dodatku na takiej podstawie można wybierać między różnymi metodami (również niepoznanymi na przedmiocie) przed przystąpieniem do rozwiązania.

$$\text{cond}(\mathbf{A}) = \|\mathbf{A}\| \|\mathbf{A}^{-1}\|$$

$$\frac{\|\Delta x\|}{\|x\|} \leq \text{cond}(\mathbf{A}) \frac{\|\Delta \mathbf{b}\|}{\|\mathbf{b}\|}$$

Istnieją struktury macierzy, które w naturalny sposób mają małe współczynniki uwarunkowania są to np. macierze diagonalnie silnie i słabo dominujące. Wiele metod numerycznych stara się z tego powodu stworzyć lub przekształcić układ równań do postaci z taką właśnie macierzą.

$$A = \begin{bmatrix} 10 & 1 & 4 & 1 & 3 & 0 \\ 5 & 33 & 6 & 6 & -7 & 0 \\ -8 & -2 & -24 & 5 & 0 & 8 \\ 3 & -6 & 0 & 22 & -3 & 9 \\ 1 & 0 & -2 & 4 & 8 & 1 \\ 0 & -3 & 4 & 7 & 3 & 20 \end{bmatrix}$$

$$B = \begin{bmatrix} 10 & 1 & 4 & 1 & 3 & 0 \\ 5 & 33 & 6 & 6 & -7 & 0 \\ -8 & -2 & -24 & 5 & 0 & 8 \\ 3 & -6 & 0 & 22 & -3 & 9 \\ 1 & 0 & -2 & 4 & 9 & 1 \\ 0 & -3 & 4 & 7 & 3 & 20 \end{bmatrix}$$

Potrzebny nam jest sposób na określenie dokładności rozwiązania niezależnie od użytej metody. W dodatku na takiej podstawie można wybierać między różnymi metodami (również niepoznanymi na przedmiocie) przed przystąpieniem do rozwiązania.

$$\text{cond}(\mathbf{A}) = \|\mathbf{A}\| \|\mathbf{A}^{-1}\|$$

$$\frac{\|\Delta x\|}{\|x\|} \leq \text{cond}(\mathbf{A}) \frac{\|\Delta \mathbf{b}\|}{\|\mathbf{b}\|}$$

Istnieją struktury macierzy, które w naturalny sposób mają małe współczynniki uwarunkowania są to np. macierze diagonalnie silnie i słabo dominujące. Wiele metod numerycznych stara się z tego powodu stworzyć lub przekształcić układ równań do postaci z taką właśnie macierzą.

Macierz diagonalnie słabo dominująca

$$A = \begin{bmatrix} 10 & 1 & 4 & 1 & 3 & 0 \\ 5 & 33 & 6 & 6 & -7 & 0 \\ -8 & -2 & -24 & 5 & 0 & 8 \\ 3 & -6 & 0 & 22 & -3 & 9 \\ 1 & 0 & -2 & 4 & 8 & 1 \\ 0 & -3 & 4 & 7 & 3 & 20 \end{bmatrix}$$

Macierz diagonalnie silnie dominująca

$$B = \begin{bmatrix} 10 & 1 & 4 & 1 & 3 & 0 \\ 5 & 33 & 6 & 6 & -7 & 0 \\ -8 & -2 & -24 & 5 & 0 & 8 \\ 3 & -6 & 0 & 22 & -3 & 9 \\ 1 & 0 & -2 & 4 & 9 & 1 \\ 0 & -3 & 4 & 7 & 3 & 20 \end{bmatrix}$$

Potrzebny nam jest sposób na określenie dokładności rozwiązania niezależnie od użytej metody. W dodatku na takiej podstawie można wybierać między różnymi metodami (również niepoznanymi na przedmiocie) przed przystąpieniem do rozwiązania.

$$cond(\mathbf{A}) = \|\mathbf{A}\| \|\mathbf{A}^{-1}\| \qquad \frac{\|\Delta x\|}{\|x\|} \leq cond(\mathbf{A}) \frac{\|\Delta \mathbf{b}\|}{\|\mathbf{b}\|}$$

Istnieją też struktury macierzy o szczególnie niekorzystnych właściwościach (budowie), mające tę cechę, że ich współczynnik uwarunkowania szybko rośnie wraz z rozmiarem macierzy.

MACIERZ HILBERTA

$$h_{i,j} = \frac{1}{i+j-1}$$

np.

$$H = \begin{bmatrix} 1 & \frac{1}{2} & \frac{1}{3} & \frac{1}{4} & \frac{1}{5} \\ \frac{1}{2} & \frac{1}{3} & \frac{1}{4} & \frac{1}{5} & \frac{1}{6} \\ \frac{1}{3} & \frac{1}{4} & \frac{1}{5} & \frac{1}{6} & \frac{1}{7} \\ \frac{1}{4} & \frac{1}{5} & \frac{1}{6} & \frac{1}{7} & \frac{1}{8} \\ \frac{1}{5} & \frac{1}{6} & \frac{1}{7} & \frac{1}{8} & \frac{1}{9} \end{bmatrix}$$

MACIERZ VANDERMONDA

$$A = \begin{pmatrix} 1 & x_1 & x_1^2 & \dots & x_1^{n-1} \\ 1 & x_2 & x_2^2 & \dots & x_2^{n-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \dots & x_n^{n-1} \end{pmatrix}$$

np. rozpięta na wektorze
 $x=[1 \ 2 \ 3 \ 4]$


$$\mathbf{A} = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & 2 & 4 & 8 \\ 1 & 3 & 9 & 27 \\ 1 & 4 & 16 & 64 \end{bmatrix}$$

MACIERZE TESTOWE – MACIEZR HILBERTA




BŁĘDY ZAOKRĄGLEŃ – ANALIZA I ZALEŻNOŚĆ OD DANYCH

Potrzebny nam jest sposób na określenie dokładności rozwiązania niezależnie od użytej metody. W dodatku na takiej podstawie można wybierać między różnymi metodami (również niepoznanymi na przedmiocie) przed przystąpieniem do rozwiązania.




BŁĘDY ZAOKRĄGLEŃ – WSPÓŁCZYNNIK UWARUNKOWANIA vs WSPÓŁCZYNNIK WZROSTU



Macierz Lehmera (SPD): $\rho_n=1$ dla LU — LU i QR trzymają się razem oszacowania teoretycznego.

Powodem wzrostu błędu w obu przypadkach jest wzrost rozmiaru problemu. To jak szybko błąd rośnie wynika ze struktury macierzy.



Macierz adwersarialna: $\rho_n=2^{n-1}$ dla LU — błąd LU rośnie dramatycznie szybko mimo małego $\text{cond}(\mathbf{A})$, QR zostaje przy precyzji maszynowej.

Błąd QR nie rośnie znacząco bo wynika on tylko z uwarunkowania numerycznego.



WŁAŚCIWOŚCI METOD ITERACYJNYCH

Wady metod algebraicznych:

- Wielomianowa złożoność obliczeniowa $O(n^2)$ w najlepszym przypadku, częściej $O(n^3)$
- W wielu przypadkach współczynnik uwarunkowania rośnie wraz z rozmiarami macierzy **A**, co oznacza, że nawet dla wielu układów rozwiązywalnych w akceptowalnym czasie wynik może być nie dość dokładny

Zalety metod algebraicznych:

- Znajdują rozwiązanie dla wszystkich rodzajów układów równań liniowych (choć może być obarczone dużym błędem, jesteśmy w stanie go oszacować) – JEST TO BARDZO DUŻA, KLUCZOWA ZALETĄ

WŁAŚCIWOŚCI METOD ITERACYJNYCH – postać ogólna metod iteracyjnych

Rozwiązaniem tego problemu są metody iteracyjne.

- Metoda iteracyjna jest w swojej istocie mechanizmem wymiany złożoności obliczeniowej na dokładność. Jeżeli udałooby się skonstruować metodę o wysokim współczynniku zbieżności to rozwiązalibyśmy w ten sposób oba problemy metod algebraicznych – moglibyśmy uzyskać wysoką dokładność przy względnie małej ilości obliczeń.
- W naturalny sposób jednak wysoki współczynnik zbieżności oznacza, że metoda nie będzie zbieżna dla wszystkich danych, zatem metody iteracyjne nie są w stanie rozwiązać dowolnego układu równań, a jedynie układy o konkretnych budowach. Dla każdej metody określone są budowy układów równań jakie dana metoda jest w stanie rozwiązać.
- To czy dana metoda iteracyjna jest zbieżna w ogóle do rozwiązania dla układu równań wynika z budowy wzoru iteracyjnego o ogólnej postaci:

$$\mathbf{x}^{(i+1)} = \mathbf{M}\mathbf{x}^{(i)} + \mathbf{w}$$

Macierz $\mathbf{M}$ i wektor $\mathbf{w}$ powstają z macierzy $\mathbf{A}$ i wektora $\mathbf{b}$ po przekształceniu przez zapis metody iteracyjnej.

WŁAŚCIWOŚCI METOD ITERACYJNYCH – postać ogólna metod iteracyjnych

Przykładowo:

$$x^{(i+1)} = Mx^{(i)} + w$$

Metoda Jacobiego:

$$Ax = b$$

$$A = L + D + U$$

gdzie: L-macierz trójkątna dolna, U – macierz trójkątna górna, D – macierz diagonalna

$$Dx = -(L + U)x + b$$

$$x = -D^{-1}(L + U)x + D^{-1}b$$

$$x^{(i+1)} = -D^{-1}(L + U)x^{(i)} + D^{-1}b$$

Rozkład strukturalny $A = L + D + U$ (metoda Jacobiego)

A			L (trójkątna dolna)			D (diagonalna)			U (trójkątna górna)		
4	-1	0	0	0	0	4	0	0	0	-1	0
-1	4	-1	-1	0	0	0	4	0	0	0	-1
0	-1	4	0	-1	0	0	0	4	0	0	0

$$M = -D^{-1}(L + U)$$

$$w = D^{-1}b$$

Macierz M i wektor w powstają z macierzy A i wektora b po przekształceniu przez zapis metody iteracyjnej.

WŁAŚCIWOŚCI METOD ITERACYJNYCH – postać ogólna metod iteracyjnych

- Metoda iteracyjna nie jest zbieżna dla każdego układu równań, ale można sprawdzić czy dany układ równań jest rozwiązywalny daną metodą

Metoda iteracyjna:

$$\mathbf{x}^{(i+1)} = \mathbf{M}\mathbf{x}^{(i)} + \mathbf{w}$$

Jest zbieżna gdy spełniony jest **warunek zbieżności**:

$$\rho(\mathbf{M}) < 1$$

oraz **zachodzi warunek zgodności**:

$$\dot{\mathbf{x}} = \mathbf{M}\dot{\mathbf{x}} + \mathbf{w}$$


Który oznacza, że dla dokładnych danych $\dot{\mathbf{x}}$ równanie iteracyjne jest spełnione.

Szybkość zbieżności jest tym większa im mniejszy jest promień spektralny macierzy.

Zbiór wszystkich wartości własnych macierzy $\mathbf{A}$ nazywamy *widmem (spectrum)* tej macierzy i oznaczamy symbolem $Spect(\mathbf{A})$, największa co do modułu wartość własna to promień spektralny macierzy.

$$\rho(\mathbf{M}) = \{\max(|\lambda|) \mid \lambda \in Spect(\mathbf{M})\}$$

WŁAŚCIWOŚCI METOD ITERACYJNYCH – postać ogólna metod iteracyjnych



WŁAŚCIWOŚCI METOD ITERACYJNYCH – postać ogólna metod iteracyjnych

- Metoda iteracyjna nie jest zbieżna dla każdego układu równań, ale można sprawdzić czy dany układ równań jest rozwiązywalny daną metodą

Metoda iteracyjna:

$$\mathbf{x}^{(i+1)} = \mathbf{M}\mathbf{x}^{(i)} + \mathbf{w}$$

Jest zbieżna gdy spełniony jest **warunek zbieżności**:

$$\rho(\mathbf{M}) < 1$$

oraz **zachodzi warunek zgodności**:

$$\dot{\mathbf{x}} = \mathbf{M}\dot{\mathbf{x}} + \mathbf{w}$$

Wszystkie metody jakie poznamy na zajęciach spełniają ten warunek zawsze

Który oznacza, że dla dokładnych danych $\dot{\mathbf{x}}$ równanie iteracyjne jest spełnione.

Szybkość zbieżności jest tym większa im mniejszy jest promień spektralny macierzy.

Zbiór wszystkich wartości własnych macierzy $\mathbf{A}$ nazywamy *widmem (spectrum)* tej macierzy i oznaczamy symbolem $Spect(\mathbf{A})$, największa co do modułu wartość własna to promień spektralny macierzy.

$$\rho(\mathbf{M}) = \{ \max(|\lambda|) \mid \lambda \in Spect(\mathbf{M}) \}$$


WŁAŚCIWOŚCI METOD ITERACYJNYCH – postać ogólna metod iteracyjnych

- Metoda iteracyjna nie jest zbieżna dla każdego układu równań, ale można sprawdzić czy dany układ równań jest rozwiązywalny daną metodą

Metoda iteracyjna:

$$\mathbf{x}^{(i+1)} = \mathbf{M}\mathbf{x}^{(i)} + \mathbf{w}$$

Jest zbieżna gdy spełniony jest **warunek zbieżności**:

$$\rho(\mathbf{M}) < 1$$


Ta właściwość pozwala nam na sterowanie szybkością zbieżności poprzez takie skonstruowanie wzoru iteracyjnego, aby zminimalizować promień spektralny macierzy $\mathbf{M}$

Szybkość zbieżności jest tym większa im mniejszy jest promień spektralny macierzy.

Zbiór wszystkich wartości własnych macierzy $\mathbf{A}$ nazywamy *widmem (spectrum)* tej macierzy i oznaczamy symbolem $Spect(\mathbf{A})$, największa co do modułu wartość własna to promień spektralny macierzy.

$$\rho(\mathbf{M}) = \{ \max(|\lambda|) \mid \lambda \in Spect(\mathbf{M}) \}$$

Metoda Richardsona:

$$\mathbf{Ax} = \mathbf{b}$$

$$p\mathbf{Ax} = p\mathbf{b}$$

$$\mathbf{x} - \mathbf{x} + p\mathbf{Ax} = p\mathbf{b}$$

$$\mathbf{x} = \mathbf{Ix} - p\mathbf{Ax} + p\mathbf{b}$$

$$\mathbf{x}^{(i+1)} = (\mathbf{I} - p\mathbf{A})\mathbf{x}^{(i)} + p\mathbf{b}$$

Zatem w metodzie Richardsona:

$$\mathbf{M} = \mathbf{I} - p\mathbf{A}$$

$$\mathbf{w} = p\mathbf{b}$$

- Parametr p pozwala na sterowanie szybkością zbieżności metody – ma wpływ na promień spektralny macierzy

POSTAĆ OGÓLNA:

$$\mathbf{x} = \mathbf{Mx} + \mathbf{w}$$

WŁAŚCIWOŚCI METOD ITERACYJNYCH – metoda Richardsona



WŁAŚCIWOŚCI METOD ITERACYJNYCH – metoda Gaussa-Seidla

Metoda Gaussa-Seidla

$$\mathbf{Ax} = \mathbf{b}$$

$$\mathbf{A} = \mathbf{L} + \mathbf{D} + \mathbf{U}$$

gdzie: L-macierz trójkątna dolna, U – macierz trójkątna górna, D – macierz diagonalna

$$(\mathbf{L} + \mathbf{D})\mathbf{x} = -\mathbf{U}\mathbf{x} + \mathbf{b}$$

$$\mathbf{D}\mathbf{x}^{(i+1)} = -\mathbf{L}\mathbf{x}^{(i+1)} - \mathbf{U}\mathbf{x}^{(i)} + \mathbf{b}$$

$$\mathbf{x}^{(i+1)} = -\mathbf{D}^{-1}\mathbf{L}\mathbf{x}^{(i+1)} - \mathbf{D}^{-1}\mathbf{U}\mathbf{x}^{(i)} + \mathbf{D}^{-1}\mathbf{b}$$

Czy to jest możliwe -

$\mathbf{x}^{(i+1)}$ występuje również po prawej stronie równania?

POSTAĆ OGÓLNA:

$$\mathbf{x} = \mathbf{M}\mathbf{x} + \mathbf{w}$$

Metoda Gaussa-Seidla opiera się na założeniu, że kolejne dwa przybliżenia spełniają następujące równania:

$$a_{m1}x_1^{(i+1)} + a_{m2}x_2^{(i+1)} + \dots + a_{mm}x_m^{(i+1)} + a_{m,m+1}x_{m+1}^{(i)} + \dots + a_{mN}x_N^{(i)} = b_m$$


Czyli korzystamy z tych wartości, które znamy! Ogólnie:

$$x_m^{(i+1)} = x_m^{(i)} - \frac{1}{a_{mm}} \left(\sum_{n=1}^{m-1} a_{mn}x_n^{(i+1)} + \sum_{n=m}^N a_{mn}x_n^{(i)} - b_m \right) \quad m = 1, \dots, N$$

$$\mathbf{M} = (\mathbf{D} + \mathbf{L})^{-1}(-\mathbf{U})$$

$$\mathbf{w} = (\mathbf{D} + \mathbf{L})^{-1}\mathbf{b}$$

WŁAŚCIWOŚCI METOD ITERACYJNYCH – metoda Gaussa-Seidla



Tak działa przyspieszanie zbieżności za pomocą zmiany algorytmu.

Okupione jest jednak ograniczeniem ilości układów, które można rozwiązać tą metodą

WŁAŚCIWOŚCI METOD ITERACYJNYCH – metoda Sukcesywnej nadrelaksacji (SOR)

Metoda SOR

$$\mathbf{Ax} = \mathbf{b}$$

$$\mathbf{A} = \mathbf{L} + \mathbf{D} + \mathbf{U}$$

gdzie: $\mathbf{L}$ – macierz trójkątna dolna, $\mathbf{U}$ – macierz trójkątna górna, $\mathbf{D}$ – macierz diagonalna

$$(\mathbf{L} + \mathbf{D})\mathbf{x} = -\mathbf{U}\mathbf{x} + \mathbf{b}$$

$$\mathbf{D}\mathbf{x}^{(i+1)} = -\mathbf{L}\mathbf{x}^{(i+1)} - \mathbf{U}\mathbf{x}^{(i)} + \mathbf{b}$$

$$\mathbf{x}^{(i+1)} = -\mathbf{D}^{-1}\mathbf{L}\mathbf{x}^{(i+1)} - \mathbf{D}^{-1}\mathbf{U}\mathbf{x}^{(i)} + \mathbf{D}^{-1}\mathbf{b}$$

Czy to jest możliwe -
 $\mathbf{x}^{(i+1)}$ występuje również po prawej
stronie równania?

POSTAĆ OGÓLNA:

$$\mathbf{x} = \mathbf{M}\mathbf{x} + \mathbf{w}$$

Korzystamy z tych wartości, które znamy!

$$x_m^{(i+1)} = x_m^{(i)} - \frac{\omega}{a_{mm}} \left(\sum_{n=1}^{m-1} a_{mn} x_n^{(i+1)} + \sum_{n=m}^N a_{mn} x_n^{(i)} - b_m \right) \quad m = 1, \dots, N$$

Parametr ω ma takie samo zadanie jak parametr p w metodzie Richardsona – wpływa na szybkość zbieżności.

$$\mathbf{M} = (\mathbf{D} + \omega\mathbf{L})^{-1}((1 - \omega)\mathbf{D} - \omega\mathbf{U})$$

$$\mathbf{w} = \omega(\mathbf{D} + \omega\mathbf{L})^{-1}\mathbf{b}$$

Równania liniowe – jak wybrać najlepszą metodę

Pytania, które warto sobie zadać:

- jak duży (i czy rzadki) jest układ,
- czy trzeba go rozwiązać wielokrotnie z różnymi wymuszeniami $\mathbf{b}$,
- jak dobre jest jego uwarunkowanie.

Sytuacja	Zalecana metoda	Dlaczego
Mały/średni układ, rozwiązywany raz	Rozkład LU (z pivotingiem)	Najprostsza, wystarczająco dokładna dla jednorazowego rozwiązania
Ten sam układ $\mathbf{A}$, wiele różnych $\mathbf{b}$ (np. symulacja z wieloma wymuszeniami)	Rozkład LU (z pivotingiem)	Koszt rozkładu ($O(n^3)$) ponosimy raz, każde kolejne rozwiązanie kosztuje tylko $O(n^2)$
Układ prostokątny/nadokreślony, albo brak pewności co do stabilności LU dla danej macierzy $\mathbf{A}$	Rozkład QR	Jedyna z tych metod działająca też dla macierzy prostokątnych; gwarantowana stabilność numeryczna niezależna od konkretnej macierzy $\mathbf{A}$ — kosztem droższego rozkładu
Duży, rzadki układ (np. z MES, różnic skończonych)	Metody iteracyjne (Jacobi, Gauss-Seidla, SOR)	Gęsta reprezentacja fizycznie nie mieści się w pamięci — metody iteracyjne wykorzystują rzadkość macierzy zamiast ją niszczyć

**Politechnika
Warszawska**

Dziękuję za uwagę

