

APROKSYMACJA

CO TO JEST APROKSYMACJA?

Aproksymacja jest problemem numerycznym bardzo podobnym do interpolacji, ale stosowanym do innego rodzaju zagadnień. Będziemy mówili o dwóch zasadniczych rodzajach aproksymacji:

- Aproksymacji dyskretnej – ten problem jest najbardziej podobny do tego co mówiliśmy w rozdziale o interpolacji. Danymi wejściowymi do tego problemu jest zbiór punktów podobnie jak w przypadku interpolacji wraz z przedziałem $[a,b]$, natomiast danymi wyjściowymi są współczynniki funkcji odwzorowującej kształt
- Aproksymacji ciągłej – mamy tutaj do czynienia z przypadkiem, kiedy znamy wzór funkcji oryginalnej, ale z jakichś powodów chcemy odwzorować ją za pomocą innych funkcji, z którymi łatwiej nam sobie radzić w dalszych działaniach, a zależy nam na dobrym odwzorowaniu jej kształtu w jakimś przedziale $[a,b]$. Danymi wyjściowymi jest również zbiór współczynników – podobnie jak w przypadku interpolacji.

Analizę zaczniemy od aproksymacji dyskretnej. Zanim jednak do tego przejdziemy musimy zrozumieć czym jest w rzeczywistości aproksymacja i czym różni się od interpolacji. Zasadnicza różnica polega na tym, że nie wymagamy teraz przechodzenia przez punkty z danych wejściowych, bo zakładamy, że dane te nie są dokładne i punkty te w rzeczywistości nie leżą na niej (zakładamy stosunkowo duży błąd danych wejściowych). Wynika z tego druga ważna różnica – postać funkcji jaką będziemy starali się odwzorować oryginalną zależność nie jest ściśle związana z ilością danych wejściowych (tak jak było to w przypadku interpolacji), a postać funkcji aproksymującej (nazywana dalej **modelem**) jest przyjmowana przed rozwiązaniem na podstawie innych, nienumerycznych kryteriów przez użytkownika danej metody. **Oznacza to, że nawet jeżeli procedury numeryczne powiodą się z małym błędem efekt może być niezadowolający, jeżeli model został nieprawidłowo przyjęty.**

Aproksymacja jest szczególnym, najprostszym przypadkiem bardziej ogólnego problemu numerycznego zwanego regresją. Regresja, a w tym aproksymacja, jest bardzo ważną i szeroko stosowaną techniką numeryczną, która służy do analizy wszelkich danych pomiarowych, od pomiarów fizycznych w CERN, przez pomiary elektroniczne wykonywane na systemach embedded po analizę danych z ankiet telefonicznych. Omówienie definicji i założeń problemu regresji dobrze tłumaczy do czego aproksymację się stosuje.

W każdym problemie regresji, w tym w aproksymacji, zakładamy, że dane wejściowe zawierające użyteczną informację o charakterze deterministycznym zawierają w sobie również część stochastyczną (losową) traktowaną w definicji naszego problemu jako szum. Można to zapisać następująco:

$$Y_i = f(x_i) + \epsilon_i \quad (1)$$

Gdzie Y_i są to wartości naszych danych wejściowych dla x_i (x_i i Y_i tworzą razem punkt danych wejściowych), $f(x_i)$ to zależność oryginalna, deterministyczna, której znalezienie nas interesuje, a ϵ_i to szum który dodaje się do naszej oryginalnej zależności zaburzając wartości.

Celem każdej regresji, a w tym aproksymacji, jest odtworzenie parametrów opisujących oryginalną zależność na podstawie tych danych oraz założonej formy równania opisującej $f(x)$ - modelu. Aproksymacja tym różni się od regresji, że w aproksymacji nie przyjmujemy dowolnego modelu (np. zgodnego z postacią fizyczną), ale model tworzony podobnie jak w przypadku interpolacji jako suma ciągu funkcji wybieranych z pewnego szeregu, a jedynymi współczynnikami są te stojące przed daną składową funkcją (liniowa kombinacja składowych szeregu)¹. Zatem postać rozwiązania problemu aproksymacji wygląda następująco:

$$\tilde{f}(x, p) = \sum_{k=1}^K p_k \varphi_k(x) \quad (2)$$

Co oznacza, że funkcją przybliżającą przebieg oryginalny $\tilde{f}(x, p)$ stworzymy z funkcji $\varphi_k(x)$ z szeregu i współczynników p stojących przed tymi funkcjami. Fizyka bardzo rzadko jest opisana taką prostą kombinacją funkcji, zatem model przyjęty w problemie aproksymacji jest modelem nie fizycznym i ma na celu głównie odwzorowanie kształtu (podobnie jak w przypadku interpolacji), a wyliczone współczynniki najczęściej nie mają

¹W przypadku rozwiązania problemu regresji moglibyśmy przyjąć dowolnie skomplikowany model z dowolną ilością współczynników. Niemniej wtedy metody numeryczne służące do rozwiązania tego problemu znacznie się komplikują w stosunku do tego o czym będziemy mówić tutaj. Na tym wykładzie nie będziemy poruszać problemu regresji, ale to on jest najczęściej wykorzystywany.

jakiegoś szczególnego znaczenia. Można więc stwierdzić, że aproksymacja jest takim szczególnym rodzajem regresji.

Każda regresja, w tym aproksymacja, rozwiązuje ten problem starając się dobrać taki zestaw współczynników $\mathbf{p}$, aby zminimalizować błąd odwzorowania w pewnym przedziale $[a, b]$. Błąd ten musi być wyrażony liczbowo w taki sposób, żeby minimum funkcji go opisującej (**zwanej dalej funkcją celu**) było jednoznaczne z minimalizacją samego błędu. A same metody są metodami szukania minimum tej funkcji. Można to zapisać następująco:

$$\min(\|\mathbf{Y}_i - \tilde{\mathbf{y}}_i\|) \quad (3)$$

tutaj $\mathbf{Y}_i$ to wektor wartości danych wejściowych w węzłach aproksymacji, $\tilde{\mathbf{y}}_i$ to wektor wartości naszej funkcji przybliżającej uzyskanej jako rozwiązanie dla tych samych wartości x co węzły interpolacji. Szukamy takiej funkcji w której norma tych różnic jest najmniejsza. Tylko powstaje pytanie która norma?

Od tego jaką normę wybierzemy do rozwiązanie naszego problemu aproksymacji zależą budowa i właściwości metod je rozwiązujących. Na tej podstawie można dalej podzielić aproksymacje na różne grupy: aproksymację średniokwadratową (bazującą na normie 2) i aproksymację min-maxową (bazującą na normie maksimum). Inne rodzaje też teoretycznie są możliwe do stworzenia, ale raczej praktycznie się ich nie spotyka. Najczęściej spotykana jest aproksymacja średniokwadratowa (stanowiąca ~90% przypadków) i na niej się tu skupimy. Aproksymacja min-maxowa stosowana jest dużo rzadziej i prowadzi do znacznie bardziej skomplikowanej matematyki. Niezależnie od tego jaką normę przyjmujemy schemat ogólny rozwiązania problemu aproksymacji jest taki sam, różnice wyrażają się szczegółowymi wzorami i z nich wynikają.

OGÓLNY PRZEBIEG APROKSYMACJI DYSKRETNEJ (NA PRZYKŁADZIE APROKSYMACJI ŚREDNIOKWADRATOWEJ)

W celu dokonania aproksymacji dyskretniej poruszamy się według pewnego schematu. Po pierwsze musimy przyjąć jakiś model. W przypadku aproksymacji przyjmujemy sumę iloczynów K funkcji z przyjętego szeregu ze współczynnikami p_k . Zatem przyjmujemy jakiś szereg funkcji i w konsekwencji nasza funkcja aproksymująca to:

$$\tilde{f}(x, \mathbf{p}) = \sum_{k=1}^K p_k \varphi_k(x) \quad (4)$$

Podobnie jak w przypadku problemu interpolacji budujemy układ równań. Tym razem nie wynika on stąd, że funkcja przechodzi przez węzły – bo nie przechodzi. Zapiszemy po prostu powyższe równanie w formie macierzowej dla x odpowiadającej każdemu z węzłów:

$$\tilde{f}(x, \mathbf{p}) = \mathbf{\Phi} \mathbf{p} \quad (5)$$

gdzie macierz $\mathbf{\Phi}$ ma formę:

$$\mathbf{\Phi} = \begin{bmatrix} \varphi_1(x_1) & \varphi_2(x_1) & \dots & \varphi_K(x_1) \\ \varphi_1(x_2) & \varphi_2(x_2) & \dots & \varphi_K(x_2) \\ \vdots & \vdots & \ddots & \vdots \\ \varphi_1(x_N) & \varphi_2(x_N) & \dots & \varphi_K(x_N) \end{bmatrix} \quad (6)$$

A wektor $\mathbf{p}$:

$$\mathbf{p} = \begin{bmatrix} p_1 \\ p_2 \\ \vdots \\ p_K \end{bmatrix} \quad (7)$$

Taką formę musimy uwzględnić w naszej funkcji celu. Przez $\mathbf{r}$ oznaczmy **wektor residuów**, czyli wektor różnic między naszymi danymi a naszym dopasowaniem (funkcja aproksymująca) dla wartości x takich samych jak węzły aproksymacji:

$$\mathbf{r} = \mathbf{Y}_i - \tilde{\mathbf{f}}(\mathbf{x}_i, \mathbf{p}) \quad (8)$$

podstawiając:

$$\mathbf{r} = \mathbf{Y}_i - \mathbf{\Phi} \mathbf{p} \quad (9)$$

Teraz musimy wprowadzić funkcję celu właściwą dla rodzaju przyjętej normy. Dla normy średniokwadratowej będzie to postać pokazana poniżej² (ale dla aproksymacji min-maxowej równania zaczną przyjmować inną postać):

$$J_2(p) = \|\mathbf{r}\|_2 = \sum_{n=1}^N r_n^2 \quad (11)$$

Dalsza część tego wywodu opiera się na właściwościach normy 2, dla aproksymacji minmaksowej zależności będą znacznie różne. Powyższą zależność można zapisać w formie:

$$J_2(p) = \mathbf{r}^T \mathbf{r} = (\mathbf{Y}_i - \mathbf{\Phi} \mathbf{p})^T (\mathbf{Y}_i - \mathbf{\Phi} \mathbf{p}) \quad (12)$$

Zwróć uwagę, że niewiadomymi w tej funkcji jest wektor $\mathbf{p}$, natomiast wartości x_i traktujemy jako dane – liczby. Bo też liczbami są – mamy je przecież podane jako liczby w danych wejściowych. Dla pełnego zrozumienia co skąd bierze się ostateczna postać układu równań, który musimy rozwiązać przeprowadzimy tutaj całość wywodu, ale wniosek natury ogólnej podany na końcu – sposób budowy układu równań za pomocą iloczynów skalarnych jest najważniejszą informacją. Wymnażając równanie:

$$J_2(p) = \mathbf{Y}_i^T \mathbf{Y}_i - \mathbf{p}^T \mathbf{\Phi}^T \mathbf{Y}_i - \mathbf{Y}_i^T \mathbf{\Phi} \mathbf{p} + \mathbf{p}^T \mathbf{\Phi}^T \mathbf{\Phi} \mathbf{p} \quad (13)$$

Wiemy, że norma jest wartością skalarną. A skoro tak to każdy ze składników tej sumy też musi być skalarą. Natomiast transpozycja skalarów też jest skalarą (i to takim samym), zatem:

$$\mathbf{p}^T \mathbf{\Phi}^T \mathbf{Y}_i = (\mathbf{p}^T \mathbf{\Phi}^T \mathbf{Y}_i)^T = \mathbf{Y}_i^T \mathbf{\Phi} \mathbf{p} \quad (14)$$

i:

$$J_2(p) = \mathbf{Y}_i^T \mathbf{Y}_i - 2 \mathbf{Y}_i^T \mathbf{\Phi} \mathbf{p} + \mathbf{p}^T \mathbf{\Phi}^T \mathbf{\Phi} \mathbf{p} \quad (15)$$

Aby rozwiązać problem aproksymacji musimy teraz znaleźć taki zestaw współczynników p_k , żeby powyższa funkcja przyjęła minimum. Ten zestaw jest rozwiązaniem naszego problemu. Funkcja przyjmuje minimum, kiedy:

$$\frac{\delta J_2(p)}{\delta p_k} = 0 \quad (16)$$

Warunek ten tworzy równoważny układ równań liniowych w postaci³:

$$\mathbf{\Phi}^T \mathbf{\Phi} \mathbf{p} = \mathbf{\Phi}^T \mathbf{Y}_i \quad (17)$$

Podobnie jak dla interpolacji doszliśmy do układu równań liniowych, którego rozwiązanie jest rozwiązaniem naszego problemu. Układ ten jest układem określonym mającym jednoznaczne rozwiązanie⁴.

Jeżeli przyjmiemy taki model, że $K = N$ to okaże się, że równania przyjmą taką samą postać jak dla interpolacji. Można więc dalej powiedzieć, że interpolacja jest szczególnym przypadkiem aproksymacji.

Chociaż już powiedzieliśmy sobie jak zaimplementować prostą aproksymację zrobimy jeszcze jeden eksperyment – pomnożymy dwa pierwsze wiersze macierzy $\mathbf{\Phi}^T \mathbf{\Phi}$. Dla pierwszego elementu macierzy $\mathbf{A}$ uzyskamy:

$$\mathbf{A} = \mathbf{\Phi}^T \mathbf{\Phi} = \begin{bmatrix} \varphi_1(x_1) & \varphi_1(x_2) & \dots & \varphi_1(x_N) \\ \varphi_2(x_1) & \varphi_2(x_2) & \dots & \varphi_2(x_N) \\ \vdots & \vdots & \ddots & \vdots \\ \varphi_K(x_1) & \varphi_K(x_2) & \dots & \varphi_K(x_N) \end{bmatrix} \begin{bmatrix} \varphi_1(x_1) & \varphi_2(x_1) & \dots & \varphi_K(x_1) \\ \varphi_1(x_2) & \varphi_2(x_2) & \dots & \varphi_K(x_2) \\ \vdots & \vdots & \ddots & \vdots \\ \varphi_1(x_N) & \varphi_2(x_N) & \dots & \varphi_K(x_N) \end{bmatrix} \quad (18)$$

$$a_{1,1} = \sum_{i=1}^N \varphi_1(x_i) \varphi_1(x_i) \quad (19)$$

² Mogłoby zauważyć, że nie jest to dokładnie postać normy 2. To prawda, to funkcja prostsza, ale mająca minimum w tym samym punkcie co norma druga. Tak naprawdę wartość funkcji celu w aproksymacji średniokwadratowej powinna wyglądać tak:

$$J'_2(p) = \sqrt{\sum_{n=1}^N r_n^2} \text{ lub czasami w ujęciu metrologicznym } J'_2(p) = \sqrt{\frac{1}{N} \sum_{n=1}^N r_n^2} \quad (10)$$

Ale ponieważ pierwiastek jest funkcją monotoniczną to minimum tej funkcji jest takie samo jak minimum funkcji bez pierwiastka. Zatem w przypadku aproksymacji przyjmuje się jako funkcję celu wersję bez pierwiastka

³ Wyprowadzenie dla czytelności tutaj nie zawarte, ale dla dociekliwych załączone na końcu w dodatku.

⁴ Ponieważ postać funkcji odwzorowującej nie jest powiązana z ilością węzłów to $K \neq N$ to macierz $\mathbf{\Phi}$ nie jest macierzą kwadratową. Ale macierz $\mathbf{A} = \mathbf{\Phi}^T \mathbf{\Phi}$ już jest.

Dla drugiego:

$$a_{1,2} = \sum_{i=1}^N \varphi_1(x_i) \varphi_2(x_i) \quad (20)$$

Itđ. Dobrym i prostym ćwiczaniem jest sprawdzenie, że każdy element tej macierzy można wyrazić wzorem:

$$a_{j,m} = \sum_{i=1}^N \varphi_j(x_i) \varphi_m(x_i) \quad (21)$$

Wyrażenie:

$$(\mathbf{x}, \mathbf{y}) = \sum_{k=1}^n x_k y_k \quad (22)$$

będziemy nazywać iloczynem skalarnym. Iloczyn skalarny jest przemienny tzn: $(\mathbf{x}, \mathbf{y}) = (\mathbf{y}, \mathbf{x})$

Dlatego można powiedzieć, że układ równań liniowych, którego rozwiązanie jest tożsame z rozwiązaniem problemu aproksymacji ma następującą postać:

$$\mathbf{A} = \begin{bmatrix} (\varphi_1, \varphi_1) & (\varphi_1, \varphi_2) & \dots & (\varphi_1, \varphi_K) \\ (\varphi_2, \varphi_1) & (\varphi_2, \varphi_2) & \dots & (\varphi_2, \varphi_K) \\ \vdots & \vdots & \ddots & \vdots \\ (\varphi_K, \varphi_1) & (\varphi_K, \varphi_2) & \dots & (\varphi_K, \varphi_K) \end{bmatrix} \quad (23)$$

Natomiast wektor $\mathbf{b}$:

$$\mathbf{b} = \begin{bmatrix} (\varphi_1, \mathbf{Y}) \\ (\varphi_2, \mathbf{Y}) \\ \vdots \\ (\varphi_K, \mathbf{Y}) \end{bmatrix} \quad (24)$$

A ogólna postać układu równań (w ogólnym przypadku nadokreślonego) budowanego do rozwiązania problemu aproksymacji wygląda następująco:


$$\mathbf{A}\mathbf{p} = \mathbf{b} \quad (25)$$

$$\begin{bmatrix} (\varphi_1, \varphi_1) & (\varphi_1, \varphi_2) & \dots & (\varphi_1, \varphi_K) \\ (\varphi_2, \varphi_1) & (\varphi_2, \varphi_2) & \dots & (\varphi_2, \varphi_K) \\ \vdots & \vdots & \ddots & \vdots \\ (\varphi_K, \varphi_1) & (\varphi_K, \varphi_2) & \dots & (\varphi_K, \varphi_K) \end{bmatrix} \mathbf{p} = \begin{bmatrix} (\varphi_1, \mathbf{Y}) \\ (\varphi_2, \mathbf{Y}) \\ \vdots \\ (\varphi_K, \mathbf{Y}) \end{bmatrix} \quad (26)$$

PRZYKŁAD 1

Przypuśćmy, że nasz wejściowy zestaw punktów wygląda następująco (punkty pochodzą z zależności x^2 , ale ich wartości są zaburzone na dosyć dużym poziomie). Kółkami zaznaczono węzły aproksymacji, a linią czerwoną oryginalną zależność x^2 .

x	1	2	3	4
Y	1.1	4.2	8.8	16.6



Najpierw musimy przyjąć jakiś model. Przyjmijmy, że model wielomian wyrażony za pomocą ciągu wielomianów naturalnych $1, x, x^2, x^3, \dots$. Weźmy 3 pierwsze funkcje z tego ciągu (to też przyjmujemy arbitralnie) a w konsekwencji nasza funkcja aproksymująca będzie miała postać:

$$\tilde{f}(x, p) = \sum_{k=1}^3 p_k \varphi_k(x) = p_1 1 + p_2 x + p_3 x^2 \quad (27)$$

Zbudujemy więc nasz układ równań który będziemy rozwiązywać:

$$\mathbf{A} = \begin{bmatrix} (\varphi_1, \varphi_1) & (\varphi_1, \varphi_2) & (\varphi_1, \varphi_3) \\ (\varphi_2, \varphi_1) & (\varphi_2, \varphi_2) & (\varphi_2, \varphi_3) \\ (\varphi_3, \varphi_1) & (\varphi_3, \varphi_2) & (\varphi_3, \varphi_3) \end{bmatrix} = \begin{bmatrix} (\mathbf{1}, \mathbf{1}) & (\mathbf{1}, \mathbf{x}) & (\mathbf{1}, \mathbf{x}^2) \\ (\mathbf{x}, \mathbf{1}) & (\mathbf{x}, \mathbf{x}) & (\mathbf{x}, \mathbf{x}^2) \\ (\mathbf{x}^2, \mathbf{1}) & (\mathbf{x}^2, \mathbf{x}) & (\mathbf{x}^2, \mathbf{x}^2) \end{bmatrix} \quad (28)$$

Gdzie przez $\mathbf{x}$ i $\mathbf{x}^2$ oznaczyłem symbolicznie wektory funkcji z ciągu w punktach $x \in [1 \ 2 \ 3 \ 4]$. Obliczmy elementy macierzy A. Najpierw na diagonalu:

$$a_{1,1} = (\varphi_1, \varphi_1) = \sum_{k=1}^4 \varphi_1(x_i) \varphi_1(x_i) = 1 + 1 + 1 + 1 = 4 \quad (29)$$

$$a_{2,2} = (\varphi_2, \varphi_2) = \sum_{k=1}^4 \varphi_2(x_i) \varphi_2(x_i) = x_1^2 + x_2^2 + x_3^2 + x_4^2 = 1 + 4 + 9 + 16 = 30 \quad (30)$$

$$a_{3,3} = (\varphi_3, \varphi_3) = \sum_{k=1}^4 \varphi_3(x_i) \varphi_3(x_i) = x_1^4 + x_2^4 + x_3^4 + x_4^4 = 1 + 16 + 81 + 256 = 354 \quad (31)$$

A potem na prawo od niej (ze względu na przemienność iloczynu skalarnego – patrz ramka – elementy w tej macierzy są rozłożone symetrycznie względem diagonalu):

$$a_{1,2} = (\varphi_1, \varphi_2) = \sum_{k=1}^4 \varphi_1(x_i) \varphi_2(x_i) = 1x_1 + 1x_2 + 1x_3 + 1x_4 = 1 + 2 + 3 + 4 = 10 \quad (32)$$

$$a_{1,3} = (\varphi_1, \varphi_3) = \sum_{k=1}^4 \varphi_1(x_i) \varphi_3(x_i) = 1x_1^2 + 1x_2^2 + 1x_3^2 + 1x_4^2 = 30 \quad (33)$$

$$a_{2,3} = (\varphi_2, \varphi_3) = \sum_{k=1}^4 \varphi_2(x_i) \varphi_3(x_i) = x_1^3 + x_2^3 + x_3^3 + x_4^3 = 100 \quad (34)$$

Ostatecznie macierz A układu równań:

$$\mathbf{A} = \begin{bmatrix} 4 & 10 & 30 \\ 10 & 30 & 100 \\ 30 & 100 & 354 \end{bmatrix} \quad (35)$$


Analogicznie postępujemy z wektorem $\mathbf{b}$:

$$\mathbf{b} = \begin{bmatrix} (\varphi_1, \mathbf{Y}) \\ (\varphi_2, \mathbf{Y}) \\ (\varphi_3, \mathbf{Y}) \end{bmatrix} = \begin{bmatrix} 30.7 \\ 102.3 \\ 362.7 \end{bmatrix} \quad (36)$$

Rozwiązaniem tego układu równań jest:

$$\mathbf{p} = \begin{bmatrix} 0.775 \\ -0.765 \\ 1.175 \end{bmatrix} \quad (37)$$


Funkcje aproksymującą pokazano poniżej kolorem zielonym:



Przykład 2 Powtórzmy to samo rozumowanie, ale dla funkcji e^x :

x	1	2	3	4
Y	2.8	8.4	20.1	55.0

Wynik uzyskamy taki:



Widać wyraźniej, że funkcja aproksymująca w znacznie mniejszym stopniu przypomina funkcję oryginalną. Jest to spowodowane tym, że przyjęty model w postaci wielomianu drugiego stopnia nie może dobrze odwzorowywać kształtu funkcji oryginalnej.

Powstają zatem pytania:

- jak sprawdzić, czy nasz model dobrze oddaje oryginalną zależność?
- Jeżeli nawet mamy model potencjalnie dobrze oddający oryginalną zależność deterministyczną to jak polepszyć odwzorowanie kształtu i od czego ono zależy.

OGÓLNE WŁAŚCIWOŚCI REGRESJI (W TYM APROKSYMACJI)

Do oceny tego czy przyjęty model potrafi odwzorować kształt zależności oryginalnej posługujemy się wektorem residuów $\mathbf{r}$. Narzucającą się miarą jakości odwzorowania jest wielkość funkcji celu np.:

$$S(\mathbf{w}) = \|\mathbf{r}\|_2 = \|\mathbf{Y} - \mathbf{f}(\mathbf{w}, \mathbf{x})\|_2 = \sum (Y_i - \tilde{f}(\mathbf{w}, x_i))^2 \quad (38)$$

Choć jest to miara poprawna to nie pozwala na porównywanie ze sobą kilku zestawów danych ponieważ operuje ona na wartościach bezwzględnych. Dlatego np. porównanie dwóch dopasowań do tego samego modelu przy danych pomiarowych różnych o kilka rzędów wielkości będzie trudne lub niewykonalne. Dlatego stosuje się różne miary liczbowe oparte o statystykę lub probabilistykę. Najpowszechniej stosowane są:

- Miara R^2

Jeżeli średnią wartość zbioru danych wejściowych Y_i można przedstawić jako:

$$\bar{y} = \frac{1}{n} \sum_{i=1}^N Y_i \quad (39)$$

Wtedy można zdefiniować miarę dokładności następująco:

Wartość $SS_{tot} = \sum_i (Y_i - \bar{y})^2$ będziemy nazywać całkowitą sumą kwadratów

Wartość $SS_{reg} = \sum_i (\tilde{f}(x_i) - \bar{y})^2$ będziemy nazywać całkowitą sumą regresji

To miarą dokładności dopasowania będzie:

$$R^2 = \frac{SS_{reg}}{SS_{tot}} \quad (40)$$

I dopasowanie jest tym lepsze im miara ta jest bliższa 1

- Miara χ^2

Jest to miara probabilistyczna – zakłada, że rozkład błędów ϵ_i jest rozkładem normalnym.

Stąd:

$$\chi^2 = \sum_{i=1}^N \left(\frac{y_i - \tilde{y}_i}{\sigma_i} \right)^2 \quad (41)$$

Odwzorowanie jest tym lepsze im niższa jest wartość tej miary.

Przyjęcie najlepszego modelu jest rzeczą trudną. W praktyce często opiera się to na wiedzy dotyczącej zagadnienia spoza metod numerycznych. Często też odbywa się to metodą iteracyjną. Jednak w pewnym szczególnym przypadku – kiedy nie interesują nas współczynniki modelu ale zamiana oryginalnej zależności na w miarę dobrze odwzorowującą ją funkcję o zadanej postaci możemy trzymać się pewnych reguł matematycznych. Z takich samych powodów jak w przypadku interpolacji (łatwe całkowanie/różniczkowanie) do ogólnego odwzorowania kształtu stosujemy ciągi w postaci wielomianów. Ponieważ taki przypadek jest dosyć częsty został bardziej szczegółowo zanalizowany.

APROKSYMACJA WIELOMIANOWA

TWIERDZENIE STONE'A-WEIERSTRASSA

Dla dowolnej funkcji $f(x)$ ciągłej w przedziale $[a, b]$ ($f \in C_{\mathbb{R}}[a, b]$) istnieje taki ciąg wielomianów $P_N(x)$ o współczynnikach rzeczywistych, że:

$$P_N(x) \xrightarrow{N \rightarrow \infty} f(x) \quad (42)$$

Oznacza to, że dla dowolnie przyjętego błędu δ istnieje taki stopień wielomianu N , że błąd – liczony **jednostajnie w całym przedziale $[a, b]$** , a nie tylko w wybranych punktach – nie będzie większy niż δ . Twierdzenie nie mówi jaki to jest stopień, ale tylko tyle, że istnieje. W praktyce jeżeli chcemy dokonać aproksymacji musimy wybrać stopień dostatecznie wysoki, żeby zapewnić dokładność, ale nie wyższy. Można to zrozumieć, jeżeli weźmiemy pod uwagę, że dla aproksymacji o stopniu $N-1$ (gdzie N to ilość punktów) aproksymacja staje się interpolacją i ze wszystkimi jej problemami omówionymi wcześniej.

W praktyce robi się to dla konkretnego problemu metodą iteracyjną jako kryterium często przyjmując dobranie takiej wartości M (stopień wielomianu aproksymującego), która minimalizuje wartość wariancji wartości residuów wyrażonej wzorem:

$$v = \frac{\sum (r_i)^2}{N - M - 1} = \frac{\mathbf{r}^2}{N - M - 1} \quad (43)$$

gdzie: M - stopień wielomianu aproksymującego, N - ilość punktów⁵, $\mathbf{r}$ jest wektorem residuów.

Jeżeli nie ma wyraźnego minimum to jako punkt optymalny przyjmujemy wartość M dla której dalsze zwiększanie stopnia wielomianu nie powoduje znaczącego spadku wariancji.


PRZYKŁAD 1

Przypuśćmy, że zależność współczynnika rozszerzalności cieplnej jakiegoś obiektu wyznaczony z pomiarów wynosi:

T [°F]	-320	-280	-240	-200	-160	-120	-80	-40	0	40	80
Wsp [$\frac{mm}{mm \cdot ^\circ F}$]	2.76	3.33	3.83	4.30	4.72	5.09	5.43	5.72	6.00	6.24	6.47

Zależność współczynnika v od stopnia wielomianu aproksymującego te dane wygląda następująco:

Optymalny stopień wielomianu aproksymującego
(dane Przykładu 1)




Co oznacza, że dla tego problemu optymalny stopień wielomianu aproksymującego wynosi 2 lub 3 a dalsze zwiększanie jego stopnia słabo polepsza dokładność odwzorowania.



⁵We wzorze na wariancję v powyżej N oznacza ilość punktów danych. To inne użycie N niż w dalszej części rozdziału (wielomiany ortogonalne, aproksymacja ciągła), gdzie N oznacza stopień najwyższego wielomianu w bazie, a same funkcje bazowe indeksowane są od 0 do N (czyli $K=N+1$ funkcji) – tak jak przy interpolacji, gdzie punktów było $N+1$, indeksowanych od 0. Kontekst rozstrzyga, o które znaczenie N chodzi.

PRZYKŁAD 2

Poprzednio okazało się, że odwzorowanie funkcji e^x wyszło nam słabo. Powtórzmy ten eksperyment i spróbujemy dobrać optymalny stopień wielomianu. Musimy teraz przyjąć jednak więcej punktów żeby można zwiększać stopień wielomianu aproksymującego. Przyjmijmy 11 punktów:




Skąd wynika, że optimum mamy dla $M=3$. Na poniższym rysunku pokazano wyniki aproksymacji wielomianami stopnia $M=3$ i $M=5$. Jak widzimy dalsze zwiększanie stopnia wielomianu przy stałej liczbie punktów nie daje już poprawy.

a) $M=3$ b) $M=3$ (kropkowana), $M=5$ (zielona)


Można się zastanawiać jak ten optymalny stopień wielomianu ma się do twierdzenia podanego na początku rozdziału, które mówi że zwiększając stopień wielomianu aproksymującego można uzyskać dowolnie mały błąd. Otóż twierdzenie to zakłada, że punktów w danych wejściowych jest bardzo dużo (w zasadzie, że jest ich nieskończenie wiele – co oznacza przypadek ciągły aproksymacji opisany trochę dalej). W rzeczywistości aproksymacja wielomianowa jest podatna na takie same efekty jak interpolacja wielomianowa, w tym w szczególności:

- Im wyższy stopień wielomianu i im bliższa dana aproksymacja wielomianowa jest interpolacji tym wraz ze wzrostem stopnia wielomianu aproksymującego M bardziej rośnie błąd odwzorowania poza węzłami. Przykładowo dla funkcji e^x analizowanej wcześniej i 11 węzłów kolejne aproksymacje wyglądają następująco:


M=2




M=4




M=6



M=8



M=10



Ostatnią z pokazanych tutaj aproksymacji $M=10$ jest interpolacją i jak widać obarczona jest dużym błędem z powodów o których już mówiliśmy. Efekt ten nakłada się na efekt wynikający z twierdzenia Stone'a-Weierstrassa. Dopóki stopień wielomianu interpolującego jest „daleko” od stopnia granicznego interpolacji zwiększanie stopnia wielomianu do pewnego momentu daje faktycznie poprawę odwzorowania. I to właśnie ujęte jest w warunku na optymalny stopień wielomianu aproksymującego

- Drugi problem analogiczny jak w przypadku interpolacji to fakt, że przyjęcie bazy wielomianów naturalnych w postaci:

$$\varphi_k(x) = x^k \quad k = 0, 1, 2, 3, \dots \quad (44)$$

Prowadzi do źle uwarunkowanych układów równań. Dlatego mogą być stosowane tylko dla stosunkowo niewielkiej liczby punktów. Jednym z częściej stosowanych rozwiązań tego problemu jest, podobnie jak w przypadku interpolacji, takie spreparowanie ciągu funkcji aproksymujących $\varphi_k(x)$, żeby ten problem ominąć. Będziemy się starali stworzyć taki ciąg funkcji, żeby:

$$(\varphi_k, \varphi_j) = \begin{cases} 0 & \text{dla } k \neq j \\ \neq 0 & \text{dla } k = j \end{cases} \quad (45)$$

Co spowoduje, że macierz **A** wyglądałaby następująco:

$$\mathbf{A} = \begin{bmatrix} (\varphi_1, \varphi_1) & 0 & \dots & 0 \\ 0 & (\varphi_2, \varphi_2) & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & (\varphi_K, \varphi_K) \end{bmatrix} \quad (46)$$

Od tego miejsca – tak jak przy interpolacji – wygodniej jest indeksować funkcje bazowe od 0 do N zamiast od 1 do K (to ta sama liczba funkcji, $K=N+1$); poniższy zapis układu równań korzysta już z tej konwencji.

A sam układ równań aproksymacji:

$$\mathbf{A}\mathbf{p} = \mathbf{b} \quad (47)$$

$$\begin{bmatrix} (\varphi_N, \varphi_N) & \dots & 0 \\ 0 & & 0 \\ \vdots & \ddots & \vdots \\ 0 & & 0 \\ 0 & \dots & (\varphi_0, \varphi_0) \end{bmatrix} \begin{bmatrix} p_N \\ \vdots \\ p_0 \end{bmatrix} = \begin{bmatrix} (\mathbf{f}, \varphi_N) \\ \vdots \\ (\mathbf{f}, \varphi_0) \end{bmatrix} \quad (48)$$

Ponieważ w oczywisty sposób tego układu równań nie trzeba rozwiązywać⁶ to problem złego uwarunkowania układu równań znika. Powstaje tylko pytanie jak zbudować taki ciąg funkcji.

WIELOMIANY ORTOGONALNE

Rozwiązaniem naszego problemu są ciągi wielomianów ortogonalnych.

Ciąg funkcji nazwiemy ciągiem ortogonalnym jeżeli dowolne funkcje z tego ciągu spełniają warunek:

$$(\varphi_k, \varphi_j) = \begin{cases} 0 & \text{dla } k \neq j \\ \|\varphi_k\| \neq 0 & \text{dla } k = j \end{cases} \quad (49)$$

Dodatkowo jeżeli $\|\varphi_k\| = 1$ to taki ciąg nazywamy ciągiem ortonormalnym.

Istnieją procedury matematyczne pozwalające z ciągu bazowego np. naszej bazy wielomianów naturalnych stworzyć ciąg ortogonalny. Nie będziemy ich tutaj szczegółowo omawiać, ale dla zainteresowanych na końcu w dodatku 2 pokazana jest szkolna procedura ortogonalizacji dowolnego ciągu wielomianów.

Istnieje tylko jedno ograniczenie tej metody – mianowicie ciągi wielomianów ortogonalnych są ortogonalne tylko w jakimś przedziale. Dla każdego przedziału zasadniczo ortogonalny jest inny ciąg. Można sobie z tym jednak poradzić jeżeli zbudujemy sobie ciąg wielomianów ortogonalnych na jakimś przykładowym przedziale, który będziemy przekształcać na inny. Dlatego ciągi wielomianów ortogonalnych podawane są typowo dla pewnego przedziału.

Takim ciągiem wielomianów ortogonalnych „ogólnego przeznaczenia” są wielomiany *Legendre’a* zdefiniowane w następujący sposób na przedziale $[-1, 1]$ ⁷:

$$P_n(x) = \frac{1}{2^n \bullet n!} \frac{d^n}{dx^n} (x^2 - 1)^n \quad (50)$$

⁶A nawet gdyby było trzeba, taki układ jest dobrze uwarunkowany – nie dlatego, że macierz jest diagonalna sama w sobie (diagonalna dominacja gwarantuje tylko nieosobliwość, nie niskie uwarunkowanie: $\text{cond}(\mathbf{A}) = \max_k (\varphi_k, \varphi_k) / \min_k (\varphi_k, \varphi_k)$), ale dlatego że dla typowych ciągów ortogonalnych normy kolejnych funkcji bazowych maleją łagodnie (np. dla wielomianów Legendre’a $(\varphi_k, \varphi_k) = \frac{1}{2k+1}$) – więc $\text{cond}(\mathbf{A})$ rośnie tylko liniowo wraz z liczbą składników K, w przeciwieństwie do wykładniczego wzrostu dla bazy naturalnej x^k .

⁷To zapis najbardziej kompaktowy, bardziej czytelny jest zapis rekurencyjny definiujący wielomian n-ty za pomocą poprzednich:

$P_n(x) = \frac{2n-1}{n} \bullet x \bullet P_{n-1}(x) - \frac{n-1}{n} P_{n-2}(x); P_0(x) = 1, P_1(x) = x,$

PRZYKŁAD

Aproksymować średniokwadratowo funkcję x^3 w przedziale $[0, 1]$ wielomianem stopnia 2 stosując wielomiany Legendre'a.

Przedział $[0, 1]$ nie odpowiada przedziałowi ortogonalności wielomianów Legendre'a, zatem musimy dokonać przekształcenia:

$$x = at + b \quad (51)$$

Co dla przedziałów $x \in [-1, 1]$ oraz $t \in [0, 1]$ daje:

$$x = 2t - 1, \quad t = \frac{x + 1}{2} \quad (52)$$

Zatem nasze wielomiany Legendre'a, ortogonalne w przedziale $[0, 1]$ są:

$$\varphi_0(t) = 1, \quad (53)$$

$$\varphi_1(t) = 2t - 1, \quad (54)$$

$$\varphi_2(t) = \frac{1}{2} (3(2t - 1)^2 - 1) = 6t^2 - 6t + 1 \quad (55)$$

Dalsze obliczenia polegają na rozwiązaniu takiego układu równań:

$$\begin{bmatrix} (\varphi_0, \varphi_0) & 0 & 0 \\ 0 & (\varphi_1, \varphi_1) & 0 \\ 0 & 0 & (\varphi_2, \varphi_2) \end{bmatrix} \mathbf{p} = \begin{bmatrix} (\varphi_0, \mathbf{Y}) \\ (\varphi_1, \mathbf{Y}) \\ (\varphi_2, \mathbf{Y}) \end{bmatrix} \quad (56)$$

WIELOMIANY ORTOGONALNE DO ZADAŃ SPECJALNYCH

W dotychczasowych rozważaniach dla czytelności funkcję celu wyrażaliśmy w postaci:

$$J_2(\mathbf{p}) = \sum_{n=0}^N \left(\tilde{f}(x_n, \mathbf{p}) - f(x_n) \right)^2 \quad (57)$$

ale w ogólnej postaci wygląda ona tak:

$$J_2(\mathbf{p}) = \sum_{n=0}^N w(x_n) \left(\tilde{f}(x_n, \mathbf{p}) - f(x_n) \right)^2 \quad (58)$$

gdzie $w(x_n)$ to funkcja wagowa. My przyjęliśmy po prostu funkcję wagową $w(x_n) = 1$ co oznaczało, że każdy z punktów danych wejściowych miał taką samą wagę jak każdy inny. To jest najbardziej popularne podejście ogólne. Fakt istnienia funkcji wagowej można jednak wykorzystać inaczej. Ponieważ $w(x_n) \geq 0$, możemy zapisać $w(x_n) = \sqrt{w(x_n)} \cdot \sqrt{w(x_n)}$ i "wciągnąć" ten pierwiastek do środka nawiasu⁸:

$$J_2(\mathbf{p}) = \sum_{n=0}^N \left(\sqrt{w(x_n)} \tilde{f}(x_n, \mathbf{p}) - \sqrt{w(x_n)} f(x_n) \right)^2 \quad (59)$$

Jeżeli teraz wiemy coś o naszym modelu, np. wiemy, że fizyczna zależność opisująca mierzone zjawisko ma postać iloczynu czegoś co można uznać za wielomian $P_k(x)$ i jakiejś funkcji np. e^x , możemy tę wagę wbudować bezpośrednio w bazę: zamiast dopasowywać $\varphi_k(x)$ dopasowujemy $\hat{\varphi}_k(x) = \sqrt{w(x)}\varphi_k(x)$, a residua liczymy względem tak samo przeważonych danych $\sqrt{w(x_n)}f(x_n)$:

$$J_2(\mathbf{p}) = \sum_{n=0}^N \left(\sum_k p_k \hat{\varphi}_k(x_n) - \sqrt{w(x_n)} f(x_n) \right)^2 \quad (60)$$

⁸Ważenie punktów danych (waga poza nawiasem, statystyka - "który punkt jest wiarygodny") i ważenie bazy przy budowie ciągu ortogonalnego (waga wbudowana we $\hat{\varphi}_k$, geometria - "który fragment przedziału ma być dobrze odwzorowany") to dwie różne role tej samej idei. Czynniki $\sqrt{w(x_n)}$ pozwala połączyć je w jednym wzorze, bo $w(x_n)(a-b)^2 = (\sqrt{w(x_n)}a - \sqrt{w(x_n)}b)^2$.

To można użyć takiej aproksymacji do odtworzenia parametrów fizycznych oryginalnego przebiegu (a nie tylko jego kształtu) jeżeli uwzględni się tą wagę przy tworzeniu ciągu wielomianów ortogonalnych $\hat{\varphi}_k$. Wtedy cała procedura przebiega identycznie jak opisaliśmy, ale współczynniki mogą być interpretowane po względem liczbowym i mają znaczenia fizyczne. Przykładowo waga e^{-x} występuje często w zagadnieniach spektralnych, gdzie mierzone wartości są sumą składowych harmonicznych wyrażanych właśnie jako czynnik e^{-x} .

Do konkretnych zastosowań stworzono wiele tego typu ciągów ortogonalnych, każdy pod konkretny problem fizyczny do którego są stosowane. Wymienię tutaj tylko kilka:

- Ciąg wielomianów ortogonalnych Czebyszewa

Określony na przedziale $[-1, 1]$. Ma postać:

$$\varphi_0(x) = 1, \quad \varphi_1(x) = x, \quad (61)$$

$$\varphi_k(x) = 2 \bullet x \bullet \varphi_{k-1}(x) - \varphi_{k-2}(x) \quad (62)$$

Odpowiada zastosowaniu wagi:

$$w(x) = \frac{1}{\sqrt{1-x^2}} \quad (63)$$

- Ciąg wielomianów ortogonalnych Hermite'a

Określony na przedziale $[-\infty, \infty]$. Ma postać:

$$\varphi_0(x) = 1, \quad \varphi_1(x) = 2x, \quad (64)$$

$$\varphi_k(x) = 2 \bullet x \bullet \varphi_{k-1}(x) - (2k-2)\varphi_{k-2}(x) \quad (65)$$

Odpowiada wadze:

$$w(x) = e^{-x^2} \quad (66)$$

Więcej na ten temat powiemy sobie przy okazji całkowania.

APROKSYMACJA CIĄGŁA

Na koniec przejdziemy do aproksymacji ciągłej. Można na nią spojrzeć jako na aproksymację bardzo dużej ilości punktów (dążącej do nieskończoności) i przeprowadzić analogiczne rozumowanie jak poprzednio dla aproksymacji dyskretnej. Sposób rozwiązania będzie identyczny, ale zmienią się postaci na iloczyny skalarne i funkcję celu. Przykładowo:

$$J_2(\mathbf{p}) = \lim_{N \rightarrow \infty} \sum_{n=0}^N w(x_n) \left(\tilde{f}(x_n, \mathbf{p}) - f(x_n) \right)^2 = \int_a^b w(x) \left(\tilde{f}(x, \mathbf{p}) - f(x) \right)^2 dx \quad (67)$$

Trochę bardziej skomplikowana sprawa teoretycznie jest z iloczynem skalarnym który wyrażany jest wzorem:

$$(f(x), g(x)) = \int_a^b w(x) f(x) g(x) dx \quad (68)$$

Tym razem jest to iloczyn skalarny funkcji a nie wektorów.

Reszta rozumowania przebiega tak samo:

1. Wybieramy ciąg funkcji aproksymujących do stworzenia funkcji aproksymującej:

$$\tilde{f}(x, \mathbf{p}) = \sum_{k=1}^K p_k \varphi_k(x) \quad (69)$$

2. Tworzymy i rozwiązujemy układ równań w postaci:

$$\begin{bmatrix} (\varphi_N, \varphi_N) & \dots & (\varphi_0, \varphi_N) \\ \vdots & \ddots & \vdots \\ (\varphi_N, \varphi_0) & \dots & (\varphi_0, \varphi_0) \end{bmatrix} \begin{bmatrix} p_N \\ \vdots \\ p_0 \end{bmatrix} = \begin{bmatrix} (f, \varphi_N) \\ \vdots \\ (f, \varphi_0) \end{bmatrix} \quad (70)$$

PRZYKŁAD

Aproksymować średniokwadratowo funkcję $\sqrt{x}$ w przedziale $[0, 1]$ wielomianem stopnia 2.
Skoro przybliżamy wielomianem stopnia drugiego to ciąg funkcji aproksymujących wygląda tak:

$$\varphi_0(x) = 1, \varphi_1(x) = x, \varphi_2(x) = x^2 \quad (71)$$

$$N = 2 \quad (72)$$

Należy zatem zbudować układ równań:

$$\mathbf{Ax} = \mathbf{b}$$

Gdzie elementami macierzy $\mathbf{A}$ i wektora $\mathbf{b}$ są iloczyny skalarne funkcji $f(x)$ oraz $\varphi_k(x)$

Elementy macierzy $\mathbf{A}$:

$$(\varphi_2, \varphi_2) = \int_0^1 x^2 x^2 dx = \left. \frac{1}{5} x^5 \right|_0^1 = \frac{1}{5} \quad (73)$$

$$(\varphi_1, \varphi_1) = \int_0^1 x x dx = \left. \frac{1}{3} x^3 \right|_0^1 = \frac{1}{3} \quad (74)$$

$$(\varphi_0, \varphi_0) = \int_0^1 1 dx = 1 \quad (75)$$

$$(\varphi_1, \varphi_2) = (\varphi_2, \varphi_1) = \int_0^1 x x^2 dx = \left. \frac{1}{4} x^4 \right|_0^1 = \frac{1}{4} \quad (76)$$

$$(\varphi_0, \varphi_1) = (\varphi_1, \varphi_0) = \int_0^1 x dx = \left. \frac{1}{2} x^2 \right|_0^1 = \frac{1}{2} \quad (77)$$

$$(\varphi_0, \varphi_2) = (\varphi_2, \varphi_0) = \int_0^1 x^2 dx = \left. \frac{1}{3} x^3 \right|_0^1 = \frac{1}{3} \quad (78)$$

$$\mathbf{A} = \begin{bmatrix} \frac{1}{5} & \frac{1}{4} & \frac{1}{3} \\ \frac{1}{4} & \frac{1}{3} & \frac{1}{2} \\ \frac{1}{3} & \frac{1}{2} & 1 \end{bmatrix} \quad (79)$$

Elementy wektora $\mathbf{b}$:

$$(f, \varphi_2) = \int_0^1 \sqrt{x} x^2 dx = \left. \frac{2}{7} x^{\frac{7}{2}} \right|_0^1 = \frac{2}{7} \quad (80)$$

$$(f, \varphi_1) = \int_0^1 \sqrt{x} x dx = \left. \frac{2}{5} x^{\frac{5}{2}} \right|_0^1 = \frac{2}{5} \quad (81)$$

$$(f, \varphi_0) = \int_0^1 \sqrt{x} dx = \left. \frac{2}{3} x^{\frac{3}{2}} \right|_0^1 = \frac{2}{3} \quad (82)$$

Układ równań:

$$\begin{bmatrix} \frac{1}{5} & \frac{1}{4} & \frac{1}{3} \\ \frac{1}{4} & \frac{1}{3} & \frac{1}{2} \\ \frac{1}{3} & \frac{1}{2} & 1 \end{bmatrix} \begin{bmatrix} p_2 \\ p_1 \\ p_0 \end{bmatrix} = \begin{bmatrix} \frac{2}{7} \\ \frac{2}{5} \\ \frac{2}{3} \end{bmatrix} \quad (83)$$

W wyniku jego rozwiązania otrzymujemy wektor:

$$\mathbf{p} = \begin{bmatrix} -0.5714 \dots \\ 1.3714 \dots \\ 0.1714 \dots \end{bmatrix} \quad (84)$$

Zatem szukany wielomian aproksymujący:

$$\tilde{f}(x) \approx -0.5714x^2 + 1.3714x + 0.1714 \quad (85)$$