

**Politechnika
Warszawska**

APROKSYMACJA

**Wstęp do metod numerycznych
(WNUM)**




Regresja

Regresja – metoda statystyczna pozwalająca na opisanie współzależności kilku zmiennych przez dopasowanie do nich funkcji. Umożliwia przewidywanie nieznanych wartości jednych wielkości na podstawie znanych wartości innych.

W praktyce sprowadza się do dwóch faz:

- konstruowanie modelu – budowa tzw. modelu regresyjnego, czyli funkcji opisującej, jak zależy wartość oczekiwana zmiennej objaśnianej od zmiennych objaśniających.
- stosowanie modelu – użycie wyliczonego modelu do danych w których znamy tylko zmienne objaśniające, w celu wyznaczenia wartości oczekiwanej zmiennej objaśnianej.




Regresja

Regresja – metoda statystyczna pozwalająca na opisanie współzależności kilku zmiennych przez dopasowanie do nich funkcji. Umożliwia przewidywanie nieznanych wartości jednych wielkości na podstawie znanych wartości innych.

W praktyce sprowadza się do dwóch faz:

- konstruowanie modelu – budowa tzw. modelu regresyjnego, czyli funkcji opisującej, jak zależy wartość oczekiwana zmiennej objaśnianej od zmiennych objaśniających.
- stosowanie modelu – użycie wyliczonego modelu do danych w których znamy tylko zmienne objaśniające, w celu wyznaczenia wartości oczekiwanej zmiennej objaśnianej.



PRZYKŁADOWO:

Na rysunku podane są dane w postaci punktów (są to dane pomiarowe). Przyjęty w tej analizie model jest modelem liniowym (prosta). Wynik regresji polega na tym, że staramy się uzyskać takie parametry modelu (współczynniki prostej), które „najlepiej” oddają zmierzone dane.


Regresja

- W problemie regresji od razu zakładamy, że posiadane przez nas dane obarczone są istotnym, niepomijalnym błędem, który bierzemy pod uwagę na etapie analizy:

$$\tilde{y}_i = f(x_i) + \varepsilon_i$$

Nasze dane to:

- $x_i, \tilde{y}_i$ – są to współrzędne danych wejściowych. $\tilde{y}_i$ nie jest równe $f(x_i)$ ponieważ w stosunku do niego jest obarczone pewnym błędem
- $Y_i = f(x_i)$ – jest to wartość „oryginalnej” zależności, która jest dodatkowo zaburzona błędem
- ε_i – błąd jakim obarczone są dane w punkcie x_i w stosunku do oryginalnej zależności




Regresja

- W problemie regresji od razu zakładamy, że posiadane przez nas dane obarczone są istotnym, niepomijalnym błędem, który bierzemy pod uwagę na etapie analizy

$$\tilde{y}_i = f(x_i) + \varepsilon_i$$

Nasze dane to:

- $x_i, \tilde{y}_i$ – są to współrzędne danych wejściowych. $\tilde{y}_i$ nie jest równe $f(x_i)$ ponieważ w stosunku do niego jest obarczone pewnym błędem
- $Y_i = f(x_i)$ – jest to wartość oryginalnej zależności, która jest dodatkowo zaburzona błędem
- ε_i – błąd jakim obarczone są dane w punkcie x_i w stosunku do oryginalnej zależności




Regresja

- W problemie regresji od razu zakładamy, że posiadane przez nas dane obarczone są istotnym, niepomijalnym błędem, który bierzemy pod uwagę na etapie analizy

$$\tilde{y}_i = f(x_i) + \varepsilon_i$$

Nasze dane to:

- $x_i, \tilde{y}_i$ – są to współrzędne danych wejściowych. y_i nie jest równe $f(x_i)$ ponieważ w stosunku do niego jest obarczone pewnym błędem
- $Y_i=f(x_i)$ – jest to wartość oryginalnej zależności, która jest dodatkowo zaburzona błędem
- ε_i – błąd jakim obarczone są dane w punkcie x_i w stosunku do oryginalnej zależności




Regresja

- W problemie regresji od razu zakładamy, że posiadane przez nas dane obarczone są istotnym, niepomijalnym błędem, który bierzemy pod uwagę na etapie analizy

$$\tilde{y}_i = f(x_i) + \varepsilon_i$$

Nasze dane to:

- $x_i, \tilde{y}_i$ – są to współrzędne danych wejściowych. y_i nie jest równe $f(x_i)$ ponieważ w stosunku do niego jest obarczone pewnym błędem
- $Y_i = f(x_i)$ – jest to wartość oryginalnej zależności, która jest dodatkowo zaburzona błędem
- ε_i – błąd jakim obarczone są dane w punkcie x_i w stosunku do oryginalnej zależności



Regresja

$$\tilde{y}_i = f(x_i) + \varepsilon_i$$




Wektorowo możemy zapisać to jako:

$$\tilde{\mathbf{y}} = f(\mathbf{x}) + \boldsymbol{\varepsilon}$$

lub:

$$\tilde{\mathbf{y}} = \mathbf{Y} + \boldsymbol{\varepsilon}$$



Regresja – co to znaczy „najlepsze”

$$\tilde{y}_i = f(x_i) + \varepsilon_i$$

Problem regresji jest zdefiniowany w taki sposób, żeby w całym zakresie danych minimalizować błąd odwzorowania:


$$\boldsymbol{\varepsilon} = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \dots \end{bmatrix}$$

Rozwiązanie spełnia warunek:

$$\min(\|\boldsymbol{\varepsilon}\|) = \min(\|\mathbf{Y} - \tilde{\mathbf{y}}\|) = \min(\|f(\mathbf{x}) - \tilde{\mathbf{y}}\|)$$

Możliwe są zatem różne regresje w zależności od wybranej normy do minimalizacji:

- **Najczęściej spotykana jest regresja średniokwadratowa** oparta o normę 2.,
- Czasami spotyka się regresję opartą o normę maksimum tzw. minimaksowa.



Regresja – aproksymacja

Aproksymacją nazywamy taki rodzaj regresji, w którym model przyjęty do dopasowania, można wyrazić w postaci identycznej jak w opisie problemu interpolacji tzn.:

$$\tilde{y}_i = f(x_i) + \varepsilon_i$$

$$f(x_i, \mathbf{p}) = \sum_{k=1}^K p_k \varphi_k(x_i)$$



To jest nasz
model

$$\tilde{y}_i = \sum_{k=1}^K p_k \varphi_k(x_i) + \varepsilon_i$$

Regresja – aproksymacja

$$\tilde{y}_i = f(x_i) + \varepsilon_i$$

Aproksymacją nazywamy taki rodzaj regresji, w którym model przyjęty do dopasowania, można wyrazić w postaci identycznej jak w opisie problemu interpolacji tzn.:

$$f(x_i, \mathbf{p}) = \sum_{k=1}^K p_k \varphi_k(x_i)$$

Celem rozwiązania problemu regresji/aproksymacji jest uzyskanie wartości liczbowych współczynników modelu, które skrywają interesującą nas informację.

$$\min(\|\boldsymbol{\varepsilon}\|)$$

$$\tilde{y}_i = \sum_{k=1}^K \mathbf{p}_k \varphi_k(x_i) + \varepsilon_i$$

Regresja – aproksymacja

$$f(x_i, \mathbf{p}) = \sum_{k=1}^K p_k \varphi_k(x_i)$$



$$f(\mathbf{x}, \mathbf{p}) = \mathbf{\Phi} \mathbf{p}$$

$$\mathbf{\Phi} = \begin{bmatrix} \varphi_1(x_1) & \varphi_2(x_1) & \dots & \varphi_K(x_1) \\ \varphi_1(x_2) & \varphi_2(x_2) & \dots & \varphi_K(x_2) \\ \vdots & \vdots & \ddots & \vdots \\ \varphi_1(x_N) & \varphi_2(x_N) & \dots & \varphi_K(x_N) \end{bmatrix}$$

$$\mathbf{p} = \begin{bmatrix} p_1 \\ p_2 \\ \vdots \\ p_K \end{bmatrix}$$

Regresja – aproksymacja

$$\tilde{y}_i = f(x_i) + \varepsilon_i$$

Aproksymacją nazywamy taki rodzaj regresji, w którym model przyjęty do dopasowania, można wyrazić w postaci identycznej jak w opisie problemu interpolacji tzn.:

$$f(x_i, \mathbf{p}) = \sum_{k=1}^K p_k \varphi_k(x_i)$$

Inaczej mówiąc celem rozwiązania problemu regresji/aproksymacji jest uzyskanie wartości liczbowych wektora $\mathbf{p}$.

$$\min(\|\boldsymbol{\varepsilon}\|)$$

$$\tilde{\mathbf{y}} = \boldsymbol{\Phi} \mathbf{p} + \boldsymbol{\varepsilon}$$

$$f(\mathbf{x}, \mathbf{p}) = \mathbf{\Phi} \mathbf{p}$$

$$\mathbf{\Phi} = \begin{bmatrix} \varphi_1(x_1) & \varphi_2(x_1) & \dots & \varphi_K(x_1) \\ \varphi_1(x_2) & \varphi_2(x_2) & \dots & \varphi_K(x_2) \\ \vdots & \vdots & \ddots & \vdots \\ \varphi_1(x_N) & \varphi_2(x_N) & \dots & \varphi_K(x_N) \end{bmatrix}$$

$$\mathbf{p} = \begin{bmatrix} p_1 \\ p_2 \\ \vdots \\ p_K \end{bmatrix}$$

W przypadku interpolacji zapisalibyśmy następujący układ równań:

$$\begin{bmatrix} \varphi_1(x_0) & \varphi_0(x_0) \\ \varphi_1(x_1) & \varphi_0(x_1) \\ \varphi_1(x_2) & \varphi_0(x_2) \\ \varphi_1(x_3) & \varphi_0(x_3) \end{bmatrix} \cdot \begin{bmatrix} p_1 \\ p_0 \end{bmatrix} = \begin{bmatrix} f(x_0) \\ f(x_1) \\ f(x_2) \\ f(x_3) \end{bmatrix}$$

Układ równań zawsze nadokreślony (więcej równań niż niewiadomych, $N > K$; przy $N = K$ byłaby to interpolacja). W przypadku zastosowania normy 2 możliwy do rozwiązania w sensie najmniejszych kwadratów (Liniowe zadanie najmniejszych kwadratów).

W przypadku interpolacji zapisalibyśmy następujący układ równań:

$$\left\{ \begin{bmatrix} \varphi_1(x_0) & \varphi_0(x_0) \\ \varphi_1(x_1) & \varphi_0(x_1) \\ \varphi_1(x_2) & \varphi_0(x_2) \\ \varphi_1(x_3) & \varphi_0(x_3) \end{bmatrix} \cdot \begin{bmatrix} p_1 \\ p_0 \end{bmatrix} = \begin{bmatrix} f(x_0) \\ f(x_1) \\ f(x_2) \\ f(x_3) \end{bmatrix} \right.$$

$$f(x, p) = \Phi p$$

$$\Phi = \begin{bmatrix} \varphi_1(x_1) & \varphi_2(x_1) & \dots & \varphi_K(x_1) \\ \varphi_1(x_2) & \varphi_2(x_2) & \dots & \varphi_K(x_2) \\ \vdots & \vdots & \ddots & \vdots \\ \varphi_1(x_N) & \varphi_2(x_N) & \dots & \varphi_K(x_N) \end{bmatrix}$$

$$p = \begin{bmatrix} p_1 \\ p_2 \\ \vdots \\ p_K \end{bmatrix}$$

W przypadku interpolacji zapisalibyśmy następujący układ równań:

$$\begin{bmatrix} \varphi_1(x_0) & \varphi_0(x_0) \\ \varphi_1(x_1) & \varphi_0(x_1) \\ \varphi_1(x_2) & \varphi_0(x_2) \\ \varphi_1(x_3) & \varphi_0(x_3) \end{bmatrix} \cdot \begin{bmatrix} p_1 \\ p_0 \end{bmatrix} = \begin{bmatrix} f(x_0) \\ f(x_1) \\ f(x_2) \\ f(x_3) \end{bmatrix}$$

Może jakaś inna
koncepcja?

Aproksymacja – rozwiązanie problemu

$$f(\mathbf{x}, \mathbf{p}) = \Phi \mathbf{p}$$

$$\Phi = \begin{bmatrix} \varphi_1(x_1) & \varphi_2(x_1) & \dots & \varphi_K(x_1) \\ \varphi_1(x_2) & \varphi_2(x_2) & \dots & \varphi_K(x_2) \\ \vdots & \vdots & \ddots & \vdots \\ \varphi_1(x_N) & \varphi_2(x_N) & \dots & \varphi_K(x_N) \end{bmatrix}$$


$$\mathbf{p} = \begin{bmatrix} p_1 \\ p_2 \\ \vdots \\ p_K \end{bmatrix}$$

Rozumowanie w przypadku rozwiązania problemu aproksymacji jest zgodne z logiką problemu regresji:

$$\tilde{y}_i = f(x_i) + \varepsilon_i$$



$$\varepsilon = \tilde{\mathbf{y}} - f(\mathbf{x}, \mathbf{p})$$




$$f(\mathbf{x}, \mathbf{p}) = \Phi \mathbf{p}$$

$$\Phi = \begin{bmatrix} \varphi_1(x_1) & \varphi_2(x_1) & \dots & \varphi_K(x_1) \\ \varphi_1(x_2) & \varphi_2(x_2) & \dots & \varphi_K(x_2) \\ \vdots & \vdots & \ddots & \vdots \\ \varphi_1(x_N) & \varphi_2(x_N) & \dots & \varphi_K(x_N) \end{bmatrix}$$

$$\mathbf{p} = \begin{bmatrix} p_1 \\ p_2 \\ \vdots \\ p_K \end{bmatrix}$$

$$\varepsilon = \tilde{\mathbf{y}} - \Phi \mathbf{p}$$



Aproksymacja – rozwiązanie problemu

$$f(\mathbf{x}, \mathbf{p}) = \Phi \mathbf{p}$$

$$\Phi = \begin{bmatrix} \varphi_1(x_1) & \varphi_2(x_1) & \dots & \varphi_K(x_1) \\ \varphi_1(x_2) & \varphi_2(x_2) & \dots & \varphi_K(x_2) \\ \vdots & \vdots & \ddots & \vdots \\ \varphi_1(x_N) & \varphi_2(x_N) & \dots & \varphi_K(x_N) \end{bmatrix}$$

$$\mathbf{p} = \begin{bmatrix} p_1 \\ p_2 \\ \vdots \\ p_K \end{bmatrix}$$

wynika to z właściwości normy
2.

Rozumowanie w przypadku rozwiązania problemu aproksymacji jest zgodne z logiką problemu regresji:

$$\min(\|\boldsymbol{\varepsilon}\|)$$

$$\boldsymbol{\varepsilon} = \tilde{\mathbf{y}} - \Phi \mathbf{p}$$

$$J_2(\mathbf{p}) = \|\boldsymbol{\varepsilon}\|_2 = \sum_{n=1}^N \varepsilon_n^2$$



$$J_2(\mathbf{p}) = \boldsymbol{\varepsilon}^T \boldsymbol{\varepsilon} = (\tilde{\mathbf{y}} - \Phi \mathbf{p})^T (\tilde{\mathbf{y}} - \Phi \mathbf{p})$$

Bez zapisu wektorowego:

$$J_2(\mathbf{p}) = \|\boldsymbol{\varepsilon}\|_2 = \sum_{n=1}^n \left(\tilde{y}_i - \sum_{k=1}^K p_k \varphi_k(x_i) \right)^2, \text{ bo } \tilde{y}_i = \sum_{k=1}^K p_k \varphi_k(x_i) + \varepsilon_i$$

$$\min(\|\boldsymbol{\varepsilon}\|)$$

Kiedy funkcja $J_2(\mathbf{p}) = \|\boldsymbol{\varepsilon}\|_2 = \boldsymbol{\varepsilon}^T \boldsymbol{\varepsilon} = (\tilde{\mathbf{y}} - \boldsymbol{\Phi} \mathbf{p})^T (\tilde{\mathbf{y}} - \boldsymbol{\Phi} \mathbf{p})$ osiąga minimum?

$$\frac{\delta J_2(p)}{\delta p_k} = 0$$



$$\boldsymbol{\Phi}^T \boldsymbol{\Phi} \mathbf{p} = \boldsymbol{\Phi}^T \tilde{\mathbf{y}}$$

$$\underbrace{\boldsymbol{\Phi}^T \boldsymbol{\Phi}}_{\mathbf{A}} \underbrace{\mathbf{p}}_{\mathbf{x}} = \underbrace{\boldsymbol{\Phi}^T \tilde{\mathbf{y}}}_{\mathbf{b}}$$

$$\underbrace{\Phi^T \Phi}_A \underbrace{p}_x = \underbrace{\Phi^T \tilde{y}}_b$$

$$A = \Phi^T \Phi = \begin{bmatrix} \varphi_1(x_1) & \varphi_1(x_2) & \dots & \varphi_1(x_N) \\ \varphi_2(x_1) & \varphi_2(x_2) & \dots & \varphi_2(x_N) \\ \vdots & \vdots & \ddots & \vdots \\ \varphi_K(x_1) & \varphi_K(x_2) & \dots & \varphi_K(x_N) \end{bmatrix} \begin{bmatrix} \varphi_1(x_1) & \varphi_2(x_1) & \dots & \varphi_K(x_1) \\ \varphi_1(x_2) & \varphi_2(x_2) & \dots & \varphi_K(x_2) \\ \vdots & \vdots & \ddots & \vdots \\ \varphi_1(x_N) & \varphi_2(x_N) & \dots & \varphi_K(x_N) \end{bmatrix}$$

Wyrażenie:

$$(x, y) = \sum_{k=1}^n x_k y_k$$

**będziemy nazywać iloczynem skalarnym. Iloczyn skalarny jest przemienny
tzn: $(x, y) = (y, x)$**

$$\underbrace{\Phi^T \Phi}_A \underbrace{p}_x = \underbrace{\Phi^T \tilde{y}}_b$$

$$A = \begin{bmatrix} (\varphi_1, \varphi_1) & (\varphi_1, \varphi_2) & \dots & (\varphi_1, \varphi_K) \\ (\varphi_2, \varphi_1) & (\varphi_2, \varphi_2) & \dots & (\varphi_2, \varphi_K) \\ \vdots & \vdots & \ddots & \vdots \\ (\varphi_K, \varphi_1) & (\varphi_K, \varphi_2) & \dots & (\varphi_K, \varphi_K) \end{bmatrix}$$

$$b = \begin{bmatrix} (\varphi_1, \tilde{y}) \\ (\varphi_2, \tilde{y}) \\ \vdots \\ (\varphi_K, \tilde{y}) \end{bmatrix}$$

$$Ap = b$$

Wyrażenie:


$$(x, y) = \sum_{k=1}^n x_k y_k$$

będziemy nazywać iloczynem skalarnym.
Iloczyn skalarny jest przemienne tzn: $(x, y) = (y, x)$

$$\begin{bmatrix} (\varphi_1, \varphi_1) & (\varphi_1, \varphi_2) & \dots & (\varphi_1, \varphi_K) \\ (\varphi_2, \varphi_1) & (\varphi_2, \varphi_2) & \dots & (\varphi_2, \varphi_K) \\ \vdots & \vdots & \ddots & \vdots \\ (\varphi_K, \varphi_1) & (\varphi_K, \varphi_2) & \dots & (\varphi_K, \varphi_K) \end{bmatrix} p = \begin{bmatrix} (\varphi_1, \tilde{y}) \\ (\varphi_2, \tilde{y}) \\ \vdots \\ (\varphi_K, \tilde{y}) \end{bmatrix}$$

Problem regresji – czego nie widać po formalizmie matematycznym



x	1	2	3	4
Y	1.1	4.2	8.8	16.6



$$\tilde{f}(x, p) = \sum_{k=1}^3 p_k \varphi_k(x) = p_1 1 + p_2 x + p_3 x^3$$

Problem regresji – czego nie widać po formalizmie matematycznym

x	1	2	3	4
Y	1.1	4.2	8.8	16.6




$$\tilde{f}(x, p) = \sum_{k=1}^3 p_k \varphi_k(x) = p_1 1 + p_2 x + p_3 x^3$$

$$\mathbf{p} = \begin{bmatrix} 0.775 \\ -0.765 \\ 1.175 \end{bmatrix}$$

Problem regresji – czego nie widać po formalizmie matematycznym

x	1	2	3	4
Y	2.8	8.4	20.1	55.0




$$\tilde{f}(x, p) = \sum_{k=1}^3 p_k \varphi_k(x) = p_1 1 + p_2 x + p_3 x^3$$

Problem regresji – czego nie widać po formalizmie matematycznym

x	1	2	3	4
Y	2.8	8.4	20.1	55.0

Dlaczego ten wynik jest
znacznie gorszy od
poprzedniego?

$$\tilde{f}(x, p) = \sum_{k=1}^3 p_k \varphi_k(x) = p_1 1 + p_2 x + p_3 x^3$$




Problem regresji – czego nie widać po formalizmie matematycznym

x	1	2	3	4
Y	2.8	8.4	20.1	55.0

Dlaczego ten wynik jest znacznie gorszy od poprzedniego?

$$\tilde{f}(x, p) = \sum_{k=1}^3 p_k \varphi_k(x) = p_1 1 + p_2 x + p_3 x^3$$



Problemem jest niewłaściwy dobór modelu podstawowej zależności.

Problem regresji – skąd wiemy, że wynik jest wiarygodny?

- Miara R^2

Jeżeli średnią wartość zbioru danych wejściowych Y_i można przedstawić jako:

$$\bar{y} = \frac{1}{n} \sum_{i=1}^N Y_i$$


Wtedy można zdefiniować miarę dokładności następująco:

$SS_{tot} = \sum_i (Y_i - \bar{y})^2$ - całkowita suma kwadratów

$SS_{reg} = \sum_i (\tilde{f}(x_i) - \bar{y})^2$ całkowita suma regresji

Miara dokładności dopasowania będzie:

$$R^2 = \frac{SS_{reg}}{SS_{tot}}$$



$$R^2 = \frac{(\tilde{f} - \bar{y})^2}{(Y - \bar{y})^2}$$

Problem regresji – skąd wiemy, że wynik jest wiarygodny?

- Miara R^2

Jeżeli średnią wartość zbioru danych wejściowych Y_i można przedstawić jako:

$$\bar{y} = \frac{1}{n} \sum_{i=1}^N Y_i$$


Wtedy można zdefiniować miarę dokładności następująco:

$SS_{tot} = \sum_i (Y_i - \bar{y})^2$ - całkowita suma kwadratów

$SS_{reg} = \sum_i (\tilde{f}(x_i) - \bar{y})^2$ całkowita suma regresji

Miara dokładności dopasowania będzie:

$$R^2 = \frac{SS_{reg}}{SS_{tot}}$$



Miara jest liniowa. Tzn. dwa razy większa wartość R^2 oznacza dwa razy więcej wyjaśnionej zmienności danych

Problem regresji – skąd wiemy, że wynik jest wiarygodny?

- Miara R^2

Jeżeli średnią wartość zbioru danych wejściowych Y_i można przedstawić jako:

$$\bar{y} = \frac{1}{n} \sum_{i=1}^N Y_i$$


Wtedy można zdefiniować miarę dokładności następująco:

$SS_{tot} = \sum_i (Y_i - \bar{y})^2$ - całkowita suma kwadratów

$SS_{reg} = \sum_i (\tilde{f}(x_i) - \bar{y})^2$ całkowita suma regresji

Miara dokładności dopasowania będzie:

$$R^2 = \frac{SS_{reg}}{SS_{tot}}$$



Można to odczytywać tak, że np. $R^2=0.4$ oznacza, że przyjęty model oddaje 40% zmienności danych

Problem regresji – skąd wiemy, że wynik jest wiarygodny?


- Miara χ^2

$$\chi^2 \equiv \sum_{i=1}^n \left(\frac{f(x_i) - Y(x_i, p)}{\sigma_i} \right)^2$$

Jest to miara statystyczna – zakłada, pewien rozkład błędów danych pomiarowych (wejściowych) jako rozkład normalny.

W tym przypadku zakładamy, że każdy punkt jest osobną zmienną o rozkładzie normalnym.


Jeżeli mamy tylko jeden punkt to zakładamy, że $\sigma_i=1$, a i jest numerem punktu.



Problem regresji – skąd wiemy, że wynik jest wiarygodny?

- Miara χ^2

$$\chi^2 \equiv \sum_{i=1}^n \left(\frac{f(x_i) - Y(x_i, p)}{\sigma_i} \right)^2$$




W przypadku danych pomiarowych możliwe jest wykonanie wielu eksperymentów i kwalifikowanie ich do n kategorii

Wtedy na podstawie danych z i -tej kategorii można wyznaczyć parametry rozkładu normalnego. i staje się indeksem kategorii, a σ_i opisuje ten właśnie rozkład.


Aproksymacja jako metoda odwzorowania kształtu zaburzonych danych:

$$\tilde{f}(x, p) = \sum_{k=1}^3 p_k \varphi_k(x) = p_1 1 + p_2 x + p_3 x^3$$

Zależność oryginalna: wielomian



Zależność oryginalna: funkcja niewielomianowa




Aproksymacja jako metoda odwzorowania kształtu zaburzonych danych:


$$\tilde{f}(x, p) = \sum_{k=1}^3 p_k \varphi_k(x) = p_1 1 + p_2 x + p_3 x^3$$

Zależność oryginalna: wielomian

Zależność oryginalna: funkcja niewielomianowa



Aproksymacja jako metoda odwzorowania kształtu zaburzonych danych:



W miarę zwiększania się stopnia wielomianu aproksymującego (w stosunku do ilości dostępnych węzłów) zagadnienie aproksymacji wielomianowej zaczyna się zbliżać do zagadnienia interpolacji wielomianowej.

Zaczynają się objawiać wszystkie problemy znane z interpolacji wielomianowej np. efekty Rungego.

Twierdzenie Stonea-Weierstrassa



Dla dowolnej funkcji $f(x)$ ciągłej w przedziale $[a, b]$ ($f \in C_{\mathbb{R}}[a, b]$) istnieją taki ciąg wielomianów $P_N(x)$ o współczynnikach rzeczywistych, że:

$$P_N(x) \xrightarrow{N} f(x)$$

Oznacza to, że dla dowolnie przyjętego błędu δ istnieje taki stopień wielomianu N , że błąd w sensie przyjętego kryterium nie będzie większy niż δ .

UWAGA!

Twierdzenie mówi o błędzie jednostajnym na CAŁYM przedziale $[a, b]$ — wszędzie, nie tylko w węzłach. Węzły to tylko nasze dane; twierdzenie jest silniejsze niż to, co widać na wykresie samych punktów.



Twierdzenie Stonea-Weierstrassa



Dla dowolnej funkcji $f(x)$ ciągłej w przedziale $[a, b]$ ($f \in C_{\mathbb{R}}[a, b]$) istnieją taki ciąg wielomianów $P_N(x)$ o współczynnikach rzeczywistych, że:

$$P_N(x) \xrightarrow{N} f(x)$$

Oznacza to, że dla dowolnie przyjętego błędu δ istnieje taki stopień wielomianu N , że błąd w sensie przyjętego kryterium nie będzie większy niż δ .

ALE...

Najlepsze wyniki da nam najmniejszy stopień wielomianu gwarantujący żadaną dokładność!



Uruchom skrypt p.t. ZI_APROKS_EX3.mlx

Aproksymacja jako metoda odwzorowania kształtu zaburzonych danych:

Innym problemem aproksymacji wielomianowej opartej o dużą ilość węzłów (niezależnie od stopnia wielomianu aproksymującego) jest złe „uwarunkowanie” macierzy przy zastosowaniu ciągu wielomianów w postaci naturalnej.

Rozwiązanie tego problemu jest takie samo jak w przypadku interpolacji – trzeba stworzyć inne ciągi wielomianów tak, aby zapewnić korzystne właściwości numeryczne.

$$A = \begin{bmatrix} (\varphi_1', \varphi_1) & 0 & \dots & 0 \\ 0 & (\varphi_2', \varphi_2) & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & (\varphi_K', \varphi_K) \end{bmatrix}$$

$$(\varphi_k, \varphi_j) = \begin{cases} 0 & \text{dla } k \neq j \\ \neq 0 & \text{dla } k = j \end{cases}$$

$$\begin{bmatrix} (\varphi_N', \varphi_N) & \dots & 0 \\ 0 & & 0 \\ \vdots & \ddots & \vdots \\ 0 & & 0 \\ 0 & \dots & (\varphi_0', \varphi_0) \end{bmatrix} \begin{bmatrix} p_N \\ \vdots \\ p_0 \end{bmatrix} = \begin{bmatrix} (f, \varphi_N) \\ \vdots \\ (f, \varphi_0) \end{bmatrix}$$

Aproksymacja jako metoda odwzorowania kształtu zaburzonych danych:

Innym problemem aproksymacji wielomianowej opartej o dużą ilość węzłów (niezależnie od stopnia wielomianu aproksymującego) jest złe „uwarunkowanie” macierzy przy zastosowaniu ciągu wielomianów w postaci naturalnej.

Rozwiązanie tego problemu jest takie samo jak w przypadku interpolacji – trzeba stworzyć inne ciągi wielomianów tak, aby zapewnić korzystne właściwości numeryczne.

$$A = \begin{bmatrix} (\varphi_1, \varphi_1) & 0 & \dots & 0 \\ 0 & (\varphi_2, \varphi_2) & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & (\varphi_K, \varphi_K) \end{bmatrix}$$

$$(\varphi_k, \varphi_j) = \begin{cases} 0 & \text{dla } k \neq j \\ \neq 0 & \text{dla } k = j \end{cases}$$

$$\begin{bmatrix} (\varphi_N, \varphi_N) & \dots & 0 \\ 0 & & 0 \\ \vdots & \ddots & \vdots \\ 0 & & 0 \\ 0 & \dots & (\varphi_0, \varphi_0) \end{bmatrix} \begin{bmatrix} p_N \\ \vdots \\ p_0 \end{bmatrix} = \begin{bmatrix} (f, \varphi_N) \\ \vdots \\ (f, \varphi_0) \end{bmatrix}$$

Takie właściwości mają ciągi wielomianów ortogonalnych!

Ciągi wielomianów ortogonalnych:

Ciąg funkcji nazwiemy ciągiem ortogonalnym jeżeli dowolne funkcje z tego ciągu spełniają warunek:

$$(\varphi_k, \varphi_j) = \begin{cases} 0 & \text{dla } k \neq j \\ \|\varphi_k\| \neq 0 & \text{dla } k = j \end{cases}$$

Dodatkowo jeżeli $\|\varphi_k\| = 1$ to taki ciąg nazywamy ciągiem ortonormalnym.

- Wielomiany ortogonalne są zdefiniowane (i ortogonalne) tylko na pewnych przedziałach.
- Na innych przedziałach należy je przekształcić z przedziału podstawowego, albo stworzyć nowy ciąg jedną z procedur ortogonalizacji np. ortogonalizacją Grama-Schmidta

Ciągi wielomianów ortogonalnych:

Ciąg funkcji nazwiemy ciągiem ortogonalnym jeżeli dowolne funkcje z tego ciągu spełniają warunek:

$$(\varphi_k, \varphi_j) = \begin{cases} 0 & \text{dla } k \neq j \\ \|\varphi_k\| \neq 0 & \text{dla } k = j \end{cases}$$

Dodatkowo jeżeli $\|\varphi_k\| = 1$ to taki ciąg nazywamy ciągiem ortonormalnym.

- Wielomiany ortogonalne są zdefiniowane (i ortogonalne) tylko na pewnych przedziałach.
- Na innych przedziałach należy je przekształcić z przedziału podstawowego, albo stworzyć nowy ciąg jedną z procedur ortogonalizacji np. ortogonalizacją Grama-Schmidta


Ciąg wielomianów „ogólnego przeznaczenia” nazywamy ciągiem Legendre’a:

$$P_n(x) = \frac{1}{2^n \cdot n!} \frac{d^n}{dx^n} (x^2 - 1)^n$$

Zastosowanie wielomianów ortogonalnych do zadań specjalnych:

Ogólna postać funkcji celu w zagadnieniu regresji może być wyrażona następująco:

$$J_2(\mathbf{p}) = \sum_{n=0}^N w(x_n) \left(\tilde{f}(x_n, \mathbf{p}) - f(x_n) \right)^2$$




Funkcja wagowa. Niektóre punkty mają większy wkład (są odwzorowane dokładniej niż inne)

Zastosowanie wielomianów ortogonalnych do zadań specjalnych:

Ogólna postać funkcji celu w zagadnieniu regresji może być wyrażona następująco:

$$J_2(\mathbf{p}) = \sum_{n=0}^N w(x_n) \left(\tilde{f}(x_n, \mathbf{p}) - f(x_n) \right)^2$$



Funkcja wagowa. Niektóre punkty mają większy wkład (są odwzorowane dokładniej niż inne)

Przykład:

Założmy, że chcemy odwzorować funkcję


$$f(x) = e^{(-x)^2} \cdot \frac{A \ln(x)}{B(x^3 - 3)}$$

W przedziale $[-\infty, \infty]$ na podstawie pewnego ciągu punktów będącego wycinkiem tej funkcji. Chodzi nam o odwzorowanie kształtu tej funkcji (nie znamy parametrów A i B)

Zastosowanie wielomianów ortogonalnych do zadań specjalnych:

Ogólna postać funkcji celu w zagadnieniu regresji może być wyrażona następująco:

$$J_2(\mathbf{p}) = \sum_{n=0}^N w(x_n) \left(\tilde{f}(x_n, \mathbf{p}) - f(x_n) \right)^2$$



Funkcja wagowa. Niektóre punkty mają większy wkład (są odwzorowane dokładniej niż inne)

Zagadka: Jak można rozwiązać ten problem?

Przykład:

Założmy, że chcemy odwzorować funkcję

$$f(x) = e^{(-x)^2} \cdot \frac{A \ln(x)}{B(x^3 - 3)}$$

W przedziale $[-\infty, \infty]$ na podstawie pewnego ciągu punktów będącego wycinkiem tej funkcji. Chodzi nam o odwzorowanie kształtu tej funkcji (nie znamy parametrów A i B)

Zastosowanie wielomianów ortogonalnych do zadań specjalnych:

Ogólna postać funkcji celu w zagadnieniu regresji może być wyrażona następująco:

$$J_2(\mathbf{p}) = \sum_{n=0}^N w(x_n) \left(\tilde{f}(x_n, \mathbf{p}) - f(x_n) \right)^2$$

Możemy kluczowy czynnik $e^{(-x)^2}$ wyłączyć w postaci wagi i uwzględnić to przy konstruowaniu ciągu wielomianów ortogonalnych

Przykład:


Założmy, że chcemy odwzorować funkcję

$$f(x) = e^{(-x)^2} \cdot \frac{A \ln(x)}{B(x^3 - 3)}$$

W przedziale $[-\infty, \infty]$ na podstawie pewnego ciągu punktów będącego wycinkiem tej funkcji. Chodzi nam o odwzorowanie kształtu tej funkcji (nie znamy parametrów A i B)

Zastosowanie wielomianów ortogonalnych do zadań specjalnych:

Ogólna postać funkcji celu w zagadnieniu regresji może być wyrażona następująco:

$$J_2(\mathbf{p}) = \sum_{n=0}^N w(x_n) \left(\tilde{f}(x_n, \mathbf{p}) - f(x_n) \right)^2$$


Przykład:

Założmy, że chcemy odwzorować funkcję

$$f(x) = e^{(-x)^2} \cdot \frac{A \ln(x)}{B(x^3 - 3)}$$

W przedziale $[-\infty, \infty]$ na podstawie pewnego ciągu punktów będącego wycinkiem tej funkcji. Chodzi nam o odwzorowanie kształtu tej funkcji (nie znamy parametrów A i B)

- Ciąg wielomianów ortogonalnych Hermite'a

Określony na przedziale $[-\infty, \infty]$. Ma postać:

$$\varphi_0(x) = 1, \quad \varphi_1(x) = 2x,$$

$$\varphi_k(x) = 2 \cdot x \cdot \varphi_{k-1}(x) - (2k - 2)\varphi_{k-2}(x)$$

Odpowiada wadze:

$$w(x) = e^{(-x)^2}$$

**Politechnika
Warszawska**

Dziękuję za uwagę

